EduSmart Decision Platform

Documentation complète : recherches, conception, tests et rapports (Phases 1 à 18)

Ndeye Penda SARR · Master 2 Business Intelligence, UCAD

Version L10 · 21/10/2026 (après le commit 80f006e)

Sommaire

1. Phase 1 — De la donnée opérationnelle à la décision
2. Phase 2 — Comprendre le besoin métier
3. Phase 3 — Les architectures décisionnelles
4. Phase 4 — ETL ou ELT ?
5. Phase 5 — Contrôle qualité des données
6. Phase 6 — Métadonnées et traçabilité
7. Phases 7, 8 et 9 — Conception du Data Warehouse
8. Phase 10 — Analyse multidimensionnelle (OLAP)
9. Phase 11 — KPI et indicateurs de performance
10. Phase 12 — Analyse et visualisation des données
11. Phase 13 — Power BI
12. Phase 14 — Data Storytelling
13. Phase 15 — Validation et tests du pipeline
14. Phase 16 — Rapport individuel
15. Phase 17 — Rapport décisionnel
16. Phase 18 — Présentation

Phase 1 — De la donnée opérationnelle à la décision

EduSmart Decision Platform · Lot L3 · Étape 1 du module BI

> **Objectif du PDF :** comprendre pourquoi les entreprises mettent en place des systèmes décisionnels.
>
> **Méthode :** chaque question de recherche est traitée en deux temps. D'abord la notion générale, puis son **illustration sur les 5 sources réellement construites** (volet A). Tous les chiffres cités sont recalculés par `python -m scripts.constats_sources`. Ce sont des calculs **exploratoires** avec des règles simples ; les valeurs officielles viendront du Data Warehouse.

Partie A — Comprendre les données opérationnelles

1. Qu'appelle-t-on une donnée opérationnelle ?

Une **donnée opérationnelle** est produite et utilisée par l'activité quotidienne de l'organisation : elle enregistre une **transaction** ou un **état courant**, au moment où il se produit, pour faire fonctionner un service.

Ses caractéristiques :

- **granulaire** : une ligne représente un fait élémentaire (un paiement, une connexion) ;
- **actuelle** : elle reflète l'état présent, et l'historique n'est pas toujours conservé ;
- **volatile** : elle est modifiée ou supprimée au fil des opérations ;

- **structurée pour le traitement**, et non pour l'analyse.

Chez EduSmart, chaque source en produit :

Source	Exemple de donnée opérationnelle	Ce qu'elle permet de faire
PostgreSQL	un paiement `PAY-2025-013460` de 700 000 XOF par Wave	encaisser une tranche de scolarité
MySQL	une note de 14,5/20 à la tentative 2 d'un quiz	valider un quiz, débloquer la suite du cours
CSV RH	le salaire d'octobre 2025 d'un enseignant	payer les enseignants
MongoDB	un événement `VIDEO_STARTED` en 720p sur un Tecno Spark 10	journaliser l'usage de l'application
Redis	`session:{id}` avec `status = ONLINE`	savoir qui est connecté *maintenant*

La donnée Redis est l'exemple extrême de la volatilité : elle n'existe que le temps d'une session (TTL de 24 h), et **la ville d'un étudiant n'est conservée nulle part avec son historique**. PostgreSQL ne garde que la ville actuelle. C'est précisément le problème traité en Phase 9 (SCD).

2. Qu'est-ce qu'une base OLTP ?

Une base **OLTP** (*Online Transaction Processing*) est conçue pour exécuter un **grand nombre de petites transactions** (insertion, mise à jour, lecture d'une ligne), avec des garanties d'intégrité fortes.

Ses caractéristiques techniques :

- **transactions ACID** : atomicité, cohérence, isolation, durabilité ;
- **modèle normalisé** (3e forme normale) : chaque information à un seul endroit, pour éviter les anomalies de mise à jour ;
- **index sur les clés primaires**, pour accéder vite à *une* ligne ;
- **nombreux utilisateurs simultanés**, avec un temps de réponse de l'ordre de la milliseconde.

Chez EduSmart, `edusmart_academic` (PostgreSQL) est une base OLTP typique : 5 tables normalisées reliées par des clés étrangères (`filieres → classes → inscriptions ← etudiants`, puis `inscriptions → paiements`).

Pour savoir « *combien a payé la filière IA en 2024-2025 ?* », il faut joindre 4 tables et agréger 40 150 paiements. Une base OLTP le permet, mais **ce n'est pas pour cela qu'elle est optimisée**.

MongoDB et Redis ne sont pas des SGBD relationnels, mais ils jouent aussi un **rôle opérationnel** : journaliser (MongoDB) et servir le temps réel (Redis).

3. Pourquoi une entreprise possède-t-elle plusieurs bases de données ?

Il y a trois raisons principales.

1. **Chaque besoin a sa technologie.** Chez EduSmart :
   - des transactions financières fiables → **PostgreSQL** ;
   - une plateforme web classique → **MySQL** ;
   - des journaux volumineux au schéma variable → **MongoDB** ;
   - un accès en quelques microsecondes → **Redis** ;
   - aucun outil au service RH → **des fichiers CSV**.
2. **L'histoire de l'organisation.** Le document de cadrage le dit : *« Au fil des années, plusieurs applications ont été développées. Chaque application possède sa propre base de données. »* On ajoute des applications ; on refond rarement l'existant.

3. **L'isolement des risques et des charges.** Une panne ou un pic de charge sur la plateforme de cours ne doit pas bloquer les encaissements.

4. Pourquoi chaque service possède-t-il souvent son propre système d'information ?

Parce que chaque service a ses **propres processus, son vocabulaire, ses priorités, son budget et ses prestataires**.

- La **scolarité** pense en *matricules*, *inscriptions* et *tranches*.
- La **pédagogie** pense en *comptes LMS*, *modules* et *quiz*.
- Les **RH** pensent en *codes enseignants*, *mois de paie* et *absences*.

Chez EduSmart, les RH n'ont même pas de base : ils exportent des fichiers. Chaque service choisit l'outil adapté à **son** métier, sans penser à la consolidation.

5. Quels sont les avantages de cette organisation ?

Avantage	Illustration EduSmart
Outil adapté à chaque métier	Le schéma flexible de MongoDB accepte des événements aux champs différents (un LOGIN n'a pas de `quiz_code`)
Performance locale	Redis répond instantanément au nombre de connectés
Autonomie des services	Les RH exportent leurs fichiers sans dépendre de l'informatique
Isolement des pannes	Une panne de MySQL n'empêche pas d'encaisser dans PostgreSQL
Évolution indépendante	L'application mobile passe de la version 2.0.0 à la 2.4.1 sans toucher aux autres systèmes

Ces avantages ont un coût : **l'information de l'entreprise est éclatée**. C'est l'objet de la partie B.

Partie B — Les limites des systèmes opérationnels

6. Quels problèmes rencontre-t-on lorsque les données sont réparties dans plusieurs systèmes ?

Problème	Constat mesuré sur les sources EduSmart
Identifiants incompatibles	PostgreSQL identifie par `id_etudiant` (UUID) et `matricule` ; MySQL, MongoDB et Redis par `student_code` (`LMS-XXXXXX`). **Aucune colonne commune.**
Hétérogénéité technique	4 technologies (SQL relationnel, documents JSON, clés-valeurs) + des fichiers ; 2 encodages (UTF-8, ISO-8859-1) ; 2 séparateurs CSV
Formats différents	Dates en 3 formats dans les CSV RH ; horodatages MongoDB stockés en date (291 289), en texte (4 739) **et** en nombre (1 573)
Référentiels incohérents	**171 écritures de villes différentes** dans PostgreSQL pour 49 villes réelles ; 8 valeurs pour le sexe (`M`, `F`, `Homme`, `Garçon`, `1`, `0`…) ; 19 écritures de modes de paiement
Même mot, sens différent	`device` vaut `Android` dans Redis mais `Samsung Galaxy A54` dans MongoDB
Unités différentes	Durée de connexion en **minutes** (MySQL), en **secondes** (MongoDB), sous forme d'horodatages (Redis)
Temporalités différentes	Redis ne connaît que l'instant présent ; PostgreSQL remonte à juin 2023

Problème	Constat mesuré sur les sources EduSmart
Pièges techniques	La collation MySQL `utf8mb4_unicode_ci` fusionne `Data`, `DATA` et `data` dans un `GROUP BY` et **cache** l'anomalie

7. Pourquoi les identifiants peuvent-ils être différents d'une base à l'autre ?

- **Chaque système génère ses propres clés** au moment où il crée l'objet. La scolarité crée le matricule à l'inscription ; la plateforme crée le compte LMS à la première connexion.
- **Les systèmes ont été conçus à des époques différentes, par des équipes différentes**, sans référentiel commun.
- **La consigne de conception l'impose parfois.** Le PDF MySQL écrit : *« Ne pas utiliser id_etudiant de PostgreSQL. Utiliser student_code »*.
- **Tout le monde n'existe pas partout** :
  - 1 000 étudiants inscrits n'ont **jamais** activé leur compte LMS ;
  - 500 comptes LMS n'ont **aucune** inscription (auditeurs libres, comptes de test, anciens étudiants).

Conséquence : le lien entre les systèmes n'existe que dans une **table de correspondance** (`mapping_etudiants.csv`, 9 000 paires). Les 1 500 cas restants ne peuvent pas être rapprochés automatiquement.

S'y ajoutent les **erreurs de saisie des identifiants eux-mêmes** : `lms-000154`, `LMS000154` ou `LMS-154` au lieu de `LMS-000154` (7 721 notes MySQL). Résultat : MySQL contient **16 476 codes étudiants distincts pour 9 500 comptes réels**.

8. Pourquoi une même information peut-elle être présente plusieurs fois ?

- **Redondance voulue entre systèmes.** Un paiement Wave fait depuis le téléphone existe dans PostgreSQL (la transaction) **et** dans MongoDB (l'événement `PAYMENT_SUCCESS`, même référence `PAY-…`). La progression existe dans MySQL **et** dans Redis (le PDF prévoit qu'elle transite par Redis).
- **Doublons techniques :**
  - un export RH lancé deux fois (102 lignes de salaires strictement identiques) ;
  - un événement journalisé deux fois (12 164 dans MongoDB) ;
  - une inscription saisie deux fois (366).
- **Doublons de saisie :** le même département écrit « Data », « Développement Data » et « Data Engineering ».

9. Quels risques cela représente-t-il pour les décideurs ?

Un décideur qui interrogerait directement les sources obtiendrait des **chiffres faux, contradictoires ou impossibles à justifier** :

Question du DG	Calcul naïf	Calcul avec des règles simples	Écart
Combien d'étudiants ?	10 000 (PostgreSQL) + 16 476 (MySQL) = **26 476**	**10 500 personnes** (10 000 inscrits + 500 comptes LMS sans inscription)	×2,5
Chiffre d'affaires ?	somme de toutes les lignes : **14,19 Mds XOF**	paiements VALIDE rattachés à une inscription : **12,91 Mds XOF**	+9,9 %
CA vu par l'application ?	somme des `PAYMENT_SUCCESS` de MongoDB : **5,14 Mds XOF**	ce n'est qu'une partie des paiements (mobile money via l'application)	−60 %

Question du DG	Calcul naïf	Calcul avec des règles simples	Écart
Temps moyen de connexion ?	**34,6 min** (MySQL, durées négatives comprises)	**37,7 min** sans les 2 453 durées négatives ; 29,3 min selon les sessions MongoDB	selon la source et la règle
Formation la plus suivie ?	« Génie Logiciel » (1 983 inscriptions)	**Intelligence Artificielle (2 561)**, une fois réunis les libellés « IA », « Ingénierie IA » et « Intelligence Artificielle »	**le classement s'inverse**

Les risques qui en découlent :

- **décisions erronées** : investir dans la mauvaise filière ;
- **perte de confiance** : deux directeurs arrivent en réunion avec deux chiffres différents ;
- **temps perdu** à réconcilier à la main ;
- **absence de traçabilité** : impossible de dire d'où vient un chiffre ;
- **risque réglementaire** sur les données financières.

Le cas du CA illustre bien le danger : 1 650 paiements VALIDE rattachés sont **négatifs** (une erreur de signe). Faut-il les exclure, les corriger en valeur absolue (14,20 Mds) ou les signaler ? **C'est une décision métier**, pas technique (Phase 2).

Partie C — Les besoins métier

10. Quelles informations un Directeur Général souhaite-t-il consulter quotidiennement ?

Un DG pilote la **santé globale** de l'organisation. Il suit :

- des **indicateurs de résultat** : chiffre d'affaires, encaissements du jour, nombre d'étudiants actifs, taux de réussite ;
- des **indicateurs de risque** : abandons, impayés, baisse d'activité sur la plateforme ;
- des **tendances** : évolution par rapport à la veille, au mois ou à l'année précédente ;
- des **alertes** : écart à un objectif, anomalie.

Le cas pratique du PDF liste 7 informations. Elles sont analysées au point 11 et dans le cas pratique.

11. Ces informations existent-elles dans une seule base ?

Non. Aucune des 7 informations demandées ne peut être produite de façon fiable à partir d'une seule source, et **deux n'existent nulle part** :

Information demandée	Sources	Une seule suffit ?
Nombre réel d'étudiants	PostgreSQL + MySQL (+ MongoDB, Redis) + correspondance	❌ Il faut réunir les inscrits et les comptes LMS
Chiffre d'affaires	PostgreSQL (référence), MongoDB (rapprochement)	⚠️ PostgreSQL suffit, mais il doit être nettoyé
Taux de réussite	MySQL (quiz)	⚠️ Au niveau du **quiz** seulement : aucun diplôme ni examen final n'est enregistré
Satisfaction des étudiants	—	❌ **Aucune source**

Information demandée	Sources	Une seule suffit ?
Formations les plus suivies	PostgreSQL (filières), MySQL (modules), MongoDB (consultations)	⚠️ Trois définitions possibles
Temps moyen de connexion	MySQL, MongoDB, Redis	⚠️ Trois mesures, deux unités
Enseignants les mieux évalués	—	❌ **Aucune source** : ni évaluation, ni lien enseignant ↔ cours

12. Pourquoi un directeur ne consulte-t-il jamais directement les bases opérationnelles ?

1. **Performance.** Une requête d'agrégation sur 300 000 notes ou 300 000 événements ralentit la base qui sert les étudiants.
2. **Complexité.** Il faut connaître 4 langages ou API (SQL PostgreSQL, SQL MySQL, requêtes MongoDB, commandes Redis), 24 tables, fichiers ou structures et leurs pièges (collation, encodage, formats de date).
3. **Données non fiables en l'état.** Voir le tableau du point 9.
4. **Absence d'historique.** Redis ne sait rien d'hier ; PostgreSQL ne garde pas l'ancienne ville d'un étudiant.
5. **Sécurité et confidentialité.** Les bases contiennent des téléphones, des adresses, des salaires et des adresses IP. On ne donne pas un accès direct à la production.
6. **Absence de langage commun.** « Étudiant actif » ne signifie rien pour une base : il faut une **définition métier partagée**.

Partie D — Introduction à la BI

13. Qu'est-ce que la Business Intelligence ?

La **Business Intelligence** (informatique décisionnelle) est l'ensemble des **méthodes, processus, architectures et outils** qui transforment des données brutes, dispersées et hétérogènes en **informations fiables, partagées et exploitables pour la décision**.

Elle couvre toute la chaîne que suit ce projet :

```
Sources opérationnelles → Intégration (ETL/ELT) → Qualité & métadonnées → Entrepôt (DW)
   → Modèle multidimensionnel → Analyse (OLAP, KPI) → Restitution (Power BI) → Décision
```

14. Quels sont ses objectifs ?

Objectif	Traduction EduSmart
Consolider les données dispersées	Réunir 5 sources sous une vue « étudiant » unique
Fiabiliser : une seule version de la vérité	Un seul chiffre d'affaires, défini et documenté
Historiser	Suivre les déménagements, l'évolution des effectifs par année académique
Analyser selon plusieurs axes	CA par région, filière, mode de paiement et mois
Mesurer la performance avec des KPI	Taux de réussite, taux d'abandon, étudiants actifs
Diffuser l'information au bon niveau	Tableau de bord du DG, vues détaillées pour la pédagogie et la finance
Tracer l'origine de chaque chiffre	Métadonnées et journal d'exécution (Phase 6)

Objectif	Traduction EduSmart
Révéler ce que les données ne disent pas	Gaps : satisfaction, évaluation et activité des enseignants

15. Quelle différence entre une base opérationnelle et un système décisionnel ?

Critère	Base opérationnelle (OLTP)	Système décisionnel (OLAP / DW)
Finalité	Faire fonctionner l'activité	Comprendre et piloter l'activité
Utilisateurs	Nombreux (étudiants, agents)	Peu nombreux (décideurs, analystes)
Opérations	Insertions, mises à jour, lecture d'une ligne	Lectures massives, agrégations
Modèle	Normalisé (3FN)	Dénormalisé (étoile, constellation)
Données	Courantes, détaillées, modifiables	Historisées, intégrées, non volatiles
Périmètre	Une application	Toute l'organisation
Qualité	Celle de la saisie	Contrôlée, nettoyée, documentée
Temps de réponse	Millisecondes par transaction	Secondes pour une analyse complexe
Exemple EduSmart	`edusmart_academic.paiements`	`dw.fact_paiements` × `dim_temps` × `dim_region`

La définition de référence d'un entrepôt de données (W. H. Inmon) résume la différence : une collection de données **orientées sujet, intégrées, historisées et non volatiles**, destinée à l'aide à la décision.

16. Pourquoi la BI est-elle indispensable aujourd'hui ?

- **Le volume et la variété des données explosent.** Même une structure de taille moyenne comme EduSmart produit près de **800 000 enregistrements** (799 037) dans 4 technologies et des fichiers, en 3 ans.
- **La concurrence impose des décisions rapides et fondées** : quelle filière ouvrir, quel module refondre, quand relancer un impayé.
- **La décision « à l'intuition » coûte cher.** L'inversion du classement des formations (point 9) le montre.
- **Les exigences de traçabilité** (financière, pédagogique) imposent de justifier chaque chiffre.
- **Les outils sont devenus accessibles** (Power BI, bases open source), mais ils n'ont de valeur que sur des **données intégrées et fiables**.

Cas pratique EduSmart

Où se trouvent ces données ?

Information du DG	PostgreSQL	MySQL	CSV RH	MongoDB	Redis
Nombre réel d'étudiants	● inscrits	● comptes LMS		○	○
Chiffre d'affaires	● paiements			○ `PAYMENT_*`	○ notifications
Taux de réussite	○ statut DIPLOME	● `notes.valide`		○ `QUIZ_SUBMITTED`	

Information du DG	PostgreSQL	MySQL	CSV RH	MongoDB	Redis
Satisfaction					
Formations les plus suivies	● inscriptions	● progression		○ `COURSE_OPENED`	
Temps moyen de connexion		● `temps_connexion`		● sessions	○ `session:*`
Enseignants les mieux évalués	○ `classes.responsable` (nom)		○ `enseignants.csv`		

● source principale · ○ source partielle ou de rapprochement

Une seule source suffit-elle ?

Non, pour les raisons développées aux points 9 et 11. Même le chiffre d'affaires, présent dans une seule base, n'est pas utilisable tel quel.

Peut-on construire directement un tableau de bord sur les cinq sources ?

Techniquement, en partie : Power BI sait se connecter à PostgreSQL, MySQL et à des fichiers CSV (MongoDB et Redis demandent des connecteurs particuliers). **Mais ce serait une erreur** :

- Power BI devrait **refaire le rapprochement** étudiant ↔ compte LMS à chaque actualisation ;
- les **règles de nettoyage** (171 villes, 19 modes de paiement, 8 écritures du sexe) seraient enfouies dans des requêtes Power Query, impossibles à tester et à tracer ;
- les **bases de production** seraient interrogées en direct ;
- **Redis serait vide ou différent** à chaque actualisation, car ses données sont temporaires ;
- **aucun historique** ne serait constitué ;
- chaque rapport risquerait de **calculer différemment** le même indicateur.

Quels problèmes rencontrera-t-on ?

Ce sont les constats de la partie B, résumés en quatre familles :

1. **Intégration** : identifiants sans clé commune, codes de contenus non résolubles (89 codes MongoDB absents de `mapping_courses.csv`), même nom de champ au sens différent.
2. **Qualité** : de 7 à 19 types d'anomalies selon la source, soit **159 946 anomalies journalisées au total**.
3. **Technique** : encodages, séparateurs, formats de dates, types mixtes MongoDB, collation MySQL, données Redis temporaires.
4. **Sémantique** : pas de définition partagée de l'« étudiant actif », de la « réussite » ou de l'« abandon », et des indicateurs sans aucune donnée (satisfaction, évaluation et activité des enseignants).

Quelle solution proposeriez-vous ?

Un système décisionnel en quatre briques, détaillé en Phases 3 et 4 :

1. un **pipeline d'intégration** qui extrait les 5 sources, les charge **brutes** puis les transforme (**ELT**, Phase 4) ;

2. un **contrôle qualité** et des **métadonnées** à chaque exécution (Phases 5 et 6) ;
3. un **entrepôt de données PostgreSQL** organisé en couches (brut → nettoyé → modèle en constellation), historisé (Phases 3, 7, 8 et 9) ;
4. une **restitution Power BI** fondée sur des **KPI définis avec le métier** (Phases 11 à 14).

Et, **avant toute technique, un travail de définition avec le métier** (Phase 2) : quel « chiffre d'affaires », quel « étudiant actif », quelle « réussite ».

Synthèse

Idée clé	Preuve EduSmart
Les données opérationnelles servent à *faire*, pas à *décider*	5 sources, 4 technologies, chacune optimisée pour son métier
La dispersion fausse les chiffres	26 476 « étudiants » pour 10 500 personnes réelles
La qualité change les décisions	Le classement des formations s'inverse après standardisation
Certains besoins n'ont aucune donnée	Satisfaction, évaluation des enseignants : des gaps à remonter au DG
La BI apporte une version unique, historisée et traçable de la vérité	Objet des phases 3 à 18

Références

- PDF « BI Recherche P8 », Phase 1 (questions 1 à 16 et cas pratique) ; « Données EduSmart » (cadrage).
- W. H. Inmon, *Building the Data Warehouse* (1992) : définition de l'entrepôt de données.
- R. Kimball et M. Ross, *The Data Warehouse Toolkit* : modélisation dimensionnelle.
- Chiffres : `python -m scripts.constats_sources`, à partir des sources du volet A (graine 2026).

Phase 2 — Comprendre le besoin métier

EduSmart Decision Platform · Lot L3 · Étape 1 du module BI

> **Objectif du PDF :** apprendre qu'un projet BI commence toujours par le **métier**, et non par la technologie.
>
> La Phase 1 a montré que les données d'EduSmart peuvent produire des chiffres très différents selon la règle appliquée : de 12,9 à 14,2 Mds XOF de CA, de 10 500 à 26 476 « étudiants ». **Choisir la règle n'est pas une décision technique** : c'est l'objet de cette phase.

Recherche

1. Qu'est-ce qu'un besoin métier ?

Un **besoin métier** exprime ce qu'un acteur de l'organisation doit **savoir, décider ou améliorer** pour atteindre ses objectifs, **dans son vocabulaire à lui** et indépendamment de toute solution technique.

Il comporte quatre éléments :

Élément	Question	Exemple EduSmart
Acteur	Qui a besoin de l'information ?	Le Directeur Général
Objectif	Pour atteindre quel but ?	Réduire les abandons
Question	Que doit-il savoir ?	Quelles filières perdent le plus d'étudiants, et à quel moment de l'année ?
Décision	Qu'en fera-t-il ?	Renforcer le tutorat de la filière concernée au 1er trimestre

Un besoin sans décision associée est une **curiosité**, pas un besoin. Un indicateur que personne n'utilise pour agir est du bruit dans le tableau de bord.

2. Pourquoi faut-il comprendre les objectifs du client avant de développer un tableau de bord ?

1. **Pour choisir les bonnes règles de calcul.** Les données EduSmart permettent au moins trois calculs du CA. Seul le métier peut dire si un paiement `EN_ATTENTE` compte, si un paiement négatif est une erreur de signe ou un remboursement, et si le CA se rattache à la date de paiement ou à l'année académique.
2. **Pour construire le bon modèle de données.** La **granularité** du Data Warehouse (Phase 7) découle des questions. Si le DG veut le CA par jour et par mode de paiement, le fait « paiement » doit garder la date et le mode. Si l'on agrège trop tôt, l'information est perdue.
3. **Pour ne pas construire l'inutile.** Un tableau de bord de 40 graphiques que personne ne regarde coûte cher et dilue le message.
4. **Pour révéler les manques.** La satisfaction et l'évaluation des enseignants n'existent dans aucune source. Sans analyse du besoin, on s'en aperçoit trop tard, le jour de la démonstration.
5. **Pour obtenir l'adhésion.** Un décideur fait confiance à un chiffre dont il a validé la définition.

3. Quelle différence entre une demande métier et une demande technique ?

	Demande métier	Demande technique
Porte sur	Un **problème** ou une **décision**	Une **solution** ou un **outil**

	Demande métier	Demande technique
Vocabulaire	Métier (abandon, encaissement, réussite)	Informatique (table, graphique, API)
Exemple EduSmart	« Je veux savoir pourquoi les étudiants abandonnent. »	« Je veux un graphique en barres Power BI des inscriptions au statut ABANDON. »
Exemple EduSmart	« Je veux être alerté quand les encaissements ralentissent. »	« Ajoute une jauge du CA mensuel en page 1. »
Risque	Rester floue	Répondre à la mauvaise question
Rôle de l'analyste BI	La **préciser** et la **quantifier**	**Remonter** au besoin qui l'a motivée (« pourquoi ? »)

Une demande technique doit toujours être **ramenée à la demande métier** qui la motive.

Exemple : on demande « un graphique des connexions ». En cherchant le besoin, on découvre que le DG veut savoir si la plateforme mobile est utilisée. La bonne réponse mobilise alors MongoDB (sessions de l'application), et pas seulement MySQL (temps de connexion).

4. Comment identifier les indicateurs réellement utiles ?

Méthode : partir des objectifs, pas des données disponibles.

```
Objectif stratégique → Questions de pilotage → Indicateurs → Données nécessaires →
Sources disponibles ?
```

C'est l'approche GQM (*Goal – Question – Metric*). Chaque indicateur retenu doit passer ces critères :

Critère	Question à se poser
Lié à un objectif	Quel objectif mesure-t-il ?
Actionnable	Quelle décision prendra-t-on s'il monte ou descend ?
Défini sans ambiguïté	Deux personnes le calculeraient-elles pareil ?
Mesurable	Les données existent-elles, et sont-elles assez fiables ?
Comparable	Peut-on le suivre dans le temps et le comparer à une cible ?
Compréhensible	Le DG le comprend-il sans explication ?

Ces critères seront approfondis en Phase 11 (KPI et critères SMART).

Outils de recueil :

- entretiens avec les acteurs, guidés par des questions ouvertes (voir ci-dessous) ;
- analyse des rapports existants (s'il y en a) ;
- ateliers de priorisation (méthode MoSCoW) ;
- **confrontation aux données réelles** : le profilage du volet A révèle ce qui est faisable.

Application à EduSmart

Les acteurs et leurs objectifs

Le PDF ne nomme que le Directeur Général. Les autres acteurs sont **déduits des sources** (chaque source correspond à un service) : ce sont des hypothèses de travail à confirmer.

Acteur	Objectifs	Sources concernées
Directeur Général (commanditaire)	Croissance, rentabilité, réputation, réduction des abandons	Toutes
Direction des études / scolarité	Effectifs, réussite, abandons, remplissage des classes	PostgreSQL, MySQL
Direction financière	Encaissements, impayés, modes de paiement	PostgreSQL, (MongoDB)
Direction pédagogique / plateforme	Engagement, progression, contenus les plus utiles	MySQL, MongoDB
Ressources humaines	Masse salariale, absentéisme, remplacements	CSV RH
Direction technique	Usage mobile, versions de l'application, qualité de service	MongoDB, Redis

Matrice « besoin → indicateur → données »

#	Objectif	Question de pilotage	Indicateur candidat	Sources	Faisabilité
1	Croissance	Combien d'étudiants avons-nous réellement ?	Nombre d'étudiants distincts (inscrits, avec ou sans compte LMS)	PG + MySQL + correspondance	✅ Avec la table de correspondance
2	Rentabilité	Combien encaissons-nous ?	Chiffre d'affaires encaissé	PostgreSQL	✅ Après nettoyage (règles à valider)
3	Rentabilité	Les étudiants paient-ils à temps ?	Taux de recouvrement (encaissé / dû)	PostgreSQL (`cout_total`, `reduction`, paiements)	✅
4	Qualité pédagogique	Les étudiants réussissent-ils ?	Taux de réussite aux quiz	MySQL	⚠️ Niveau quiz uniquement
5	Réduction des abandons	Combien abandonnent, où, quand ?	Taux d'abandon	PostgreSQL (`statut = ABANDON`)	✅
6	Engagement	Les étudiants progressent-ils ?	Progression moyenne	MySQL (+ Redis)	✅
7	Engagement	Combien d'étudiants utilisent la plateforme ?	Étudiants actifs	MySQL, MongoDB, Redis	✅ Définition à valider
8	Offre de formation	Quelles formations attirent ?	Inscriptions par filière ; suivis par module	PostgreSQL, MySQL	✅ Après standardisation des libellés
9	Engagement	Combien de temps passent-ils connectés ?	Durée moyenne de connexion	MySQL, MongoDB	⚠️ Deux mesures, deux unités
10	Réputation	Les étudiants sont-ils satisfaits ?	Satisfaction	—	❌ **Aucune donnée**
11	Qualité d'enseignement	Quels enseignants sont les mieux évalués ?	Note moyenne des enseignants	—	❌ **Aucune donnée**
12	Maîtrise des coûts	Que coûtent les enseignants ?	Masse salariale mensuelle	CSV RH	✅ Après nettoyage (formule du net, doublons)

#	Objectif	Question de pilotage	Indicateur candidat	Sources	Faisabilité
13	Continuité pédagogique	Les absences sont-elles remplacées ?	Taux d'absentéisme, taux de remplacement	CSV RH	✅
14	Usage mobile	L'application est-elle utilisée, et à jour ?	Sessions mobiles, part de la dernière version	MongoDB	✅

Les indicateurs 1, 2, 4, 8, 9, 10 et 11 correspondent exactement aux 7 demandes du DG (Phase 1). Les indicateurs 5, 6 et 7 correspondent aux exemples de KPI de la Phase 11.

Définitions à faire valider par le métier

Pour chacune de ces définitions, **les données ne tranchent pas** : c'est une décision métier. Les propositions ci-dessous seront reprises en Phase 11.

Notion	Options possibles	Proposition	Impact chiffré (Phase 1)
Étudiant	inscrit (PG) ; compte LMS (MySQL) ; les deux	Personne distincte inscrite **ou** ayant un compte LMS, avec ventilation	10 500 (10 000 inscrits + 500 comptes LMS seuls)
Chiffre d'affaires	toutes les lignes ; paiements VALIDE ; VALIDE rattachés ; négatifs en valeur absolue	Paiements **VALIDE**, rattachés à une inscription, **négatifs signalés et exclus** en attendant une décision	de 12,91 à 14,20 Mds XOF
Réussite	quiz validé à la 1re tentative ; quiz validé au moins une fois ; diplôme	Part des couples (étudiant, quiz) validés au moins une fois	74,1 % par tentative contre 91,5 % par (étudiant, quiz)
Abandon	statut ABANDON ; plus d'activité LMS depuis 60 jours	Statut ABANDON (PostgreSQL), rapproché de l'inactivité LMS	—
Étudiant actif	connecté dans la journée ; dans les 30 derniers jours ; en ce moment	Au moins une activité (MySQL ou MongoDB) dans les **30 derniers jours**	241 connectés à 23 h, 729 actifs le 15/09
Temps de connexion	durée MySQL ; durée des sessions mobiles	Durée MySQL (minutes), **médiane** plutôt que moyenne	médiane 28 min ; moyenne de 34,6 à 37,7 min selon la règle
Formation	filière (PG) ; module (MySQL)	Deux axes distincts : l'offre diplômante (filière) et les contenus (module)	L'IA passe de 5e à 1re après unification des libellés

L'exemple de la **réussite** est parlant : 74 % et 91 % sont deux réponses exactes à deux questions différentes. Sans définition partagée, deux rapports donneront deux chiffres « vrais » et contradictoires.

Besoins non couverts par les données (gaps)

Besoin	Pourquoi il n'est pas couvert	Recommandation (Phase 18)
Satisfaction des étudiants	Aucune enquête, aucune note de cours dans les 5 sources	Mettre en place une enquête de fin de module (application mobile)
Enseignants les mieux évalués	Aucune évaluation ; le lien enseignant ↔ cours n'existe que par le **nom** du responsable de classe	Créer une table d'affectation (le fichier « affectations » est mentionné par le PDF RH, jamais décrit) et une évaluation des enseignements
Activité des enseignants sur la plateforme	Aucun journal de connexion des enseignants (`active_teachers` de Redis n'est pas vérifiable)	Journaliser les connexions des enseignants

Besoin	Pourquoi il n'est pas couvert	Recommandation (Phase 18)
Réussite diplômante	Pas de notes d'examen ni de délibération ; le statut DIPLOME est la seule trace	Intégrer les résultats d'examens

Remonter ces gaps fait partie du livrable : **dire au DG ce que ses données ne permettent pas de savoir** est aussi utile que de lui montrer ce qu'elles savent.

Guide d'entretien avec le Directeur Général

1. Quelles sont vos trois priorités pour l'année ?
2. Quelles décisions prenez-vous chaque semaine ? Sur quelles informations ?
3. Quel chiffre regardez-vous en premier le lundi matin ?
4. Pour vous, qu'est-ce qu'un « étudiant actif » ? Et un « abandon » ?
5. Le chiffre d'affaires doit-il suivre la date de paiement ou l'année académique ?
6. Un paiement en attente ou remboursé compte-t-il dans le CA ?
7. Qu'attendez-vous d'un « taux de réussite » : la réussite aux quiz ou l'obtention du diplôme ?
8. Quels seuils vous alerteraient ? (Exemple : un taux d'abandon supérieur à 8 %.)
9. À quel niveau de détail descendez-vous : région, filière, classe, étudiant ?
10. Qui d'autre doit voir ces indicateurs ? Avec quelles restrictions (salaires) ?

Priorisation (MoSCoW, proposition)

Priorité	Indicateurs
Must (indispensable)	Étudiants distincts, CA encaissé, taux de réussite, taux d'abandon, étudiants actifs
Should (important)	Progression moyenne, formations les plus suivies, recouvrement, durée de connexion
Could (souhaitable)	Masse salariale, absentéisme, usage mobile
Won't (pas maintenant, faute de données)	Satisfaction, évaluation des enseignants → recommandations

---

Synthèse

Idée clé	Illustration
Le besoin métier précède la technique	Le choix de la règle du CA fait varier le chiffre de 10 %
Toute demande technique se ramène à un besoin	« Un graphique des connexions » → « la plateforme mobile est-elle utilisée ? »
Un indicateur utile est lié à une décision	L'abandon mène au renforcement du tutorat ; la satisfaction ne peut pas être mesurée
Les définitions doivent être validées	Réussite : 74 % ou 91 % selon la définition
L'analyse du besoin révèle les gaps	4 besoins sans données, à remonter au DG

Références

- PDF « BI Recherche P8 », Phase 2 (questions 1 à 4) ; Phase 1 (cas pratique) ; Phase 11 (exemples de KPI).
- V. Basili, G. Caldiera et H. D. Rombach, *The Goal Question Metric Approach* (1994).
- Chiffres : `python -m scripts.constats_sources` et `docs/01_operationnel_vers_decision.md`.

Phase 3 — Les architectures décisionnelles

EduSmart Decision Platform · Lot L3 · Étapes 1 et 2 du module BI

> **Demande du PDF :** étudier le Data Warehouse, le Data Mart, le Data Lake et le Data Lakehouse, selon cinq axes : définition, architecture, avantages, limites, cas d'utilisation. Puis proposer et justifier une architecture pour EduSmart.

---

1. Data Warehouse (entrepôt de données)

Définition

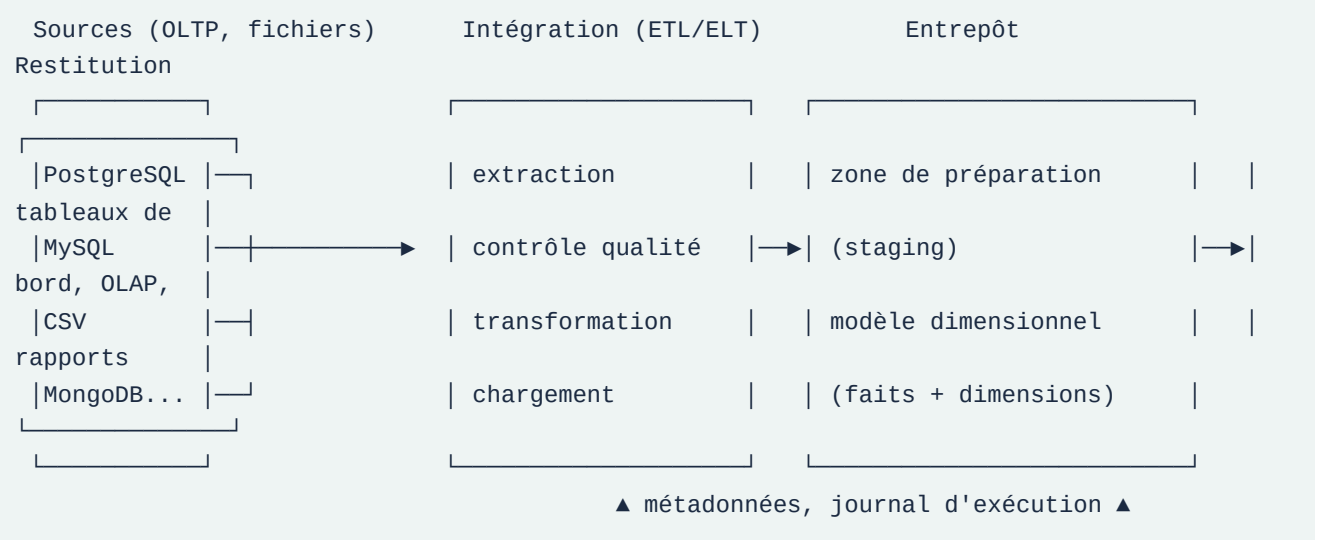
Un **Data Warehouse** est une base de données centrale qui **intègre** les données de plusieurs sources opérationnelles, les **nettoie**, les **historise** et les **organise pour l'analyse**.

La définition de W. H. Inmon reste la référence : une collection de données

- **orientées sujet** (étudiant, paiement, et non « application MySQL ») ;
- **intégrées** (identifiants, formats et référentiels unifiés) ;
- **historisées** (le temps est une dimension) ;
- **non volatiles** (on ajoute, on ne modifie pas l'historique) ;

destinée à l'aide à la décision.

Architecture



Il existe deux grandes approches de construction :

- **Inmon (descendante)** : un entrepôt d'entreprise normalisé, à partir duquel on dérive des data marts.
- **Kimball (ascendante)** : des modèles dimensionnels en étoile, construits sujet par sujet et reliés par des **dimensions conformes**. C'est l'approche des Phases 7 et 8.

Avantages

- **Une seule version de la vérité** : une définition du CA, un comptage des étudiants.
- **Données fiables et nettoyées** ; qualité mesurée.
- **Historique** : suivi dans le temps, dimensions à évolution lente (Phase 9).
- **Performance d'analyse** : modèle dénormalisé, agrégations rapides, sans charger les bases de production.
- **Traçabilité** : métadonnées, lignage, journal d'exécution.
- Parfaitement adapté aux **outils BI** (Power BI) et au **SQL**.

Limites

- **Conception exigeante** : il faut modéliser *avant* de charger (*schema-on-write*).
- **Rigidité** : une nouvelle question non prévue peut exiger de modifier le modèle.
- **Coût et délai** de mise en place, en particulier l'intégration.
- **Peu adapté aux données non structurées** (images, vidéos, textes libres) et au temps réel strict.
- La **latence** : des données souvent rafraîchies une fois par jour.

Cas d'utilisation

Pilotage de la performance, reporting financier, tableaux de bord de direction, analyses historiques. **C'est le cas typique d'une direction qui veut ses indicateurs de pilotage consolidés.**

---

2. Data Mart (magasin de données)

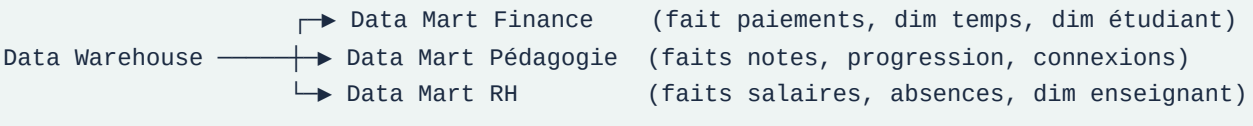
Définition

Un **Data Mart** est un **sous-ensemble** de données décisionnelles consacré à **un domaine métier** ou à un service (finance, pédagogie, RH). Il contient uniquement les faits et les dimensions utiles à ce domaine.

Architecture

On en distingue deux formes :

- **Dépendant** : il est alimenté *à partir du Data Warehouse*. C'est la forme recommandée, car les définitions restent cohérentes.
- **Indépendant** : il est alimenté *directement depuis les sources*. C'est rapide à construire, mais on recrée des silos.



Avantages

- **Simple et rapide** pour les utilisateurs d'un service.
- **Performances** : un volume réduit, un modèle ciblé.
- **Sécurité** : chaque service ne voit que son domaine (les salaires RH restent confidentiels).
- Permet une **mise en œuvre progressive**, domaine par domaine.

Limites

- Des marts **indépendants** recréent des silos, avec des définitions divergentes : le problème même que la BI veut résoudre.
- **Redondance** des données et des traitements.
- **Pas de vue transverse** à lui seul : le DG a besoin de croiser finance et pédagogie.

Cas d'utilisation

Besoin d'un service précis, périmètre limité, sécurité par domaine, projet pilote avant un entrepôt complet.

---

3. Data Lake (lac de données)

Définition

Un **Data Lake** est un espace de stockage **massif et peu coûteux** qui conserve les données **brutes, dans leur format natif** (structurées, semi-structurées, non structurées). La structure n'est imposée **qu'à la lecture** (*schema-on-read*). Le terme a été popularisé par J. Dixon en 2010.

Architecture

```
Sources (tout format) ──► stockage objet (S3, ADLS, HDFS) organisé en zones :
                          brut (raw) ─► nettoyé ─► préparé
                          + catalogue de métadonnées
                          + moteurs de traitement (Spark, SQL distribué, ML)
```

Avantages

- **Tout conserver**, sans devoir modéliser à l'avance.
- **Souplesse** : de nouvelles analyses sont possibles sur des données brutes.
- **Faible coût** de stockage, **passage à l'échelle** (téraoctets, pétaoctets).
- Adapté au **Big Data**, à la **science des données** et au **machine learning** (fichiers, images, logs).

Limites

- Risque de **« marécage de données »** (*data swamp*) : sans gouvernance ni catalogue, personne ne sait ce que contient le lac, ni si c'est fiable.
- **Qualité non garantie** : la donnée est brute.
- **Pas de transactions ACID** natives ; mises à jour difficiles.
- **Performances médiocres** pour le reporting interactif ; il faut souvent recopier dans un entrepôt pour la BI.
- Exige des **compétences** spécialisées (Spark, formats Parquet) et une infrastructure distribuée.

Cas d'utilisation

Très gros volumes et grande variété (logs, IoT, images), exploration par des data scientists, entraînement de modèles, archivage à bas coût.

---

4. Data Lakehouse

Définition

Un **Data Lakehouse** combine le **stockage bon marché et ouvert d'un lac** (fichiers Parquet sur stockage objet) avec les **fonctions d'un entrepôt** : transactions ACID, schémas, gouvernance, performances SQL. Cela passe par une **couche de tables transactionnelles** (Delta Lake, Apache Iceberg, Apache Hudi). Le concept a été formalisé par M. Armbrust et al. (CIDR 2021).

Architecture

Elle est souvent organisée en **médaillon** :

```
Sources ─► Stockage objet + format de table ouvert (Delta / Iceberg)
           ├── Bronze : données brutes, telles qu'extraites
           ├── Argent : données nettoyées, conformes, dédoublonnées
           └── Or     : données agrégées / modèles dimensionnels pour la BI
          + moteur SQL, ML et streaming sur les MÊMES données
```

Avantages

- **Une seule plateforme** pour la BI **et** la science des données, **sans copie** entre lac et entrepôt.
- **ACID, versions** (*time travel*), évolution de schéma.
- **Coût du stockage objet**, formats ouverts (pas d'enfermement propriétaire).
- Adapté aux **gros volumes** et au **temps réel** (streaming).

Limites

- **Technologie récente** et en évolution ; écosystème complexe (Spark, Databricks, catalogues).
- Exige une **infrastructure** (cloud ou cluster) et des **compétences** avancées.
- **Surdimensionné** pour de petits volumes structurés.
- Les performances BI interactives peuvent rester inférieures à celles d'un entrepôt bien optimisé.

Cas d'utilisation

Organisations qui ont **à la fois** de gros volumes variés, des besoins BI **et** des besoins de machine learning ou de temps réel : grandes plateformes numériques, télécoms, banques.

---

5. Comparaison

Critère	Data Warehouse	Data Mart	Data Lake	Data Lakehouse
Données	Structurées, intégrées	Structurées, un domaine	Tout format, brut	Tout format, brut → raffiné
Schéma	À l'écriture	À l'écriture	À la lecture	Les deux (couches)
Qualité	Élevée, contrôlée	Élevée (si dépendant)	Non garantie	Croissante par couche
Historique	Oui (SCD)	Oui	Oui (brut)	Oui (+ *time travel*)
ACID	Oui	Oui	Non	Oui
Volume visé	Go → To	Mo → Go	To → Po	To → Po

Critère	Data Warehouse	Data Mart	Data Lake	Data Lakehouse
Utilisateurs	Décideurs, analystes	Un service	Data scientists	Tous
Outils BI (Power BI)	Excellent	Excellent	Médiocre	Bon
Coût et complexité	Moyens	Faibles	Stockage faible, compétences élevées	Élevés
Maturité	Très forte	Très forte	Forte	En cours

---

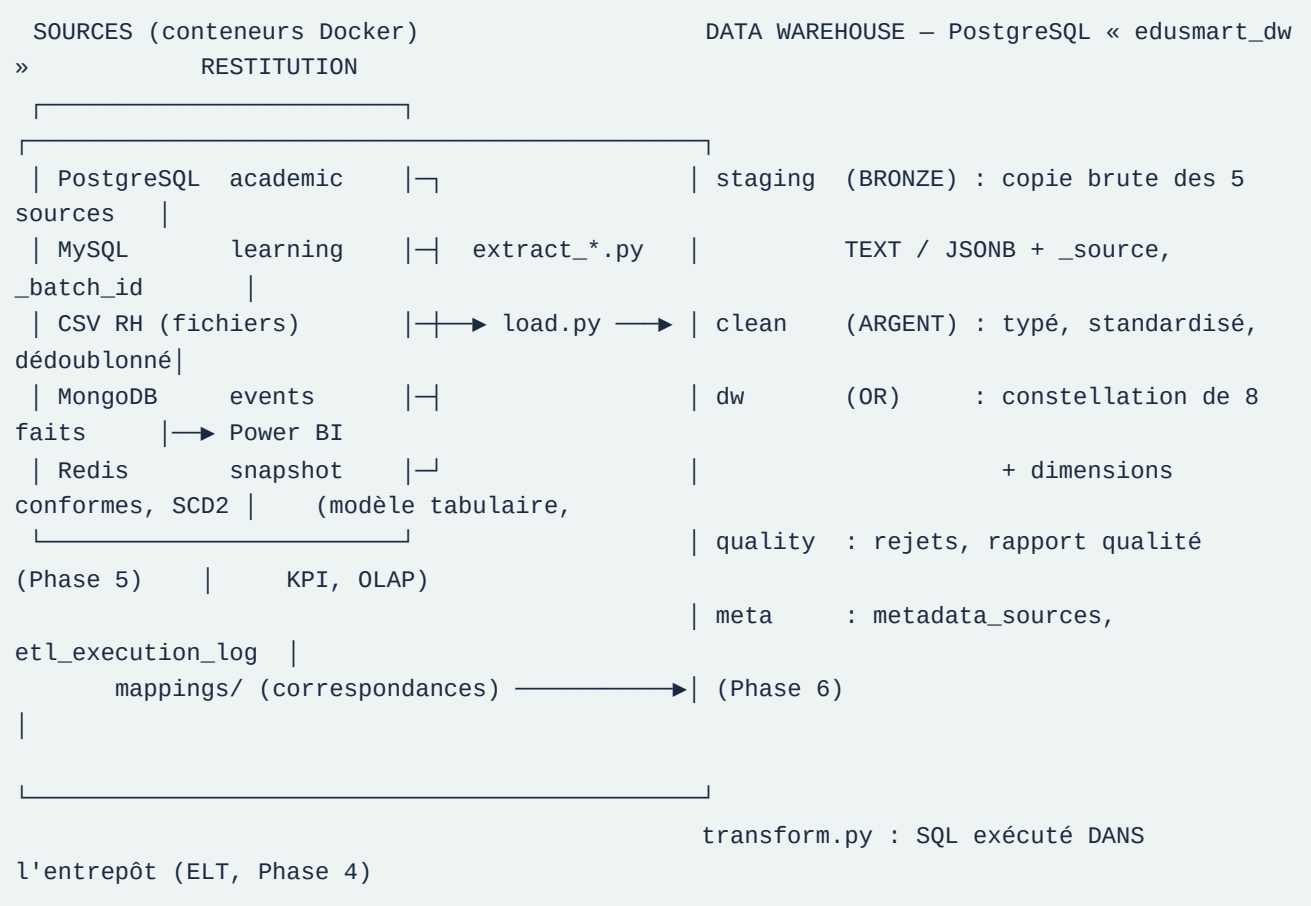
6. Cas pratique : quelle architecture pour EduSmart ?

6.1 Critères de choix, mesurés sur le volet A

Critère	Constat EduSmart	Conséquence
Volume	~800 000 enregistrements (799 037), quelques centaines de Mo	Pas de Big Data : un SGBD relationnel suffit largement
Nature des données	4 sources structurées (PostgreSQL, MySQL, CSV) + 1 semi-structurée (JSON MongoDB) + 1 clé-valeur temporaire (Redis). **Aucune donnée non structurée** (ni image, ni vidéo, ni texte libre)	Le stockage JSONB de PostgreSQL suffit pour MongoDB
Besoin principal	Pilotage de direction : KPI, historique, Power BI (Phases 10 à 14)	Besoin typique d'un **entrepôt**
Qualité	159 946 anomalies réparties sur 69 types	Il faut des **couches** (brut → nettoyé) et un contrôle qualité traçable (Phases 5 et 6)
Historique	Déménagements des étudiants (Phase 9) ; Redis ne garde rien	Il faut un **SCD 2** dans des dimensions : fonction d'entrepôt
Temps réel	Redis n'est qu'un **snapshot** ; aucun besoin de décision à la seconde	Chargement par lots (quotidien) suffisant
Machine learning	Aucun besoin exprimé	Aucun argument pour un lac ou un lakehouse
Équipe et moyens	Une personne, un poste Windows, Docker, sans cloud	Pas de cluster Spark ni de stockage objet
Confidentialité	Salaires, téléphones, adresses IP	Vues ou marts par domaine, droits différenciés

6.2 Proposition : un Data Warehouse PostgreSQL en couches, avec des data marts dépendants

(Décision prise à l'Étape 2 et en L0 : PostgreSQL pour le DW, conteneur `pg_dw` distinct des sources.)



Les **data marts** sont des **vues** ou des sous-ensembles de la constellation, *dépendants* de l'entrepôt :

Data mart	Faits	Utilisateurs	Contenu confidentiel
Finance	paiements, inscriptions	Direction financière, DG	—
Pédagogie	notes, quiz, connexions, progression	Direction des études	—
RH	salaires, absences	RH, DG uniquement	**Salaires**

6.3 Justification

1. **Le besoin est un pilotage de direction sur des données structurées.** C'est le domaine d'excellence du Data Warehouse (point 1).
2. **Le volume est modeste.** Un lac ou un lakehouse apporterait complexité et coût sans bénéfice.
3. **Le seul format non relationnel (JSON MongoDB) est géré nativement par PostgreSQL** (`JSONB`). Le schéma flexible est conservé en couche brute, puis normalisé.
4. **On reprend la meilleure idée du Lakehouse**, l'organisation en couches bronze / argent / or, **sans sa technologie**. Les données brutes restent disponibles, ce qui permet de rejouer les transformations et de prouver la qualité (Phases 5, 6 et 15).
5. **Les data marts dépendants** évitent les silos et répondent au besoin de confidentialité (salaires).
6. **La cohérence technique** : même SGBD que la Source 1, SQL standard, connecteur Power BI natif, Docker déjà opérationnel.
7. **Une trajectoire d'évolution est possible.** Si EduSmart ajoutait un jour des vidéos de cours, des traces d'apprentissage massives ou du machine learning (prédiction des abandons), les couches bronze et argent pourraient migrer vers un **lakehouse** (Parquet + Iceberg) sans remettre en cause le modèle « or ».

6.4 Ce que cette architecture n'est pas

Par honnêteté, et c'est un point de soutenance : il ne s'agit **pas** d'un vrai Data Lakehouse. Il n'y a ni stockage objet, ni format de table ouvert, ni moteur distribué. Il s'agit d'un **Data Warehouse** qui emprunte au Lakehouse son **organisation en médaillon**. Ce choix est cohérent avec le volume et les moyens d'EduSmart.

Architecture	Retenue ?	Motif
Data Warehouse	✅ Cœur de la solution	Pilotage, historique, qualité, Power BI
Data Marts dépendants	✅ Sous forme de vues par domaine	Simplicité, confidentialité RH
Data Lake	❌	Volume faible, aucune donnée non structurée, risque de marécage
Data Lakehouse	⚠️ Organisation seulement	Couches bronze / argent / or reprises ; technologie non justifiée

Références

- PDF « BI Recherche P8 », Phase 3 ; décisions validées à l'Étape 2 (architecture cible, schémas du DW).
- W. H. Inmon, *Building the Data Warehouse* (1992).
- R. Kimball et M. Ross, *The Data Warehouse Toolkit* (3e édition, 2013).
- J. Dixon, billet « Pentaho, Hadoop, and Data Lakes » (2010) : origine du terme *data lake*.
- M. Armbrust, A. Ghodsi, R. Xin, M. Zaharia, *Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics*, CIDR 2021.

Phase 4 — ETL ou ELT ?

EduSmart Decision Platform · Lot L3 · Étape 2 du module BI

> **Demande du PDF :** répondre à 4 questions de recherche, puis préparer le TP (7 scripts : `extract_postgres.py`, `extract_mysql.py`, `extract_mongodb.py`, `extract_redis.py`, `extract_csv.py`, `transform.py`, `load.py`). Le PDF précise : *« Nous déciderons ensemble lequel faire »*.
>
> **Décision prise : ELT** (Étape 1, travail en solo). Ce document la justifie et **conçoit** le pipeline. Le code viendra au lot L4.

---

1. Qu'est-ce qu'un ETL ?

ETL (*Extract – Transform – Load*) désigne un processus d'intégration en trois étapes **dans cet ordre** :

1. **Extract** : lire les données dans les sources ;
2. **Transform** : les nettoyer, les convertir, les rapprocher et les agréger **dans un moteur intermédiaire** (serveur ETL, script Python, outil comme Talend ou SSIS) ;
3. **Load** : charger dans l'entrepôt des données **déjà propres et au format cible**.

```
Sources ──Extract──▶ [ Moteur ETL : nettoyage, conversion, rapprochement ] ──Load──▶ Data Warehouse (données finales)
```

La transformation a lieu **avant** l'entrepôt : l'entrepôt ne voit jamais la donnée brute.

2. Qu'est-ce qu'un ELT ?

ELT (*Extract – Load – Transform*) inverse les deux dernières étapes :

1. **Extract** : lire les données dans les sources ;
2. **Load** : les charger **telles quelles** dans une zone brute (*staging*) de l'entrepôt ;
3. **Transform** : les transformer **à l'intérieur de l'entrepôt**, avec son propre moteur (SQL), de couche en couche.

```
Sources ──Extract──▶ ──Load──▶ Data Warehouse [ brut ──SQL──▶ nettoyé ──SQL──▶ modèle final ]
```

L'ELT s'est généralisé avec les entrepôts puissants et bon marché (entrepôts cloud, PostgreSQL moderne) et des outils comme dbt.

3. Quelles différences ?

Critère	ETL	ELT
Lieu de la transformation	Moteur intermédiaire, hors entrepôt	**Dans** l'entrepôt (SQL)
Données brutes dans l'entrepôt	Non	**Oui** (zone *staging*)
Rejouer une transformation	Il faut réextraire les sources	On **relance le SQL** sur le brut déjà chargé

Critère	ETL	ELT
Traçabilité, audit	Le brut est perdu, sauf archivage séparé	Brut conservé : on peut **prouver** chaque correction
Puissance nécessaire	Dans le moteur ETL	Dans l'entrepôt
Délai de disponibilité	Données finales seulement	Brut disponible tout de suite, raffiné ensuite
Données personnelles	Peuvent être **masquées avant** chargement	Arrivent **en clair** dans le *staging* : à protéger
Espace de stockage	Faible (données finales)	Plus élevé (brut + nettoyé + final)
Langage des transformations	Python, Java, outil graphique	Principalement **SQL**
Schéma cible	Doit être fixé avant	Le brut peut être chargé sans schéma final

4. Dans quels cas choisir l'un ou l'autre ?

Choisir l'ETL quand :

- des données sensibles doivent être **masquées ou filtrées avant** d'entrer dans l'entrepôt (conformité) ;
- l'entrepôt cible a une **puissance de calcul limitée** ou coûteuse ;
- les transformations sont **très complexes** et mieux exprimées en code procédural qu'en SQL ;
- l'organisation dispose déjà d'un **outil ETL** et des compétences associées ;
- on veut limiter le stockage (pas de copie brute).

Choisir l'ELT quand :

- l'entrepôt est **puissant** et sait transformer en SQL ;
- on veut **garder le brut** pour l'audit, la reprise et l'amélioration des règles ;
- les sources sont **hétérogènes** ou ont des **schémas variables** : on charge d'abord, on interprète ensuite ;
- les règles de transformation vont **évoluer** (les définitions métier de la Phase 2 ne sont pas encore validées) ;
- l'équipe maîtrise bien le **SQL**.

En pratique, beaucoup de pipelines sont **hybrides**, ce qu'on appelle **EtLT** : une petite transformation *technique* au chargement (décoder un encodage, aplatir un document), puis les transformations *métier* dans l'entrepôt.

---

5. La décision pour EduSmart : ELT

5.1 Arguments retenus

Argument	Constat EduSmart
Traçabilité et contrôle qualité (Phases 5, 6, 15)	Le PDF demande de compter les lignes extraites, **rejetées**, les doublons et les **corrections**. Il faut donc garder le brut dans l'entrepôt pour prouver chaque correction : les 159 946 anomalies doivent pouvoir être retrouvées **avant** et **après** traitement
Des règles métier encore ouvertes (Phase 2)	Faut-il exclure ou corriger les 1 650 paiements négatifs au statut VALIDE (sur 1 700 paiements négatifs, A14) ? Quelle définition de la réussite ? En ELT, changer de règle revient à **relancer le SQL**, sans réextraire
Sources hétérogènes, schéma flexible	MongoDB : documents aux champs variables et horodatages de 3 types. Ils se chargent tels quels en `JSONB` et s'interprètent ensuite en SQL
Sources volatiles	Redis change à chaque instant : il faut **figer le snapshot** en *staging* dès l'extraction

Argument	Constat EduSmart
Moteur disponible	PostgreSQL 15 : SQL analytique, `JSONB`, expressions régulières, fonctions
Architecture en couches (Phase 3)	Les couches bronze / argent / or sont la mise en œuvre naturelle de l'ELT

5.2 Une nuance à la justification initiale

La justification initiale invoquait aussi « *les volumes MongoDB/Redis importants* » et « *un contexte Big Data / Data Lakehouse* ». Les mesures du volet A **nuancent ce point** :

- MongoDB compte 297 601 documents (16 Mo compressés) ;
- Redis compte 4 608 clés ;
- l'ensemble représente environ 800 000 enregistrements.

Ce n'est pas du Big Data, et l'architecture n'est pas un vrai Lakehouse (Phase 3, § 6.4). **La décision ELT reste la bonne**, mais pour les raisons du § 5.1 (traçabilité, hétérogénéité, règles évolutives), **pas pour une raison de volume**. C'est plus solide à défendre en soutenance.

5.3 Contrepartie à gérer : les données personnelles en *staging*

En ELT, les téléphones, adresses, adresses IP et **salaires** arrivent **en clair** dans le schéma `staging`.

Mesures prévues :

- droits d'accès restreints aux schémas `staging` et `clean` : Power BI ne lit **que** le schéma `dw` (et les vues des data marts, Phase 3 § 6.2) ;
- aucune donnée personnelle superflue dans les dimensions (pas d'adresse IP, pas de téléphone) ;
- purge possible des lots anciens de *staging*.

5.4 Forme retenue : EtLT

Le « t » minuscule ne désigne que des **conversions techniques, sans règle métier** :

Au chargement (technique, en Python)	Dans l'entrepôt (métier, en SQL)
Décoder l'encodage déclaré (ISO-8859-1 → UTF-8)	Standardiser les villes, modes de paiement, catégories
Lire le séparateur `;` ou `,`	Lire les 3 formats de date
Sérialiser un document MongoDB en `JSONB` sans perdre le type (date, texte, nombre)	Dédoublonner, rattacher, rejeter
Figer un snapshot Redis (clé, type, valeur, TTL)	Rapprocher les identifiants (`mapping_*`)
Ajouter les colonnes techniques (`_batch_id`, `_source`…)	Construire les dimensions et les faits, SCD2

Aucune valeur n'est corrigée avant d'entrer dans l'entrepôt. Toute correction est faite, et donc tracée, en SQL.

---

6. Conception du pipeline (préparation du lot L4)

6.1 Enchaînement

```
run_pipeline.py  (un lot = un batch_id)
 │
 ├─ 1. extract_postgres.py ─┐
 ├─ 1. extract_mysql.py    ─┤   lisent les sources, n'y écrivent JAMAIS
 ├─ 1. extract_csv.py      ─┼─► data/landing/<batch_id>/<source>/…   (fichiers bruts du
lot)
 ├─ 1. extract_mongodb.py  ─┤
 ├─ 1. extract_redis.py    ─┘
 │
 ├─ 2. load.py        ─► edusmart_dw.staging.*   (COPY, tout en TEXT / JSONB + colonnes
techniques)
 │
 ├─ 3. transform.py   ─► SQL : staging ─► clean ─► dw     (+ quality.* : rejets et
rapport)
 │
 └─ à chaque étape : meta.etl_execution_log (source, date, durée, lignes, erreurs,
statut)
```

Pourquoi une zone d'atterrissage (*landing*) sur disque entre l'extraction et le chargement ? (Réalisé en L4 : même format CSV pour les 17 objets, y compris MongoDB et Redis, qui y placent leur JSON dans une colonne. Le chargement se réduit donc à un `COPY`.)

- l'extraction et le chargement se **testent séparément** (Phase 15 : « toutes les lignes ont-elles été extraites ? chargées ? ») ;
- en cas d'échec du chargement, on **recharge sans réinterroger** les sources ;
- le lot est **archivé**, ce qui est utile pour l'audit.

6.2 Rôle de chaque script

Script	Lit	Produit	Particularités
`extract_postgres.py`	5 tables de `edusmart_academic`	5 fichiers CSV	`COPY … TO STDOUT` : rapide et fidèle
`extract_mysql.py`	6 tables de `edusmart_learning`	6 fichiers CSV	Lecture par lots (300 000 notes) ; le NULL reste un NULL
`extract_csv.py`	4 fichiers RH	4 fichiers UTF-8	Encodage et séparateur **déclarés** (`SCHEMAS`) ; contrôle de l'en-tête ; **aucune** conversion de valeur
`extract_mongodb.py`	Collection `events`	1 fichier CSV (le document complet en JSON étendu dans une colonne)	Un horodatage texte reste texte, un nombre reste nombre
`extract_redis.py`	Toutes les clés (SCAN)	1 fichier CSV (clé, type, valeur JSON, TTL)	Le snapshot est figé à l'instant du lot
`load.py`	Les fichiers du lot	Tables `staging.*`	Idempotent (le lot est remplacé s'il est rechargé) ; compte les lignes
`transform.py`	`staging.*` + `mappings/`	`clean.*`, `dw.*`, `quality.*`	Scripts SQL ordonnés ; rejets tracés ; rapport qualité
`run_pipeline.py`	—	Un lot complet	Orchestration, `batch_id`, arrêt propre en cas d'erreur

6.3 Couche *staging* (bronze) : principes

- **Une table par table ou collection source**, avec un préfixe par source : `stg_pg_paiements`, `stg_mysql_notes`, `stg_csv_salaires`, `stg_mongo_events`, `stg_redis_keys`.
- **Toutes les colonnes en `TEXT`** : un montant négatif, une date `12/09/2026` ou un sexe `Garçon` sont chargés **sans erreur**, puisque rien n'est encore interprété.
- **MongoDB** : le document entier est stocké en `JSONB`, ainsi que `event_id` pour l'indexation.
- **Redis** : une ligne par clé (`cle`, `type`, `valeur JSONB`, `ttl`).
- **Colonnes techniques** sur chaque ligne :
  - `_batch_id` ;
  - `_source` ;
  - `_extracted_at` ;
  - `_row_number` (position dans l'extraction).

6.4 Pièges d'intégration identifiés au volet A

C'est l'apport principal du volet A : ces pièges sont **connus avant d'écrire la première ligne d'ETL**.

Source	Piège	Traitement prévu
Toutes	Identifiants incompatibles (`id_etudiant` ≠ `student_code`)	Rapprochement par `mapping_etudiants.csv` (9 000 paires) ; les 1 500 non rapprochés sont **conservés et signalés**
MySQL, MongoDB, Redis	`student_code` mal formés (`lms-000154`, `LMS-154`)	Normalisation, puis **contrôle** dans le référentiel des comptes LMS
MongoDB, Redis	Codes `COURSE-n` et `QUIZ-n` sans colonne MySQL correspondante	Rapprochement par `mapping_courses.csv` ; les **89 codes** absents sont signalés
MySQL	Collation insensible à la casse : `GROUP BY` fusionne `Data` et `DATA`	Extraction de la valeur **exacte** ; standardisation dans l'entrepôt (PostgreSQL est sensible à la casse)
MySQL	`NULL` écrit `\N` dans les fichiers	Gestion explicite dans l'extraction
CSV RH	ISO-8859-1 et `;` pour salaires et absences	Encodage et séparateur déclarés (`SCHEMAS`), jamais devinés
CSV RH	3 formats de date ; `03-04-2024` ambigu	Convention : `/` signifie JJ/MM/AAAA, `-` avec l'année en fin signifie MM-JJ-AAAA (`parse_date` du volet A, à traduire en SQL)
CSV RH	Mois en toutes lettres, parfois mal écrits (`Fevrier`, `03`, `Sept.`)	Table de correspondance des mois
MongoDB	Horodatage de 3 types (date, texte, nombre)	Types conservés en `JSONB` ; conversion en SQL selon le type
MongoDB	Schéma flexible (un LOGIN sans `quiz_code` est **normal**)	Ne pas confondre champ absent par conception et anomalie D02
MongoDB, Redis	`device` = modèle (MongoDB) ou plateforme (Redis)	Deux attributs distincts : `modele_appareil` et `plateforme`
MySQL, MongoDB	Durées en minutes et en secondes	Conversion en **secondes** partout
Redis	Données temporaires, TTL	Extraction juste après `insert_data` ; instant d'extraction enregistré
PostgreSQL, MongoDB	Paiements présents deux fois	PostgreSQL = référence du CA ; MongoDB = rapprochement seulement

6.5 Critères de validation du lot L4 (porte G2, rappel de l'Étape 2)

- Pour chaque source : **lignes extraites = lignes en *staging*** (compte exact, par table).
- **Une ligne `meta.etl_execution_log` par source et par exécution** (source, date, durée, lignes, erreurs, statut).
- **Idempotence** : relancer le même lot ne duplique rien.
- **Aucune modification** des sources, et aucune valeur corrigée avant le *staging*.

Synthèse

Question	Réponse courte
ETL ?	Transformer **avant** de charger, dans un moteur intermédiaire
ELT ?	Charger **brut**, puis transformer **dans** l'entrepôt
Différence clé	L'endroit de la transformation, donc la **conservation du brut**
Pour EduSmart	**ELT (forme EtLT)**, pour la traçabilité, l'hétérogénéité et des règles métier encore ouvertes, et non pour le volume
Point de vigilance	Données personnelles en clair dans le *staging* : accès restreint

Références

- PDF « BI Recherche P8 », Phase 4 (questions 1 à 4 et TP) ; Phases 5, 6 et 15 (qualité, métadonnées, tests).
- Décisions validées : Étape 1 (ELT), Étape 2 (architecture, lots L4 et L5, porte G2).
- R. Kimball et J. Caserta, *The Data Warehouse ETL Toolkit* (2004).
- Pièges d'intégration : README des 5 sources du volet A (`sources/s*/README.md`).

Phase 5 — Contrôle qualité des données

EduSmart Decision Platform · Lot L5 · Étape 3 du module BI

> **Objectif du PDF :** comprendre qu'un ETL ne consiste pas seulement à déplacer des données.
>
> **TP :** construire un rapport qualité indiquant le nombre de lignes extraites, les lignes rejetées, les doublons, les valeurs manquantes, les incohérences détectées et les corrections effectuées.
>
> Les chiffres ci-dessous sont ceux du rapport automatique `data/reports/qualite_<lot>.md`, produit à chaque exécution du pipeline.

---

1. Qu'est-ce que la qualité des données ?

La **qualité des données** est leur **aptitude à l'usage** : une donnée est de qualité si elle permet de prendre la bonne décision. Ce n'est donc pas une propriété absolue.

- Un téléphone mal formaté ne gêne pas le calcul du CA.
- Un montant négatif, lui, le fausse.

On la mesure selon plusieurs **dimensions**, et on la rend visible par des **règles** exécutées à chaque chargement.

Dans un ETL, la qualité se traite **dans le pipeline**, et pas après coup dans le tableau de bord. Sinon, chaque rapport corrige à sa façon, et deux rapports finissent par donner deux chiffres différents (Phase 1, point 9).

2. Les cinq dimensions demandées par le PDF

Dimension	Définition	Exemple EduSmart	Règles	Taux de conformité mesuré
Complétude	La donnée attendue est présente	Téléphone manquant, document MongoDB tronqué, connexion sans déconnexion	14	de 86,4 % (MongoDB) à 99,7 % (Redis)
Unicité	Un fait réel n'est enregistré qu'une fois	Inscription saisie deux fois, événement journalisé deux fois, ligne RH exportée deux fois	11	de 95,9 % (MongoDB) à 98,8 % (Redis)
Cohérence	Les données sont conformes entre elles et aux référentiels	`DAKAR` et `Dakar`, 19 écritures d'un mode de paiement, paiement sans inscription	39	de 88,8 % (MongoDB) à 98,8 % (MySQL)
Exactitude	La valeur est correcte et plausible	Montant négatif, progression à 127 %, score au-dessus du maximum, date au mauvais format	25	de 91,7 % (MongoDB) à 97,7 % (Redis)
Fraîcheur	La donnée est assez récente pour l'usage	MySQL et MongoDB à jour au 15/09/2026 ; derniers paiements PostgreSQL en mai	mesure par source	voir le § 4

Taux de conformité = 1 − lignes en défaut / lignes contrôlées, pour chaque source (tableau complet dans le rapport, § 3).

Deux remarques de méthode :

- **Une anomalie peut relever de plusieurs dimensions** selon l'angle d'analyse. Une référence de paiement partagée est un défaut d'**unicité** ; un paiement orphelin est un défaut de **cohérence** (intégrité référentielle). Chaque règle est rattachée à **une seule** dimension, documentée dans le catalogue.
- **Certaines anomalies échappent à tout schéma.** 3 des 11 anomalies MongoDB (villes mal écrites, doublons, adresses IP invalides) passent le validateur `$jsonSchema` (L2-d). Seules des règles **métier** les détectent.

3. Méthode appliquée

3.1 Trois actions, décidées règle par règle

Action	Principe	Nombre de règles	Anomalies traitées
CORRIGÉ	La bonne valeur se déduit **sans ambiguïté** (référentiel, format, recalcul)	30	55 853
REJETÉ	La ligne est inutilisable ou en double : écartée de la couche clean et **conservée intégralement** dans `quality.rejets`	14	25 932
SIGNALÉ	La vraie valeur est **inconnaissable** : la ligne est gardée et marquée (colonne `_anomalies`), la valeur invalide est neutralisée à NULL	45	78 161

Principe : on ne fabrique jamais une valeur. Une progression de 127 % peut provenir d'une vraie progression de 27 % comme de 100 %. La plafonner à 100 reviendrait à **inventer** une donnée : on la **signale** et on la neutralise.

À l'inverse, une durée de connexion négative se **recalcule** exactement à partir des heures de connexion et de déconnexion : on la **corrige**.

3.2 Des corrections fondées sur d'autres données

Plusieurs corrections exploitent la redondance entre les sources ou à l'intérieur d'une même source :

Correction	Fondement	Résultat
Événement MongoDB sans `student_code`	Les autres événements de **la même session**	8 606 sur 8 606 retrouvés
Session Redis sans étudiant	La même session dans **MongoDB**	10 sur 10 retrouvées
Compteurs Redis faux	Recalcul à partir des sessions et des événements nettoyés	241 connectés (et non 737), 43 vidéos (et non 88) : **exactement** les valeurs réelles
Salaire net négatif	Formule `base + primes − retenues`	151 corrigés
Durée de connexion négative	Heure de déconnexion − heure de connexion	2 453 corrigées

3.3 Catalogue et traçabilité

- **89 règles** dans `pipeline/qualite_regles.py`, chargées dans `quality.regles`. Chaque règle précise sa dimension, son action et les **anomalies du volet A qu'elle couvre**.
- **Une ligne `quality.constats` par constat** : règle, ligne source, colonne, valeur **avant**, valeur **après**, action. Chaque correction est donc **réversible et justifiable**.
- Les **référentiels** (villes, synonymes) ont été construits par **profilage** des valeurs distinctes du staging. Une valeur absente de ces listes n'est **pas devinée** : une règle « … inconnu(e) » la signale.

- **Des règles d'intégration** s'ajoutent aux anomalies du volet A :
  - 1 000 étudiants sans compte LMS ;
  - 500 comptes LMS sans inscription ;
  - 9 885 événements portant un code de contenu non résoluble (les 5 % absents de `mapping_courses.csv`).

4. Le rapport qualité (TP)

Lot `B20260927T100618`, 5 sources :

Indicateur exigé par le PDF	Total
Lignes extraites	797 378
Lignes rejetées	25 795
Lignes en couche clean	772 432
Doublons	24 570
Valeurs manquantes	44 322
Incohérences détectées	103 000
Corrections effectuées	55 853

Le rapport détaille ces indicateurs **pour chacune des 21 tables**, et le nombre de constats **pour chacune des 89 règles**.

Fraîcheur, rapportée à la date de référence de la simulation (15/09/2026, C20) :

Source	Dernière donnée	Interprétation
MySQL, MongoDB	15/09/2026 au soir	À jour
CSV RH	28/08/2026	Dernière absence avant la date de référence ; salaires versés jusqu'en août (C20)
PostgreSQL	03/05/2026	Retard **métier** : les tranches de l'année se terminent en avril-mai
Redis	15/09/2026 23:00	L'instant de son snapshot (C24)

La fraîcheur se juge **par rapport à l'usage** : un retard de 135 jours n'est pas un défaut pour les paiements, alors qu'il en serait un pour les connexions.

5. Porte G3 : toutes les anomalies sont-elles traitées ?

La porte G3 confronte **chacune des 159 946 anomalies du journal** du volet A (la vérité terrain, lue **uniquement** par ce contrôle) aux constats de l'entrepôt.

Résultat : 159 946 / 159 946 anomalies traitées, 69 types sur 69 à 100 %.

Chaque règle détecte **exactement** le nombre d'anomalies injectées : aucune anomalie oubliée. Les seuls constats « hors journal » viennent de règles qui signalent volontairement **les deux lignes** d'une paire (référence de paiement partagée, titre de cours dupliqué). Il n'y a donc **aucune fausse détection**.

6. Ce que cette phase démontre

Idée clé	Preuve
Un ETL doit contrôler, pas seulement déplacer	25 795 lignes rejetées et 55 853 corrections, qu'un simple déplacement aurait fait entrer dans les indicateurs
La qualité se mesure	Un taux par dimension et par source, à chaque lot
Corriger n'est pas inventer	45 règles **signalent** au lieu de deviner
Tout est tracé	Valeur avant et après, règle, action : chaque chiffre du DW est justifiable
Les sources se corrigent mutuellement	Étudiants retrouvés par la session, compteurs Redis recalculés à l'unité près

Références

- PDF « BI Recherche P8 », Phase 5 (recherche et TP) ; Phase 15 (tests).
- DAMA International, *DAMA-DMBOK : Data Management Body of Knowledge* (2e éd., 2017) : dimensions de la qualité des données.
- Code : `pipeline/qualite_regles.py`, `pipeline/sql/clean/`, `pipeline/rapport_qualite.py`, `pipeline/verify_g3.py`.

Phase 6 — Métadonnées et traçabilité

EduSmart Decision Platform · Lots L4 et L5 · Étape 3 du module BI

> **Recherche du PDF :** pourquoi conserver la source, la date d'extraction, la version, le nombre de lignes, le statut du traitement ?
>
> **TP :** créer `metadata_sources` et `etl_execution_log`. Chaque exécution doit enregistrer la source, la date, la durée, le nombre de lignes, les erreurs et le statut.

---

1. Qu'est-ce qu'une métadonnée ?

Une **métadonnée** est une **donnée sur les données**. On en distingue trois familles :

Famille	Répond à	Exemple EduSmart
Descriptive (technique)	Qu'est-ce que c'est ? Où est-ce ? Sous quelle forme ?	`salaires.csv`, ISO-8859-1, séparateur `;`, 9 colonnes
Opérationnelle (d'exécution)	Que s'est-il passé, quand, avec quel résultat ?	Lot `B20260927T100618` : 4 125 salaires extraits en 0,02 s, statut SUCCES
De lignage (traçabilité)	D'où vient ce chiffre ? Quelles transformations a-t-il subies ?	Le paiement `PAY-2025-013460` : source PostgreSQL → fichier du lot → staging → clean (mode `OM` corrigé en `Orange Money`)

2. Pourquoi conserver chaque information ?

Information	Pourquoi	Cas vécu dans ce projet
La source	Savoir d'où vient un chiffre ; comparer les sources ; attribuer une anomalie à son système d'origine	Le CA existe dans PostgreSQL **et** dans MongoDB : sans la source, impossible de savoir lequel fait foi
La date d'extraction	Dater l'état des données ; juger leur fraîcheur ; rejouer un lot	Redis change en permanence : seule la date d'extraction dit **quel** instant a été figé
La version	Détecter un changement de structure ; savoir quel code a produit quel résultat	`version_schema` (empreinte des colonnes) : une colonne ajoutée dans une source change l'empreinte et le signale. `version_pipeline` = 1.0.0
Le nombre de lignes	Prouver que rien n'a été perdu entre les étapes (Phase 15)	La porte G2 compare les lignes de la source, du fichier et du staging : 85/85
Le statut	Savoir si le chiffre est fiable ; relancer ce qui a échoué	Une source injoignable est tracée `ECHEC` : on sait qu'il manque des données plutôt que de croire qu'il n'y en a pas

Un cas réel. Pendant le développement de L5, le premier calcul du rapport qualité a échoué (une erreur `IndexError`). Le journal l'a enregistré :

```
etape  | statut | nb_lignes | erreurs
VERIFY | ECHEC  |           | IndexError: tuple index out of range
```

Sans cette trace, un rapport vide aurait pu passer pour « aucune anomalie ».

3. Les tables (TP)

3.1 `meta.metadata_sources` : le catalogue des 17 objets sources

Une ligne par objet, soit 5 tables PostgreSQL, 6 tables MySQL, 4 fichiers CSV, la collection MongoDB et la base Redis.

Colonne	Contenu
`code_source`, `objet`	Clé : `s3_csv` / `salaires`
`technologie`, `emplacement`	`Fichier CSV` / `sources/s3_csv/output/` ; `PostgreSQL 15` / `localhost:5435/edusmart_academic`
`table_staging`, `nb_colonnes`, `encodage`, `separateur`	`staging.stg_csv_salaires`, `9`, `ISO-8859-1`, `;`
`description`	Reprise du PDF
`version_schema`	Empreinte MD5 de la liste des colonnes (`e904f46848c4` pour les salaires)
`derniere_extraction`, **`dernier_batch_id`**, **`derniere_nb_lignes`**, **`dernier_statut`**	État de la **dernière** extraction

La partie descriptive est générée depuis `pipeline/registry.py` : il n'y a **pas de double saisie**, donc le catalogue ne peut pas diverger du code.

3.2 `meta.etl_execution_log` : le journal de chaque étape

Une ligne **par étape, par objet et par exécution**.

Exigence du PDF	Colonne
source	`code_source`, `objet`
date	`date_debut`, `date_fin`
durée	`duree_secondes`
nombre de lignes	`nb_lignes`
erreurs	`nb_erreurs`, `erreurs` (message complet)
statut	`statut` : `EN_COURS` → `SUCCES` ou `ECHEC`
(ajouts)	`batch_id` (le lot), `etape` (EXTRACT, LOAD, TRANSFORM, VERIFY), `version_pipeline`

Chaque ligne est **validée immédiatement**, en autocommit : même si le pipeline s'arrête brutalement, la trace de l'étape en cours reste, au statut `EN_COURS`.

Exemple réel, pour le lot `B20260927T100618` (4 sources extraites, 5 transformées) :

Étape	Statut	Lignes	Objets
EXTRACT	SUCCES	501 436	16
LOAD	SUCCES	501 436	16
TRANSFORM	SUCCES	—	5 sources, à chaque exécution
VERIFY	SUCCES (G2, G3) / ECHEC (1 tentative)	—	—

4. Le lignage de bout en bout

Chaque ligne peut être suivie de la source jusqu'à la couche clean :

```
Source ──► data/landing/<lot>/<source>/<objet>.csv ──► staging.stg_* ──► clean.*
           manifest.json (lignes, empreinte)           _batch_id         _batch_id
                                                       _source           _anomalies
(règles appliquées)
                                                       _extracted_at
                                                       _row_number ──►
quality.rejets.rang (ligne écartée)
                                                                          quality.constats
(avant → après)
```

Pour une ligne de la couche clean, on sait donc :

- de quel **lot** et de quelle **source** elle vient, et **quand** elle a été extraite ;
- quelles **règles** l'ont touchée : colonne `_anomalies`, puis `quality.constats` pour la valeur avant et après ;
- si une ligne source **manque**, pourquoi : `quality.rejets` en conserve le **contenu intégral** et le motif.

Exemple de requête d'audit :

```
-- Qu'est-il arrivé au paiement X ?
SELECT code_regle, colonne, valeur_avant, valeur_apres, action
FROM quality.constats WHERE id_ligne = '<id_paiement>';
```

5. Ce que les métadonnées permettent

Usage	Comment
Auditer un chiffre	Lignage : lot → source → constats
Reprendre après une panne	Statut par objet ; `--steps load verify` recharge le dernier lot sans réextraire
Détecter une évolution de source	`version_schema` change si une colonne change
Mesurer la fraîcheur	`derniere_extraction` et dernière donnée métier (rapport qualité, § 4)
Tester le pipeline (Phase 15)	Lignes par étape ; les portes G2 et G3 s'appuient sur ces tables
Surveiller la performance	`duree_secondes` : l'extraction MongoDB (environ 30 s) est l'étape la plus longue

Références

- PDF « BI Recherche P8 », Phase 6 (recherche et TP) ; Phase 15 (tests).
- R. Kimball et J. Caserta, *The Data Warehouse ETL Toolkit* (2004) : métadonnées de processus et journal d'audit.
- Code : `pipeline/sql/meta/01_meta_tables.sql`, `pipeline/meta.py`, `pipeline/registry.py`.

Phases 7, 8 et 9 — Conception du Data Warehouse

EduSmart Decision Platform · Lot L6 · Étape 4 du module BI

> **Phase 7** : faits, dimensions, mesures, hiérarchies, granularité ; identifier ces éléments pour EduSmart.
>
> **Phase 8** : schéma en étoile, en flocon, constellation ; choisir et justifier.
>
> **Phase 9** : SCD de type 1, 2 et 3 ; traiter le cas « un étudiant change de ville ».
>
> Implémentation : `pipeline/sql/dw/`, `pipeline/load_dw.py`, porte G4 (`pipeline/verify_g4.py`).

Phase 7 — Les concepts et leur application

7.1 Définitions

Concept	Définition	Exemple EduSmart
Fait	Un **événement mesurable** du métier, enregistré au moment où il se produit	Un paiement, une tentative de quiz, une connexion
Dimension	Le **contexte** d'un fait, par lequel on filtre et on regroupe : qui, quoi, quand, où	L'étudiant qui paie, la formation, la date, la région
Mesure	La **valeur numérique** d'un fait, que l'on agrège	Montant, score, durée, pourcentage
Hiérarchie	Des niveaux emboîtés d'une dimension, pour descendre dans le détail ou remonter vers la synthèse	Jour > mois > trimestre > année ; ville > région > pays
Granularité (grain)	Ce que représente **une ligne** de la table de faits : la décision de conception la plus importante	« Une ligne = un paiement » ; « une ligne = un enseignant pour un mois »

Trois natures de mesures, qui ne s'agrègent pas de la même façon :

Nature	Règle	Exemple
Additive	Se somme sur toutes les dimensions	Montant, durée de connexion, salaire net
Semi-additive	Se somme sur certaines dimensions seulement ; ailleurs, on la moyenne	Pourcentage de progression : on le **moyenne**, on ne le somme jamais
Non additive	Ne se somme pas ; on la recalcule	Taux de réussite = somme des validations / somme des tentatives

7.2 Les dimensions d'EduSmart

Le PDF propose 5 dimensions : Temps, Étudiant, Formation, Enseignant, Région. Le modèle en compte **7**, car la dimension « Formation » recouvre en réalité **deux offres qui ne se rejoignent pas** dans les sources (constat du volet A, validé à l'Étape 2) :

Dimension	Grain	Hiérarchies	Source	Évolution
`dim_temps`	Le jour	jour > mois > trimestre > année ; jour > mois > **année académique** (octobre → septembre)	Générée	Fixe

Dimension	Grain	Hiérarchies	Source	Évolution
`dim_etudiant`	Une **version** d'un étudiant	—	PostgreSQL + comptes LMS (MySQL)	**SCD 2** (ville, région) + SCD 1
`dim_formation`	La classe	classe > filière > niveau / département	PostgreSQL	SCD 1
`dim_module`	Le module	module > catégorie	MySQL	SCD 1
`dim_quiz`	Le quiz	quiz > cours > module	MySQL (+ codes de `mapping_courses`)	SCD 1
`dim_enseignant`	L'enseignant	—	CSV RH	SCD 1
`dim_region`	La ville	ville > région > pays	Référentiel géographique	Fixe

`dim_formation` porte l'offre **diplômante** (Licence en IA…), liée aux paiements et aux inscriptions. `dim_module` et `dim_quiz` portent l'offre **pédagogique en ligne** (modules Python, quiz…), liée aux notes et à la progression. Les fondre en une seule dimension inventerait un lien que les données ne contiennent pas.

Clés de substitution et membre « Inconnu ». Chaque dimension a une clé entière propre au DW, indépendante des identifiants sources qui sont incompatibles (UUID, `LMS-…`, `ENS-…`). Elle possède aussi une ligne de clé **−1 « Inconnu »**. Un fait dont la référence est introuvable (un quiz absent de `mapping_courses`, par exemple) pointe vers −1 : **jamais de clé NULL**, et les totaux restent justes.

7.3 Les faits d'EduSmart

Fait	Grain (1 ligne =)	Mesures	Dimensions
`fact_paiements`	un paiement	montant, **montant_ca** (VALIDE et non négatif, définition L3), indicateurs 0/1	temps, étudiant, formation, région
`fact_inscriptions`	une inscription (étudiant × classe)	nombre, réduction, **montant dû**, boursier, abandon, diplômé, tardive	temps, étudiant, formation, région
`fact_notes`	une tentative à un quiz	score, score sur 20, validé, nombre de tentatives	temps, étudiant, quiz, module
`fact_quiz_activite`	un événement de quiz dans l'application mobile	durée, score, succès, nombre d'événements	temps (+ heure), étudiant, quiz, module, région (lieu de l'événement)
`fact_connexions`	une connexion à la plateforme	durée en secondes, nombre de connexions, sans déconnexion	temps (+ heure), étudiant
`fact_progression`	un couple étudiant × module, à sa dernière mise à jour (**instantané**)	pourcentage (semi-additif), terminé	temps, étudiant, module
`fact_salaires`	un enseignant × un mois	base, primes, retenues, **net**	temps (1er du mois), enseignant
`fact_absences`	une absence	durée en heures, justifiée, remplacée, nombre	temps, enseignant

Les mesures demandées par le PDF (montant, note, durée, nombre de connexions, pourcentage, base, primes, retenues, net) sont toutes présentes.

7.4 Matrice de bus : qui partage quoi

Fait	Temps	Étudiant	Formation	Module	Quiz	Enseignant	Région
Paiements	✓	✓	✓				✓
Inscriptions	✓	✓	✓				✓
Notes	✓	✓		✓	✓		
Activité quiz	✓	✓		✓	✓		✓
Connexions	✓	✓					
Progression	✓	✓		✓			
Salaires	✓					✓	
Absences	✓					✓	

`dim_temps` et `dim_etudiant` sont **conformes** : partagées par plusieurs faits, elles permettent de croiser les domaines, par exemple le CA et l'assiduité d'un même étudiant.

Limite assumée : aucun fait ne relie un enseignant à un étudiant. Aucune source ne lie un cours à un enseignant, en dehors du responsable de classe rapproché par son nom (C18). L'« évaluation des enseignants » reste donc hors d'atteinte (gap documenté en L3).

Phase 8 — Étoile, flocon ou constellation ?

8.1 Comparaison

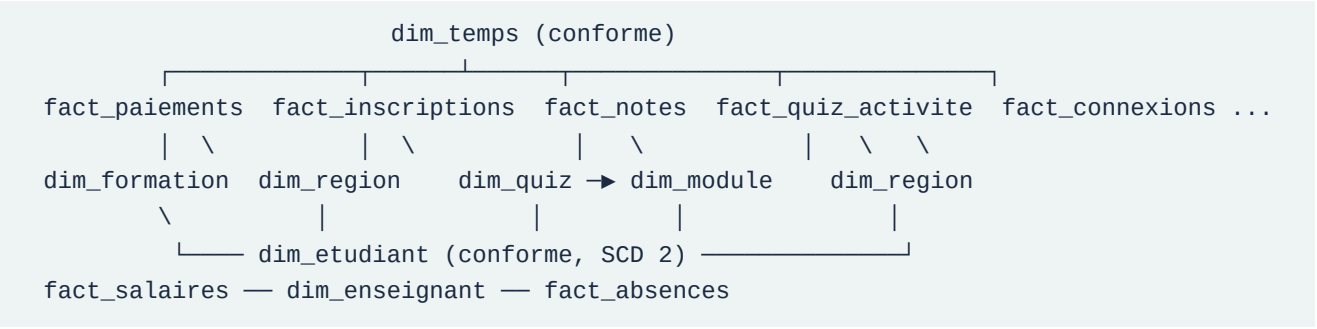
	Étoile	Flocon	Constellation
Principe	1 fait au centre ; dimensions **dénormalisées** (une table chacune)	Dimensions **normalisées** en plusieurs tables (ville → région → pays)	**Plusieurs faits** qui partagent des dimensions conformes
Jointures	Peu (1 par dimension)	Nombreuses	Peu, par fait
Redondance	Oui (la région répétée pour chaque ville)	Minimale	Comme l'étoile
Lisibilité métier	Excellente	Plus faible	Bonne (une étoile par processus)
Performance en analyse	Très bonne	Moins bonne	Très bonne
Mise à jour d'un attribut	Plusieurs lignes à modifier	Une seule ligne	Comme l'étoile
Cas d'usage	Un seul processus métier	Dimensions volumineuses et très hiérarchisées	**Plusieurs processus** à croiser

8.2 Choix : une constellation d'étoiles

EduSmart suit **8 processus métier** (paiements, inscriptions, notes…) qui partagent le temps et l'étudiant. Une étoile unique mélangerait des grains incompatibles : un paiement n'est pas une tentative de quiz. Une étoile par processus **sans dimensions communes** interdirait de les croiser.

La **constellation** donne une étoile par processus, reliées par des dimensions conformes. C'est le choix validé à l'Étape 2.

Une seule branche en flocon, assumée : `dim_quiz` → `dim_module`. Le module d'un quiz est aussi une dimension à part entière, dont ont besoin les notes et la progression. La référencer évite de dupliquer la catégorie et le niveau dans `dim_quiz`. Ailleurs, les hiérarchies sont dénormalisées : la région est une colonne de `dim_region`, et la filière une colonne de `dim_formation`. Power BI (Phase 13) préfère les étoiles.



Phase 9 — Dimensions à évolution lente (SCD)

9.1 Les trois types

Type	Principe	Historique	Coût	Quand l'utiliser
SCD 1	On **écrase** l'ancienne valeur	Aucun	Nul	Correction d'erreur ; attribut sans intérêt historique (téléphone, orthographe du nom)
SCD 2	On **ferme** la ligne courante et on en **ajoute** une nouvelle, avec des dates de validité	**Complet**	Une ligne par changement ; clé durable + clé de version	Attribut dont l'**analyse historique** compte (localisation, statut)
SCD 3	On ajoute une **colonne** « valeur précédente »	Une seule valeur antérieure	Une colonne	Comparer avant et après une réorganisation unique

9.2 Le cas « un étudiant change de ville »

Awa, inscrite en 2024 à Thiès, déménage à Ziguinchor en septembre 2026. Question du DG : « Quel CA avons-nous encaissé dans la région de Thiès en 2025 ? »

Type	Ce que devient la dimension	Réponse	Verdict
SCD 1	Ville = Ziguinchor, sans trace de Thiès	Les paiements de 2025 d'Awa **passent à Ziguinchor** : l'histoire est réécrite	❌ Faux
SCD 3	Ville = Ziguinchor, ville précédente = Thiès	Juste pour **un** déménagement, faux au deuxième	⚠️ Fragile
SCD 2	Version 1 : Thiès (jusqu'au 26/09/2026) ; version 2 : Ziguinchor (depuis le 27/09/2026)	Les paiements de 2025 restent rattachés à la **version 1**, donc à Thiès	✅ Juste

Décision : SCD 2 sur la ville et la région de `dim_etudiant`, et SCD 1 sur ses autres attributs. Une faute d'orthographe corrigée dans un nom est une **correction**, pas une évolution : elle s'applique à toutes les versions.

9.3 Mise en œuvre (`pipeline/sql/dw/10_charger_dimensions.sql`)

Colonne	Rôle
`etudiant_key`	Clé de **version** (clé de substitution), utilisée par les faits
`etudiant_id`	Clé **durable** : `id_etudiant`, ou `LMS:<student_code>` pour un compte seul
`date_debut`, `date_fin`	Période de validité ; la version courante se termine le `9999-12-31`
`est_courant`, `version`	Version en vigueur (index unique partiel : **une seule** par étudiant) ; numéro 1, 2, 3…

À chaque chargement :

1. **SCD 1** : les corrections (nom, sexe, `student_code`…) sont écrasées dans toutes les versions.
2. **SCD 2** : si la ville ou la région diffère, la version courante est **fermée la veille** de la date d'effet, et une nouvelle version s'ouvre à la date d'effet, qui est la **date d'extraction du lot**. Un second changement le même jour met à jour la version du jour, sans créer de version vide.
3. **Nouvel étudiant** : version 1, valable « depuis toujours » (`1900-01-01`), car l'historique antérieur est inconnu.

Les **faits** sont rattachés à la version valable **à leur date** :

```
JOIN dw.dim_etudiant d ON d.etudiant_id = <étudiant> AND <date du fait> BETWEEN
d.date_debut AND d.date_fin
```

9.4 Démonstration : le second chargement (`python -m pipeline.demo_scd2`)

200 étudiants (2 %, graine fixe) déménagent **dans la source PostgreSQL** vers une autre région, puis le pipeline complet est relancé pour cette source.

Contrôle	Résultat
Chaque étudiant déplacé a une version 2 courante	200/200 ✅
Version 1 fermée la veille de la date d'effet	200/200 ✅
Anciennes et nouvelles villes exactes	200/200 ✅
Paiements passés rattachés à l'ancienne version (l'histoire est préservée)	**746/746** ✅
Toujours 10 500 étudiants courants	✅
Portes G2, G3, G4 du second lot	25/25 · 69/69 · 57/57 ✅

Leçon du volet A retrouvée en chemin. La source porte des contraintes `CHECK … NOT VALID` : elles tolèrent les anciennes lignes anomalies, mais **s'appliquent à toute ligne modifiée**. Déplacer un étudiant dont le sexe vaut `Homme` (A01) est refusé par PostgreSQL. La démonstration ne déplace donc que des étudiants sans anomalie bloquante.

Porte G4

Contrôle	Contenu	Résultat
G4.1 Clés étrangères	26 liens fait → dimension, aucune clé orpheline (et de vraies `FOREIGN KEY`)	✅
G4.2 Grain	Aucun doublon sur le grain déclaré des 8 faits	✅
G4.3 Complétude	Chaque fait = sa table clean, ligne pour ligne	✅

Contrôle	Contenu	Résultat
G4.4 Mesures	Montant, CA, masse salariale, durées, scores : DW = clean au centime	✅
G4.5 SCD 2	10 500 étudiants courants (9 000 appariés, 1 000 sans LMS, 500 LMS seuls) ; une version courante chacun ; ni chevauchement, ni trou	✅
G4.6 Inconnus	Aucun fait sans étudiant ni sans date ; 2 268 événements de quiz au code non résoluble (5 % voulus)	✅

57/57 contrôles, au premier chargement comme au second.

Références

- PDF « BI Recherche P8 », Phases 7, 8, 9 (recherche et TP).
- R. Kimball et M. Ross, *The Data Warehouse Toolkit*, 3e éd. (2013) : modélisation dimensionnelle, matrice de bus, dimensions conformes, SCD.
- Code : `pipeline/sql/dw/`, `pipeline/load_dw.py`, `pipeline/verify_g4.py`, `pipeline/demo_scd2.py`.

Phase 10 — Analyse multidimensionnelle (OLAP)

EduSmart Decision Platform · Lot L7 · Étape 5 du module BI

> **Recherche du PDF :** cube OLAP, drill down, roll up, slice, dice, pivot.
>
> **TP :** explorer le cube EduSmart.
>
> Requêtes : `pipeline/sql/olap/01_cube.sql` à `06_pivot.sql`. Résultats complets : `data/reports/olap_<lot>.md` (`python -m pipeline.olap`). Montants en XOF.

---

1. Le cube OLAP

Un **cube OLAP** présente une mesure selon plusieurs **axes** (les dimensions). Chaque **cellule** est la valeur de la mesure pour une combinaison de membres : par exemple, le CA de l'année 2024-2025, dans la région de Thiès, en Master.

Le cube contient aussi **tous les totaux** : par année toutes régions confondues, par région toutes années confondues, le total général… L'analyse consiste alors à **naviguer** dans le cube, sans écrire une nouvelle requête pour chaque question.

OLAP vs OLTP (rappel de la Phase 1). L'OLTP enregistre des transactions, une ligne à la fois. L'OLAP agrège des millions de lignes pour répondre à des questions de pilotage.

Mise en œuvre choisie à l'Étape 2 : ROLAP. Le cube est calculé par SQL sur le schéma en constellation (`GROUP BY CUBE`, `ROLLUP`, `GROUPING SETS`), puis consommé par le modèle tabulaire de Power BI (L8). Pas de serveur MOLAP dédié : le volume (environ 500 000 faits) ne le justifie pas.

Les deux cubes d'EduSmart (matérialisés dans le DW)

Cube	Mesures	Axes	Cellules
`dw.cube_finance`	CA, nombre de paiements	année académique × région × niveau	toutes les combinaisons + 7 niveaux de totaux (`GROUP BY CUBE` = 2^3 regroupements)
`dw.cube_pedagogie`	tentatives, validations, taux de validation, score moyen sur 20	catégorie × niveau du module × année académique	idem

La colonne `niveau_agregation` (fonction `GROUPING`) indique quelles dimensions sont agrégées : 0 pour une cellule détaillée, 7 pour le total général.

Contrôle d'intégrité (test d'intégration) : le total du cube (13 553 901 000 XOF) est égal au KPI CA. Le cube est **additif** : la somme des régions, des niveaux ou des années redonne le total.

2. Les cinq opérations, sur le cube EduSmart

Roll up (forage vers le haut) : du détail vers la synthèse

On **remonte** une hiérarchie, ici `dim_temps` : mois > trimestre > année.

2025	T1	T2	T3	T4	Année
Encaissements (millions XOF)	1 537,7	1 038,2	**2 653,9**	196,6	5 426,3

Au niveau des mois, le détail montre **trois pics** : janvier (909 M), avril (906 M) et août-septembre (2 263 M). Ce sont les trois tranches, la plus forte étant celle de la rentrée. Mars, mai, novembre et décembre sont presque vides.

Enseignement pour la trésorerie : près de la moitié des encaissements de l'année arrive en trois mois.

Piège évité. Une hiérarchie se parcourt sur **une seule** dimension. Croiser l'année **de la formation** avec le trimestre **de la date de paiement** placerait les acomptes de juillet-septembre (avant la rentrée) à la **fin** d'une année qu'ils précèdent. Ma première version de cette requête commettait cette erreur.

Drill down (forage vers le bas) : de la synthèse vers le détail

Le parcours d'un décideur :

Niveau	Question	Réponse
1. Région	Où est le CA ?	**Dakar** : 3 897 M (29 %), loin devant Thiès (1 735 M) et Diourbel (1 247 M)
2. Ville (région de Dakar)	Dakar, c'est uniquement la capitale ?	Non : la ville de Dakar pèse 1 747 M, mais la banlieue (Guédiawaye, Rufisque, Keur Massar, Pikine) en apporte **2 150 M**
3. Filière (ville de Dakar)	Qu'y achète-t-on ?	Des **Masters** : Business Intelligence (189 M), IA (168 M), Cybersécurité (133 M)

Slice (tranche) : on fixe une dimension

Tranche « année académique = 2024-2025 », toutes filières. Les 10 filières au taux d'abandon le plus élevé :

Filière	Inscriptions	Abandon	Recouvrement
Réseaux et Télécommunications (Licence)	341	**9,38 %**	90,74 %
Marketing Digital (Licence)	152	9,21 %	88,28 %
Intelligence Artificielle (Certificat)	144	8,33 %	89,19 %
…			

Les **Licences** et les **Certificats** abandonnent plus que les Masters. C'est une piste pour la Phase 14.

Dice (dé) : on restreint plusieurs dimensions → un sous-cube

Sous-cube « années 2024-2025 et 2025-2026 × régions Dakar et Thiès × niveau Master » :

Année	Région	CA	Paiements	Paiement moyen
2024-2025	Dakar	787 M	1 231	686 384
2024-2025	Thiès	348 M	565	674 753
2025-2026	Dakar	718 M	1 212	659 105
2025-2026	Thiès	327 M	537	680 336

Pivot (rotation) : on fait tourner les axes

La même donnée, les années passées **en colonnes** pour comparer d'un coup d'œil (CA en millions XOF) :

Région	2023-2024	2024-2025	2025-2026
Dakar	846,7	1 455,5	1 594,6
Thiès	351,3	648,4	735,0
Diourbel	266,9	465,9	514,2
…			

Toutes les régions progressent. 2023-2024 est plus faible parce qu'elle compte moins d'inscriptions (3 617, contre 6 191 l'année suivante) : c'est la première année de la période étudiée.

Le **pivot pédagogique** (catégorie × niveau du module) montre un taux de validation **par tentative** d'environ 74 %, homogène (de 71,6 % à 75,8 %). Cette **métrique** diffère du **KPI** de réussite, qui compte par couple étudiant-quiz (93,13 %) ; la Phase 11 explique cette différence.

3. Synthèse

Opération	Geste	SQL	Exemple EduSmart
Cube	Toutes les combinaisons et tous les totaux	`GROUP BY CUBE (a, b, c)`	`dw.cube_finance`
Roll up	Remonter une hiérarchie	`GROUP BY ROLLUP (année, trimestre, mois)`	Encaissements 2025
Drill down	Descendre une hiérarchie	filtre sur le niveau supérieur + regroupement au niveau inférieur	Région → ville → filière
Slice	Fixer une dimension	`WHERE annee_academique = '2024-2025'`	Abandon par filière
Dice	Restreindre plusieurs dimensions	`WHERE annee IN (…) AND region IN (…) AND niveau = …`	Masters à Dakar et Thiès
Pivot	Tourner les axes	`SUM(…) FILTER (WHERE …)`, un par colonne	Régions × années

Dans Power BI (L8), ces gestes deviennent des clics : hiérarchie de dates et de régions (drill down et roll up), segments (slice et dice), matrice (pivot).

Références

- PDF « BI Recherche P8 », Phase 10.
- E. F. Codd, *Providing OLAP to User-Analysts* (1993) : origine du terme OLAP.
- Documentation PostgreSQL : `GROUPING SETS`, `CUBE` et `ROLLUP`.

Phase 11 — KPI et indicateurs de performance

EduSmart Decision Platform · Lot L7 · Étape 5 du module BI

> **Recherche du PDF :** 1. Qu'est-ce qu'un KPI ? 2. Quelle différence entre KPI et métrique ? 3. Comment choisir un bon KPI ?
>
> **TP :** définir les KPI d'EduSmart (chiffre d'affaires, taux de réussite, taux d'abandon, progression moyenne, satisfaction, nombre d'étudiants actifs) et **justifier chaque KPI**.
>
> Calcul : `dw.v_kpi` et `dw.v_kpi_annee` (`pipeline/sql/olap/10_kpi.sql`) · recalcul indépendant et porte G5a : `pipeline/kpi.py` · mesures DAX : `powerbi/mesures_kpi.dax`. Date de référence : 15/09/2026 (C20).

---

1. Qu'est-ce qu'un KPI ?

Un **KPI** (*Key Performance Indicator*, indicateur clé de performance) est une mesure **rattachée à un objectif**, suivie dans le temps, qui déclenche une **décision** quand elle s'écarte de sa cible.

Il répond à la question « sommes-nous en train d'atteindre notre objectif ? ». Il est **peu nombreux** par nature : un tableau de direction en compte 5 à 10.

2. KPI ou métrique ?

	Métrique	KPI
Nature	Toute mesure quantifiable	Une métrique **choisie** parce qu'elle traduit un objectif
Nombre	Des centaines	Quelques-uns
Cible	Non	**Oui**, et un seuil d'alerte
Décideur	Aucun en particulier	Un responsable identifié
Exemple EduSmart	Nombre de tentatives de quiz ; taux de validation **par tentative** (74 %)	Taux de réussite **par couple étudiant-quiz** (93,13 %)

L'exemple de la dernière ligne est tiré du cube pédagogique (Phase 10). Les deux chiffres mesurent la « réussite », mais avec des sens opposés. Le taux par tentative **pénalise** l'étudiant qui échoue deux fois puis réussit, alors que l'objectif pédagogique est justement qu'il finisse par réussir. Seul le second traduit l'objectif : c'est le KPI.

Tout KPI est une métrique ; peu de métriques sont des KPI.

3. Comment choisir un bon KPI ?

Six critères, appliqués à chaque fiche du § 4 :

Critère	Question
Aligné	Traduit-il un objectif du DG (Phase 1) ou un besoin métier (Phase 2) ?

Critère	Question
Actionnable	Si la valeur se dégrade, sait-on **qui** agit et **comment** ?
Défini sans ambiguïté	Deux personnes calculeraient-elles la même valeur ? (définitions validées en L3)
Mesurable	Les données existent-elles, avec une qualité connue (Phase 5) ?
Pourvu d'une cible	Sait-on dire si 90 % est bon ou mauvais ?
Honnête sur ses limites	Ce qu'il ne dit pas est-il écrit ?

Le critère « mesurable » **élimine la satisfaction** (§ 5).

4. Les 8 KPI d'EduSmart

#	KPI	Valeur au 15/09/2026	Cible proposée	Décideur
1	Chiffre d'affaires encaissé	**13,554 Mds XOF**	≥ CA de l'année précédente à date	DG, Finance
2	Taux de recouvrement	**90,10 %**	≥ 90 % en fin d'année	Finance
3	Taux de réussite aux quiz	**93,13 %**	≥ 85 %	Pédagogie
4	Taux d'abandon	**6,24 %**	≤ 5 % ⚠️	DG, Pédagogie
5	Progression moyenne	**65,59 %**	≥ 70 % ⚠️	Pédagogie
6	Étudiants actifs (30 jours)	**3 003** (28,6 % des étudiants)	≥ 30 % des étudiants ⚠️	DG
7	Temps médian de connexion	**1 740 s (29 min)**	≥ 20 min	Pédagogie
8	Nombre réel d'étudiants	**10 500**	suivi	DG

Les cibles sont des propositions, à valider avec la direction : aucune source ne contient d'objectif. Trois KPI sont sous leur cible (⚠️) ; ce seront les points d'attention du Data Storytelling (Phase 14).

Par **année académique de la formation** (`dw.v_kpi_annee`) :

Année	CA	Montant dû	Recouvrement	Inscriptions	Abandon
2023-2024	2 868 M	3 179 M	90,19 %	3 617	6,25 %
2024-2025	5 101 M	5 624 M	90,70 %	6 191	6,33 %
2025-2026	5 585 M	6 240 M	89,51 %	7 383	6,16 %

Le CA est rattaché à l'année **de la formation payée**, et non à la date du paiement. Sinon, les acomptes de juin-septembre 2023 créeraient une année « 2022-2023 » fictive (3 458 paiements). C'est la dimension conforme `dim_formation`, partagée par les paiements et les inscriptions, qui rend ce calcul possible.

Fiches

Chaque fiche donne : définition, formule, sources, fréquence, cible, justification, limites. Le catalogue complet est `pipeline/kpi.py` (`KPIS`).

1. Chiffre d'affaires encaissé — 13,554 Mds XOF

- *Définition* : somme des paiements au statut VALIDE, rattachés à une inscription existante, montants négatifs exclus (définition L3).

- *Formule* : SQL `SUM(montant_ca)` ; DAX `SUM(fact_paiements[montant_ca])`.
- *Sources* : PostgreSQL. *Fréquence* : mensuelle.
- *Justification* : premier indicateur demandé par le DG (Phase 1).
- *Limites* : 1 700 paiements négatifs (A14) exclus ; s'il s'agit d'erreurs de signe, le CA réel est plus élevé, et c'est à trancher avec la finance. Les paiements EN_ATTENTE, ECHOUE et REMBOURSE sont exclus.

2. Taux de recouvrement — 90,10 %

- *Définition* : CA encaissé ÷ montant dû, soit les frais annuels de la classe après réduction.
- *Formule* : SQL `SUM(montant_ca) / SUM(montant_du)` ; DAX `DIVIDE([CA encaissé], [Montant dû])`.
- *Sources* : PostgreSQL. *Fréquence* : mensuelle.
- *Justification* : le CA seul ne dit pas si les étudiants paient ce qu'ils doivent ; le recouvrement mesure les **impayés** (environ 1,5 Md XOF au total).
- *Limites* : frais annuels = coût total ÷ nombre d'années (convention L6). Les 541 réductions neutralisées (A11) sont comptées sans réduction. L'année en cours n'est pas close.

3. Taux de réussite aux quiz — 93,13 %

- *Définition* : couples (étudiant, quiz) validés au moins une fois ÷ couples tentés (définition L3).
- *Formule* : SQL, `AVG` du maximum de `est_valide` par couple ; DAX, `SUMMARIZE` puis `FILTER` (voir le fichier `.dax`).
- *Sources* : MySQL. *Fréquence* : hebdomadaire.
- *Justification* : demandé par le DG ; compter par couple ne pénalise pas celui qui retente.
- *Limites* : c'est la réussite aux quiz en ligne, **pas au diplôme**, qu'aucune source ne contient (gap L3). Sur les données brutes, on mesurait 91,54 % en L3 : le nettoyage a réuni les tentatives d'un même étudiant écrites avec des `student_code` différents (B13) et retiré les doublons (B12).

4. Taux d'abandon — 6,24 %

- *Définition* : inscriptions au statut ABANDON ÷ inscriptions.
- *Formule* : SQL `SUM(est_abandon) / COUNT(*)` ; DAX `DIVIDE(SUM(…[est_abandon]), COUNTROWS(…))`.
- *Sources* : PostgreSQL. *Fréquence* : trimestrielle.
- *Justification* : exemple du PDF ; un abandon est un CA futur perdu et un signal pédagogique.
- *Limites* : la source ne **date** pas l'abandon. Les 360 inscriptions SUSPENDU ne sont pas comptées. Le slice de la Phase 10 montre que les Licences et les Certificats abandonnent davantage.

5. Progression moyenne — 65,59 %

- *Définition* : moyenne des pourcentages de progression par couple (étudiant, module).
- *Formule* : SQL `AVG(pourcentage)` ; DAX `AVERAGE(fact_progression[pourcentage])`.
- *Sources* : MySQL. *Fréquence* : hebdomadaire.
- *Justification* : exemple du PDF ; mesure l'avancement réel dans les contenus.
- *Limites* : mesure **semi-additive** (on la moyenne, on ne la somme jamais). Les 3 180 valeurs hors [0, 100] neutralisées en L5 sont ignorées. C'est un instantané, sans historique.

6. Étudiants actifs (30 jours) — 3 003

- *Définition* : personnes distinctes ayant au moins une connexion, une note ou une activité de quiz entre le 17/08 et le 15/09/2026 (définition L3).
- *Formule* : SQL `COUNT(DISTINCT etudiant_id)` sur les trois faits ; DAX `UNION` des trois faits filtrés, puis `DISTINCT`.

- *Sources* : MySQL, MongoDB. *Fréquence* : quotidienne.
- *Justification* : exemple du PDF ; l'engagement réel, que le nombre d'inscrits ne dit pas.
- *Limites* : les événements MongoDB hors quiz (vidéos, téléchargements) ne sont pas dans le DW. La fenêtre est fixée à la date de référence de la simulation.

7. Temps médian de connexion — 1 740 s (29 min)

- *Définition* : médiane des durées de connexion, en secondes (définition L3).
- *Formule* : SQL `percentile_cont(0.5)` ; DAX `MEDIAN(fact_connexions[duree_secondes])`. Les deux font la moyenne des deux valeurs centrales quand le nombre est pair.
- *Sources* : MySQL. *Fréquence* : hebdomadaire.
- *Justification* : demandé par le DG ; la médiane résiste aux sessions anormalement longues.
- *Limites* : les 1 658 connexions sans déconnexion (B08) sont exclues. Le temps connecté ne mesure pas l'attention.

8. Nombre réel d'étudiants — 10 500

- *Définition* : personnes distinctes, soit les inscrits (PostgreSQL) et les comptes LMS sans inscription (MySQL).
- *Formule* : SQL `COUNT(DISTINCT etudiant_id)` sur les versions courantes ; DAX `DISTINCTCOUNT` filtré.
- *Sources* : PostgreSQL, MySQL. *Fréquence* : mensuelle.
- *Justification* : première question du DG ; la somme naïve des sources donnait **26 476** (L3).
- *Limites* : 1 000 inscrits sans compte LMS et 500 comptes sans inscription ne peuvent pas être rapprochés ; chacun compte pour une personne.

5. La satisfaction : un KPI demandé mais non calculable

Le PDF la cite, et le DG la demande (Phase 1). Pourtant, **aucune des 5 sources** ne contient d'avis, de note ni d'enquête (gap documenté en L3).

Ce qu'il ne faut pas faire	Présenter un indicateur de substitution (taux de réussite, temps de connexion) sous le nom de « satisfaction ». Un étudiant peut réussir ses quiz et être mécontent : **ce serait tromper le décideur**
Recommandation	Collecter une note de 1 à 5 à la fin de chaque module, dans la plateforme pédagogique. Elle deviendrait la mesure d'un nouveau fait `fact_evaluations`, lié aux dimensions étudiant, module et temps, et le KPI serait calculable sans changer le reste du modèle

Il en va de même pour « les enseignants les mieux évalués » : aucune évaluation, et aucun lien entre un cours et un enseignant (L6).

6. Porte G5 : le même KPI par deux chemins

Porte	Comparaison	Statut
G5a (L7)	**SQL sur le DW** (`dw.v_kpi`) = **Python sur la couche clean** (`pipeline/kpi.py`)	✅ **8/8** : montants au centime, effectifs exacts, ratios à 10^{-9} près
G5b (L8)	**DAX dans Power BI** = valeurs de référence (`data/reports/kpi_reference.json`)	À exécuter en L8

G5a compare deux **langages** et deux **couches**, sans code commun. Le Python ne lit pas le DW : il repart de la couche clean, refait les jointures, le rapprochement des étudiants et le calcul des frais annuels. Un écart aurait révélé une

erreur de grain, de jointure ou de rattachement SCD 2. Il n'y en a aucun.

Procédure G5b (L8). Importer les tables `dw.*`, créer les relations, coller les mesures de `powerbi/mesures_kpi.dax`, puis comparer chaque carte, **sans aucun filtre**, à `kpi_reference.json`.

Références

- PDF « BI Recherche P8 », Phase 11 ; Phase 1 (besoins du DG) ; L3 (définitions métier validées).
- D. Parmenter, *Key Performance Indicators*, 4e éd. (2019) : KPI, indicateurs de résultat et de performance.
- Critères SMART (G. T. Doran, 1981) : spécifique, mesurable, atteignable, réaliste, temporellement défini.

Phase 12 — Analyse et visualisation des données

EduSmart Decision Platform · Lot L8 · Étape 6 du module BI

> **TP du PDF :** choisir les visualisations adaptées parmi l'histogramme, le boxplot, le scatterplot, la heatmap et le barplot. Pour chaque graphique : pourquoi ce choix ? pourquoi pas un autre ?
>
> Les 5 graphiques ci-dessous sont **produits depuis le DW** par `python -m scripts.visualisations` (dans `docs/figures/`). Leur transposition dans Power BI est décrite dans `powerbi/guide_powerbi.md` (§ 6).

---

1. Le principe : partir de la question, pas du graphique

Un graphique se choisit d'après **ce que la donnée doit révéler** :

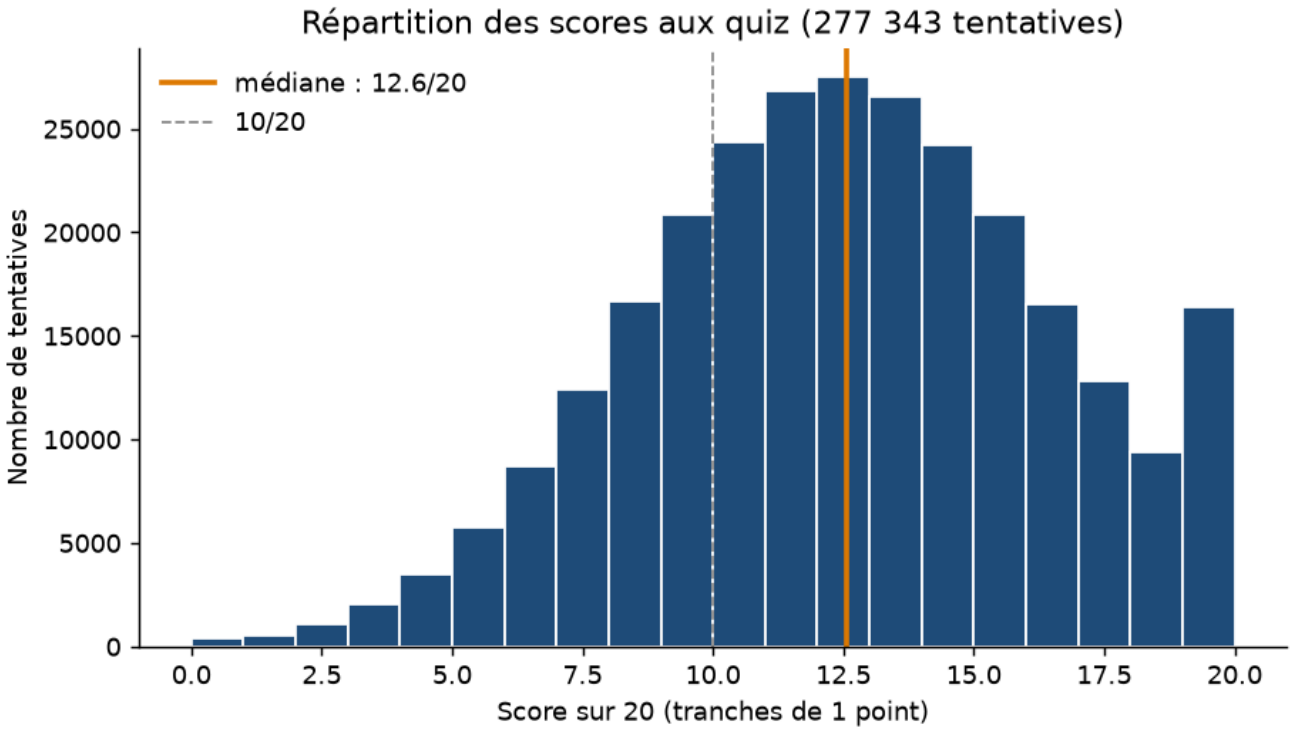
On veut montrer…	Graphique	Nature des données
une **distribution** (forme, centre, dispersion)	**Histogramme**	1 variable quantitative, beaucoup d'observations
des **distributions à comparer** entre groupes	**Boxplot**	1 variable quantitative × 1 variable qualitative
une **relation** entre deux mesures	**Scatterplot**	2 variables quantitatives, une observation par point
une **intensité** selon deux axes	**Heatmap**	2 variables qualitatives (ou discrétisées) × 1 mesure
une **comparaison** entre catégories	**Barplot**	1 variable qualitative × 1 mesure agrégée

Quatre règles s'appliquent à tous :

- un titre qui **énonce la conclusion** (« l'activité se concentre le soir »), et non le contenu (« connexions par heure ») ;
- des barres qui **partent de zéro** ;
- une couleur réservée à ce qui doit attirer l'œil ;
- **aucun** camembert à plus de trois parts, aucun effet 3D.

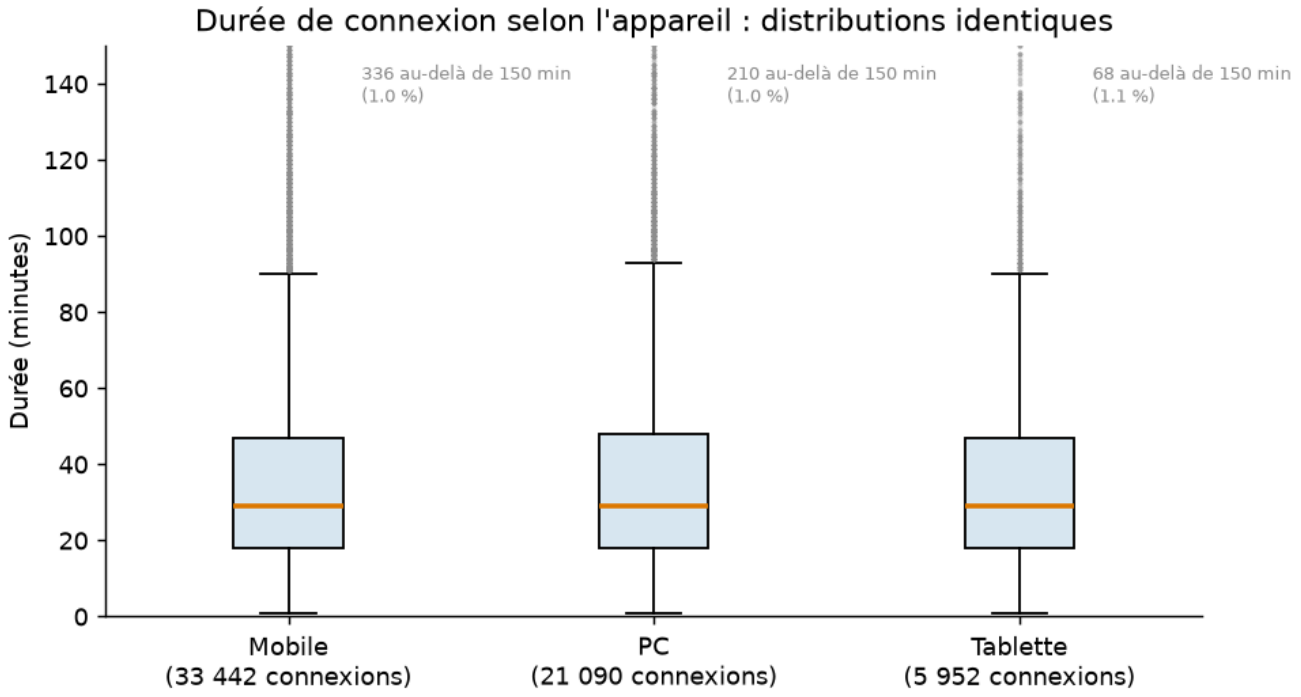
2. Les cinq graphiques d'EduSmart

2.1 Histogramme — Comment se répartissent les scores aux quiz ?



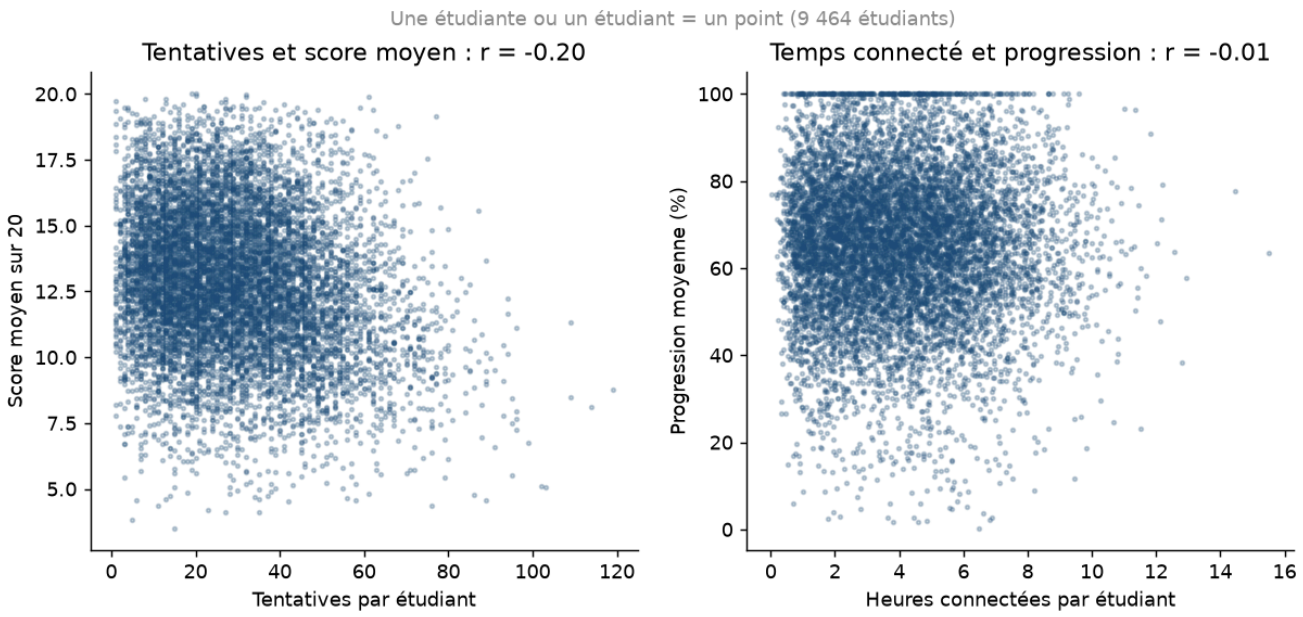
Données	277 343 tentatives notées (`fact_notes.score_sur_20`), tranches de 1 point
Ce qu'il révèle	Une distribution en **cloche**, de médiane **12,6/20** ; **25,9 %** des tentatives sont sous 10/20 ; un **pic à 20/20** (3,6 %, soit 10 111 tentatives)
Pourquoi ce choix	C'est le seul des cinq graphiques qui montre la **forme** d'une distribution. Le pic à 20/20 est un **effet plafond** : une note ne peut pas dépasser le maximum, donc les meilleurs s'y accumulent. En lecture métier, ces quiz ne distinguent plus les meilleurs étudiants. Prudence : une partie de l'effet peut venir de la simulation
Pourquoi pas un autre	Une **moyenne** (un seul nombre) cacherait le pic et la queue sous 10. Un **boxplot** résumerait la distribution en 5 nombres et ne montrerait pas le pic. Un **barplot** traiterait les notes comme des catégories sans ordre
Dans Power BI	Pas de visuel « histogramme » natif : graphique en colonnes sur la colonne `score_sur_20` **compartimentée** (taille 1)

2.2 Boxplot — La durée de connexion dépend-elle de l'appareil ?



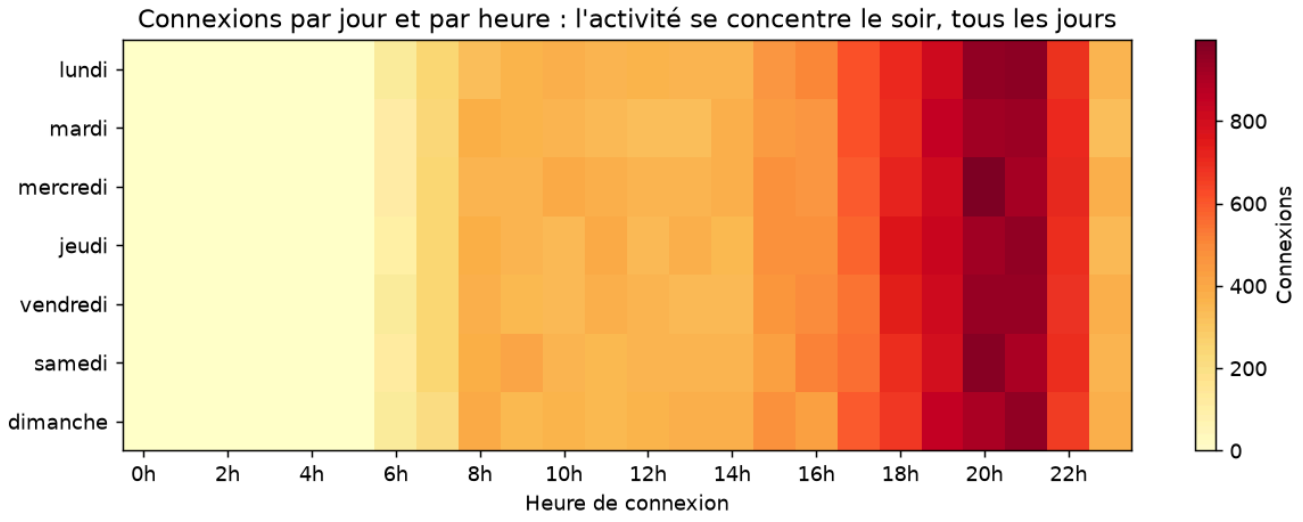
Données	60 484 connexions avec durée (`fact_connexions`), par appareil
Ce qu'il révèle	Des distributions **identiques** : médiane de 29 min et moitié centrale entre 18 et 48 min, sur mobile, PC et tablette. Environ 1 % des connexions dépasse 150 min, avec un maximum à 480 min
Pourquoi ce choix	Il compare **plusieurs distributions côte à côte** : médiane, quartiles, étendue et valeurs extrêmes. Conclure « l'appareil ne change rien » est un résultat à part entière : inutile de financer une application tablette **pour allonger les sessions**
Pourquoi pas un autre	Trois **histogrammes** superposés seraient illisibles ; un **barplot des moyennes** cacherait la dispersion et serait tiré vers le haut par les sessions de 8 h
Lisibilité	La longue traîne écrasait les boîtes : l'axe est limité à 150 min, et les valeurs au-delà sont **comptées à l'écran** plutôt que masquées en silence
Dans Power BI	Pas de visuel natif : visuel certifié « Box and Whisker chart » (AppSource), ou visuel Python reprenant `scripts/visualisations.py`

2.3 Scatterplot — Deux mesures sont-elles liées ?



Données	Un point par étudiant (9 464) ; à gauche, tentatives et score moyen ; à droite, heures connectées et progression moyenne
Ce qu'il révèle	À gauche, une relation **négative faible** (r = −0,20) : ceux qui ont besoin de plus de tentatives ont un score moyen plus bas. À droite, **aucune relation** (r = −0,01) : un nuage sans direction
Pourquoi ce choix	C'est **le** graphique de la relation entre deux variables quantitatives. Il montre la forme, la force, les exceptions, et aussi l'**absence** de relation
Pourquoi pas un autre	Un **coefficient seul** (r = −0,01) ne montre pas s'il y a une relation non linéaire ou des sous-groupes. Une **courbe** relierait des étudiants qui n'ont pas d'ordre entre eux
Enseignement pour la Phase 14	On ne pourra **pas** affirmer que « plus de temps connecté donne une meilleure progression » : les données ne le montrent pas. Le nuage sert à **tester** une relation avant de la raconter. Ces données étant simulées, le générateur a produit ces variables indépendamment
Dans Power BI	Nuage de points natif, `dim_etudiant[etudiant_id]` dans **Valeurs** (un point par étudiant)

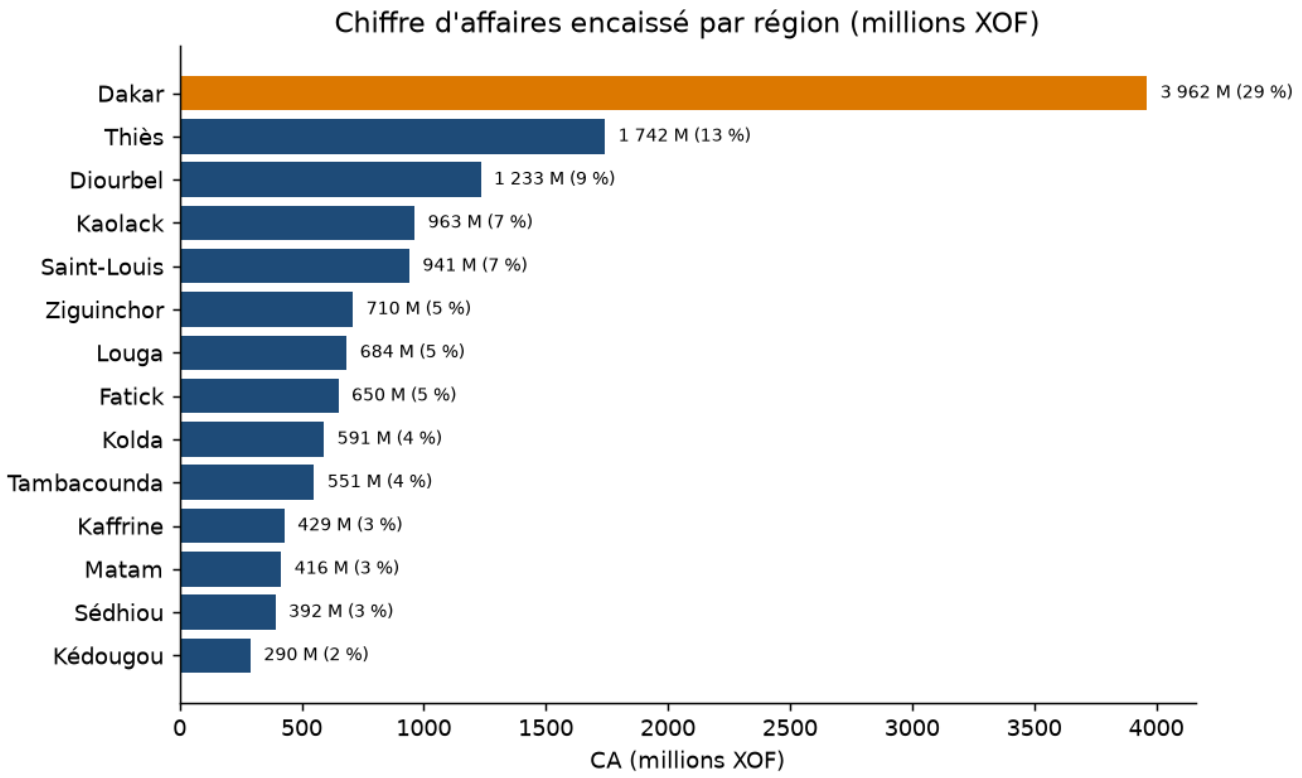
2.4 Heatmap — Quand les étudiants se connectent-ils ?



Données	62 142 connexions (`fact_connexions`), 7 jours × 24 heures = 168 cases

Ce qu'il révèle	Un pic entre **20 h et 22 h, tous les jours**. Environ la moitié des connexions a lieu entre 18 h et minuit, **aucune** entre minuit et 6 h, et il n'y a **pas d'effet du jour de la semaine** (le week-end ressemble à la semaine)
Pourquoi ce choix	Deux axes discrets (jour, heure) et une intensité : la couleur fait lire 168 valeurs d'un coup d'œil. Décision directe : programmer les classes virtuelles et les notifications **le soir**, maintenance **la nuit**
Pourquoi pas un autre	Un **barplot** par heure perdrait le jour (ou il faudrait 7 barplots) ; un **tableau** de 168 nombres ne se lit pas ; 7 **courbes** superposées se chevaucheraient
Dans Power BI	Matrice (jour en lignes, heure en colonnes) avec **mise en forme conditionnelle** de l'arrière-plan (échelle de couleurs)

2.5 Barplot — Quelles régions portent le chiffre d'affaires ?



Données	CA encaissé (`fact_paiements.montant_ca`) par région, en millions de XOF
Ce qu'il révèle	**Dakar : 29 %** du CA, plus du double de Thiès (13 %) ; les régions suivent en pente douce. La couleur signale la région principale
Pourquoi ce choix	Comparer une mesure entre **catégories** : la longueur des barres est ce que l'œil compare le mieux. Barres **horizontales**, pour lire les noms de région, et **triées**
Pourquoi pas un autre	Un **camembert** à 14 parts est illisible : on ne compare pas des angles. Une **carte géographique** est séduisante, mais on y compare mal des intensités de couleur ; elle peut compléter, pas remplacer
Dans Power BI	Graphique à barres groupées, avec une hiérarchie Géographie (région › ville) pour le **drill down** de la Phase 10

3. Au-delà des cinq : les visuels du tableau de bord

Visuel	Usage	Pourquoi
Carte (KPI)	Les 8 KPI	Un nombre, avec une couleur par rapport à la cible

Visuel	Usage	Pourquoi
Courbe	CA par mois (saisonnalité)	L'évolution dans le **temps** : les points sont ordonnés, le trait a un sens
Histogramme groupé	CA et montant dû par année	Deux mesures comparées par catégorie
Carte texte	Satisfaction : « Non mesurée »	Rendre visible un manque de données plutôt que le cacher

Références

- PDF « BI Recherche P8 », Phase 12.
- E. Tufte, *The Visual Display of Quantitative Information* (1983) : rapport données/encre.
- C. Nussbaumer Knaflic, *Storytelling with Data* (2015) : choisir le visuel d'après le message.
- J. Tukey, *Exploratory Data Analysis* (1977) : la boîte à moustaches.

Phase 13 — Power BI

EduSmart Decision Platform · Lot L8 · Étape 6 du module BI

> **PDF :** créer le modèle relationnel, les mesures, les KPI, les segments, les filtres, les visualisations, le tableau de bord interactif.
>
> Mode opératoire : `powerbi/guide_powerbi.md` · mesures : `powerbi/mesures_kpi.dax` · contrôle : `scripts/verifier_g5b.py`.

---

1. Le modèle relationnel

Power BI importe les 15 tables du schéma `dw` (7 dimensions, 8 faits) et reproduit la **constellation** de la Phase 8. Les 26 relations sont de cardinalité **plusieurs à un**, filtrent **de la dimension vers le fait**, et doivent toutes être **actives** (voir l'encadré ci-dessous : l'une d'elles ne l'était pas, corrigée en L10).

Deux adaptations par rapport au DW, et pourquoi :

Dans le DW (L6)	Dans Power BI	Raison
`dim_quiz` → `dim_module` (branche en flocon)	**Supprimée**	Les faits portent déjà `module_key`. Deux chemins vers le module rendraient le filtrage **ambigu**, et Power BI désactiverait arbitrairement l'un des deux. Le modèle Power BI est une constellation d'**étoiles pures**
`dim_etudiant.region_key`	**Relation supprimée** (la colonne reste)	Les faits portent la région **à la date du fait** (SCD 2). C'est elle qui fait foi : le paiement de 2024 reste attribué à la région de 2024
Ligne « Inconnu » (−1) de `dim_temps` (1900)	**Filtrée** dans Power Query	Pour marquer `dim_temps` comme table de dates, les dates doivent être contiguës. Aucun fait n'utilise −1 (porte G4.6)

> **Correctif L10 (21/10/2026) : une relation inactive.** La relation `fact_paiements[region_key] → dim_region[region_key]` existait mais était **inactive** (trait pointillé). Power BI l'ignore alors : un filtre sur une région ne filtrait **pas** les paiements.
>
> | Symptôme | Explication |
> |---|---|
> | Page Vue Direction : 14 barres « CA par région » **toutes égales**, au niveau du CA total | Chaque région recevait le CA de **toutes** les régions |
> | Kaffrine : recouvrement de **2 821 %** | CA total (13,55 Mds) ÷ montant dû de Kaffrine seule (le dénominateur, lui, était bien filtré) |
>
> **Correction :** relation rendue active ; les relations de `fact_inscriptions` et `fact_quiz_activite` vers `dim_region` ont été contrôlées (actives). Après correction, le CA se répartit entre les régions (Dakar en tête, ≈ 29 %, comme dans l'entrepôt ; export du 21/10/2026). Le Data Warehouse n'était pas en cause : les requêtes K1 à K4 donnaient déjà Kaffrine à 89,68 % (14_data_storytelling.md, § 8.5).
>
> **Corrections complémentaires (21/10/2026) :** l'interaction du segment région avec la matrice du recouvrement (page Finance) a été rétablie, la carte « CA encaissé » formatée en milliards, le tableau des paiements négatifs par mode de paiement corrigé.

> **Écart restant, non expliqué :** segments année et niveau vides, la matrice affiche pour Kaffrine un recouvrement de **89,29 %** (86,59 % ; 92,21 % ; 88,06 % par année académique), contre **89,68 %** dans l'entrepôt (requête K1). Les deux calculs ont la même définition (ratio des sommes : `DIVIDE([CA encaissé], [Montant dû])` d'un côté, `SUM(montant_ca) / SUM(montant_du)` de l'autre) : un écart de 0,39 point signifie qu'ils ne portent pas exactement sur la même population. Ni une moyenne de ratios, ni un filtre de segment ne l'expliquent. Prochaine vérification : comparer, pour Kaffrine, `[CA encaissé]` et `[Montant dû]` aux colonnes `ca` et `du` de K1, puis inspecter les filtres de page et de visuel de la page Finance. **La valeur qui fait foi reste celle de l'entrepôt.**
>
> **Leçon :** après la création du modèle, relire **chaque** relation dans la vue Modèle (trait plein = active), et tester au moins une mesure **filtrée** par chaque dimension, pas seulement les totaux.

Pas de filtrage bidirectionnel. Avec 8 faits qui partagent `dim_etudiant`, un filtre remontant d'un fait vers une dimension se propagerait aux 7 autres faits : les résultats dépendraient du visuel où l'on clique.

2. Mesures ou colonnes calculées ?

	Mesure (DAX)	Colonne calculée
Calculée	Au moment de l'affichage, **dans le contexte du filtre**	Au chargement, une fois par ligne
Stockage	Aucun	En mémoire
Usage	Tout ce qui s'**agrège** : taux, sommes, médianes	Ce qui **catégorise** une ligne : tranche de score, libellé

Les 8 KPI sont des mesures. Un taux de recouvrement ne s'additionne pas d'une ligne à l'autre : il se **recalcule** pour chaque sélection (une région, une année, une filière). Une colonne calculée donnerait un taux figé, faux dès qu'on filtre.

Aucune colonne calculée n'est nécessaire : les indicateurs par ligne (`montant_ca`, `est_abandon`, `score_sur_20`, `est_termine`…) ont été calculés **une fois, dans le DW** (L6). Le calcul se fait au plus près des données, et une seule fois.

Les mesures se répartissent en deux familles (`mesures_kpi.dax`) : les **8 KPI** (Phase 11), puis les **mesures d'appui** aux visuels. Ces dernières sont des métriques : impayés, tentatives, heures connectées…

3. Les KPI dans le tableau de bord

- Une **carte** par KPI, en tête de la page « Vue Direction ».
- **Mise en forme conditionnelle** d'après les cibles proposées en L7 (`[Cible recouvrement]`, `[Cible abandon]`) : l'écart saute aux yeux.
- La **Satisfaction** a sa carte, qui affiche « Non mesurée : aucune source ». Un manque de données visible vaut mieux qu'une case absente, qui laisserait croire qu'on l'a oubliée.

4. Segments et filtres

Outil	Qui l'utilise	Niveau	Usage EduSmart
Segment	Le décideur, sur la page	Visible, interactif	Année académique, région, niveau, catégorie
Filtre de visuel	Le concepteur	Un seul visuel	« 10 premières filières par impayés »

Outil	Qui l'utilise	Niveau	Usage EduSmart
Filtre de page	Le concepteur	Toute la page	Une page RH limitée aux enseignants permanents
Filtre de rapport	Le concepteur	Toutes les pages	Aucun : les données sont déjà propres (L5)

Le piège des deux « années académiques ».

- `dim_formation[annee_academique]` est l'année **de la formation payée**. Elle sert au CA et au recouvrement, conformément à la définition L7.
- `dim_temps[annee_academique]` est l'année **de la date de l'événement**. Elle sert aux connexions et aux notes.

Utiliser la seconde sur la page Finance ferait réapparaître l'année « 2022-2023 » fictive (les acomptes d'été). Chaque page utilise donc **explicitement** la bonne colonne.

5. Interactivité

Mécanisme	Usage
Filtrage croisé	Un clic sur une région filtre les autres visuels de la page
Modifier les interactions	Les cartes KPI de la page 1 **ne** sont **pas** filtrées par ce clic : les chiffres globaux restent visibles pendant l'exploration
Drill down (hiérarchies)	Géographie (région › ville), Calendrier (année › trimestre › mois), Offre (département › filière › classe) : les opérations de la Phase 10, en un clic
Segments synchronisés	Région et niveau conservés entre les pages Direction et Finance

6. Le tableau de bord

Page	Question du décideur	Visuels principaux
Vue Direction	Où en sommes-nous ?	8 cartes KPI + Satisfaction, CA et montant dû par année, CA par région
Finance	L'argent rentre-t-il ?	Courbe mensuelle (saisonnalité), carte de chaleur du recouvrement (filière × année), Top 10 des impayés
Pédagogie	Les étudiants apprennent-ils ?	Histogramme des scores, carte de chaleur catégorie × niveau, nuage tentatives × score
Engagement	Sont-ils présents ?	Carte de chaleur jour × heure, boxplot par appareil, étudiants actifs
RH (facultative)	Masse salariale et absences	Courbe, barres par motif
Contrôle G5b (masquée)	Les mesures sont-elles justes ?	Tableau des 8 mesures, 6 décimales

Principes de mise en page :

- une page = une question ;
- lecture en « Z » : KPI en haut, détail en bas ;
- 6 visuels au maximum par page ;
- titres qui énoncent la conclusion ;

- une couleur d'accent réservée à ce qui s'écarte de la cible.

7. Porte G5b

Chaque mesure DAX, **sans filtre**, doit retrouver la valeur SQL de référence (`kpi_reference.json`, validée par G5a en L7). `scripts/verifier_g5b.py` compare les valeurs recopiées depuis Power BI, avec des tolérances explicites :

- le centime pour le CA ;
- l'exactitude pour les effectifs et la médiane ;
- 10^{-6} pour les ratios.

Le fichier de saisie ne contient pas les valeurs attendues : la saisie reste « à l'aveugle ».

La chaîne de confiance est alors complète : **SQL (DW) = Python (clean) = DAX (Power BI)**, soit trois langages et trois couches pour les mêmes 8 chiffres.

Limite de G5b, révélée en L10. G5b ne compare que des valeurs **sans filtre**. Or une relation inactive ne change pas un total : elle ne fausse que les valeurs **filtrées** par la dimension concernée. G5b était donc verte (8/8) alors que tout filtre par région faussait le CA. Une version renforcée de la porte comparerait aussi quelques valeurs filtrées par chaque dimension (par exemple le recouvrement d'une région, calculé en SQL et lu dans Power BI).

Références

- PDF « BI Recherche P8 », Phase 13.
- M. Russo et A. Ferrari, *The Definitive Guide to DAX*, 2e éd. (2019) : contexte de filtre, mesures ou colonnes calculées.
- Microsoft Learn, *Modélisation en schéma en étoile dans Power BI* : relations, cardinalité, direction du filtrage.

Phase 14 — Data Storytelling

EduSmart Decision Platform · Lot L9 · Étape 6 du module BI

> **PDF, recherche :** qu'est-ce que le Data Storytelling ? Comment raconter une histoire avec les données ? Comment convaincre un décideur ?
>
> **PDF, TP :** présenter les résultats obtenus à partir du tableau de bord.
>
> Tableau de bord : `powerbi/EduSmart.pbix` (4 pages) · export : `powerbi/EduSmart.pdf` · chiffres : 11_kpi.md · graphiques : 12_visualisations.md.

Nature de ce document. C'est un document de **compréhension** : il construit le récit qu'un analyste présenterait au Directeur Général, et il dit honnêtement ce que ces données permettent, ou non, d'affirmer. Tous les chiffres sont ceux du Data Warehouse au 15/09/2026 (date de référence C20), validés par trois chemins de calcul (SQL, Python, DAX : portes G5a et G5b).

---

1. Qu'est-ce que le Data Storytelling ?

Le Data Storytelling est l'art de transformer une analyse en **message qui déclenche une décision**. Il combine trois éléments, et aucun ne suffit seul :

Élément	Rôle	Seul, il donne…
Les données	La preuve	un tableau de chiffres que personne ne lit
Les visuels	Rendre la preuve évidente	un joli graphique sans conclusion
Le récit	Relier les preuves à une décision	une opinion sans preuve

Les données expliquent **ce qui se passe**, le récit explique **pourquoi cela compte**, et les visuels **le rendent visible**. Un tableau de bord répond à « où en sommes-nous ? ». Une histoire répond à « que devons-nous faire, et pourquoi maintenant ? ».

Différence avec un tableau de bord. Le tableau de bord EduSmart (L8) est un outil d'**exploration** : le décideur filtre, descend dans les hiérarchies et trouve ses réponses. Le storytelling est une **explication** : l'analyste a déjà exploré et choisit le chemin, les 3 ou 4 constats qui comptent, dans un ordre qui mène à une décision.

2. Comment raconter une histoire avec les données ?

2.1 Partir d'une idée maîtresse

Avant tout visuel, il faut pouvoir écrire le message en **une phrase** : un point de vue, ce qui est en jeu, la décision attendue. Si cette phrase n'existe pas, il n'y a pas encore d'histoire, seulement des chiffres.

2.2 Une structure en trois temps : situation, complication, résolution

Temps	Question	Contenu
Situation	Où en sommes-nous ?	Les faits partagés, sans surprise : le décideur doit se reconnaître

Temps	Question	Contenu
Complication	Qu'est-ce qui ne va pas, ou pourrait mal tourner ?	L'écart à la cible, le risque, ce qu'on ne sait pas
Résolution	Que faire ?	Des recommandations précises, chacune liée à un constat et à un indicateur de suivi

Pour un décideur, on peut aussi **commencer par la conclusion** (principe de la pyramide) : la recommandation d'abord, puis les arguments, puis les preuves. Le décideur pressé s'arrête à la première ligne ; le décideur sceptique descend jusqu'aux chiffres.

2.3 Des règles de mise en forme

Elles sont déjà appliquées dans le tableau de bord (L8, 13_powerbi.md § 6) :

- **une page = une question** du décideur ;
- des **titres qui énoncent la conclusion** (« Le recouvrement est stable autour de 90 % ») et non le sujet (« Recouvrement ») ;
- une **couleur d'accent** réservée à ce qui s'écarte de la cible ;
- au plus **6 visuels** par page ;
- le **bon graphique** pour la bonne question (Phase 12) : une évolution se lit sur une courbe, une comparaison entre catégories sur des barres.

3. Comment convaincre un décideur ?

Principe	Application à EduSmart
Répondre à SES questions, pas aux nôtres	Le récit suit les 7 questions du DG (Phase 1), § 4
Chiffre + comparaison + décision	« 6,24 % d'abandon » ne dit rien seul ; « 6,24 % pour une cible de 5 %, stable sur 3 ans : le problème est structurel » appelle une décision
Mériter la confiance dans les chiffres	Chaque KPI est calculé par 3 chemins (SQL = Python = DAX), et le pipeline est testé de bout en bout (porte G6, 15_tests_pipeline.md)
Dire ce qu'on ne sait pas	Satisfaction et évaluation des enseignants : aucune donnée. Le dire renforce la crédibilité de tout le reste
Ne jamais affirmer une cause sans preuve	Une corrélation n'est pas une cause ; ici, la plupart des relations testées sont nulles ou faibles (§ 8)
Anticiper les objections	§ 9 : les questions qu'un DG posera, avec leurs réponses
Proposer une action mesurable	Chaque recommandation a un responsable et un KPI de suivi (§ 7)

4. Le public : le Directeur Général et ses 7 questions

Le cas pratique de la Phase 1 liste ce que le DG veut savoir. Le récit doit y répondre, y compris quand la réponse est « on ne peut pas savoir ».

Question du DG (PDF, Phase 1)	Réponse au 15/09/2026	Page Power BI	Statut
Le nombre réel d'étudiants	**10 500** personnes distinctes (la somme naïve des sources donnait **26 476**)	Vue Direction	✅
Le chiffre d'affaires	**13,554 Mds XOF** encaissés	Vue Direction, Finance	✅
Le taux de réussite	**93,13 %** de réussite aux quiz en ligne	Vue Direction, Pédagogie	✅ (≠ réussite au diplôme, § 8.3)
La satisfaction des étudiants	Aucune source ne la contient	Vue Direction (carte « Non mesurée »)	❌
Les formations les plus suivies	Matrice catégorie × niveau, hiérarchies Offre	Pédagogie	✅
Le temps moyen de connexion	Médiane de **29 min** (1 740 s)	Engagement	✅ (médiane plutôt que moyenne, § 8.4)
Les enseignants les mieux évalués	Aucune évaluation dans les sources	—	❌

5 questions sur 7 ont une réponse. Les 2 autres sont des **manques de données**, documentés depuis L3 (02_besoin_metier.md) : ils deviennent des recommandations.

5. L'idée maîtresse

> **EduSmart encaisse 90 % de ce qu'elle attend et ses apprenants réussissent leurs quiz (93 %), mais seulement 3 sur 10 sont actifs sur 30 jours. La priorité n'est plus de recruter, c'est d'engager et d'écouter.**

« Écouter » renvoie aux **deux** angles morts : l'entreprise ne mesure ni la satisfaction de ses étudiants, ni la qualité perçue de ses enseignants.

Précision : 3 003 actifs sur 10 500 étudiants, soit **28,6 %**. « 3 sur 10 » est un arrondi un peu favorable ; la cible proposée en L7 est de 30 %.

6. Le récit en trois actes

Acte 1 — Situation : une plateforme qui fonctionne *(page Vue Direction)*

Constat	Chiffre	Lecture
Une base d'étudiants enfin connue	**10 500** personnes (9 000 rapprochées entre PostgreSQL et MySQL, 1 000 inscrits sans compte LMS, 500 comptes LMS sans inscription)	Sans plateforme décisionnelle, la direction aurait additionné les sources : **26 476**, soit 2,5 fois trop
Un chiffre d'affaires en croissance	2 868 M → 5 101 M → 5 585 M XOF (années académiques 2023-2024 à 2025-2026)	Le volume d'inscriptions a doublé : 3 617 → 7 383
Les étudiants réussissent leurs quiz	**93,13 %** des couples (étudiant, quiz) validés	Au-dessus de la cible proposée (85 %)
Les sessions sont longues	Médiane de **29 min**	Au-dessus de la cible proposée (20 min)

Message de l'acte 1 : *les fondamentaux sont sains, et pour la première fois, on peut le prouver avec des chiffres fiables.*

Acte 2 — Complication : trois signaux d'alerte et deux angles morts *(pages Finance, Engagement, Pédagogie)*

Signal 1 — L'argent qui ne rentre pas grossit avec l'activité.

Année académique	Montant dû	Encaissé	Non encaissé	Recouvrement
2023-2024	3 179 M	2 868 M	**311 M**	90,19 %
2024-2025	5 624 M	5 101 M	**523 M**	90,70 %
2025-2026	6 240 M	5 585 M	**655 M**	89,51 %
Total	**15 043 M**	**13 554 M**	**≈ 1 489 M**	**90,10 %**

Le **taux** est stable, autour de 90 % ; le **montant** non encaissé, lui, a doublé en deux ans (311 M → 655 M), parce que l'activité a doublé. À taux constant, chaque nouvelle cohorte ajoute des impayés. *Nuance :* l'année 2025-2026 n'est pas close au 15/09/2026 ; une partie des 655 M peut encore être encaissée. *(Montants en millions de XOF, arrondis : écart d'arrondi possible de ±1 M sur le total.)*

Signal 2 — 7 étudiants sur 10 ne se sont pas manifestés depuis 30 jours. 3 003 actifs sur 10 500 (28,6 %), sous la cible proposée de 30 %. *Nuance importante :* ce KPI ne compte que les connexions, les notes et l'activité de quiz. Les vidéos et les téléchargements MongoDB ne sont pas dans le DW (11_kpi.md, limites du KPI). Le chiffre est donc un **minimum** : l'engagement réel est au moins de 28,6 %.

Signal 3 — Ils commencent, mais ne finissent pas.

- Progression moyenne : **65,59 %**, sous la cible proposée de 70 %.
- Abandon : **6,24 %**, au-dessus de la cible proposée de 5 %, et **stable** sur trois ans (6,25 % ; 6,33 % ; 6,16 %). Un taux stable n'est pas un accident : c'est une caractéristique du fonctionnement actuel.

Angle mort 1 — La satisfaction n'est pas mesurée. Aucune des 5 sources ne contient d'avis ni d'enquête. Le tableau de bord le montre explicitement (carte « Non mesurée ») plutôt que de le cacher.

Angle mort 2 — La qualité des enseignants n'est pas mesurée. Il n'existe aucune évaluation, et le lien enseignant ↔ cours n'existe que par le **nom** du responsable de classe (convention C18).

Message de l'acte 2 : *l'entreprise recrute bien et encaisse bien, mais elle ne retient pas assez, et elle ne sait pas pourquoi, faute d'écouter ses étudiants.*

Acte 3 — Résolution : engager et écouter *(§ 7)*

7. Recommandations

Chaque recommandation est rattachée à un constat, à un indicateur de suivi et à un niveau de confiance. **Les cibles chiffrées ne figurent dans aucune source** : celles qui sont citées sont les propositions de L7, à valider par la direction.

#	Recommandation	Constat d'appui	KPI de suivi	Responsable	Confiance
R1	Collecter un **score de satisfaction** (échelle de 1 à 5) à la fin de chaque module, dans la plateforme pédagogique ; il alimenterait un nouveau fait `fact_evaluations`	Satisfaction : aucune donnée	Satisfaction (enfin mesurable)	DG	**Haute** : manque factuel
R2	Créer une **évaluation des enseignements** et une table d'**affectation** enseignant ↔ cours (le PDF RH évoque les affectations sans les décrire)	Évaluation des enseignants : aucune donnée	Note moyenne par enseignant	Direction pédagogique, RH	**Haute** : manque factuel
R3	Un **plan de relance des impayés** dès la 2e tranche, piloté par le Top 10 des impayés (page Finance)	≈ 1 489 M XOF non encaissés, montant en hausse	Taux de recouvrement ; impayés (XOF)	Direction financière	**Moyenne** : l'année en cours n'est pas close
R4	Un **programme de réactivation** des inactifs (relance après 15 jours sans activité, tutorat)	71,4 % d'étudiants sans activité mesurée sur 30 jours ; progression 65,59 % ; abandon 6,24 %	Étudiants actifs (30 j) ; progression ; abandon	Direction pédagogique	**Moyenne** : KPI sous-estimé (vidéos non comptées), cause de l'inactivité inconnue tant que R1 n'existe pas
R5	Intégrer les **vidéos et téléchargements** MongoDB dans le DW, pour un KPI d'activité complet	Le KPI actuel est un minimum	Étudiants actifs (30 j)	Équipe data	**Haute** : limite technique documentée
R6	**Normaliser la saisie à la source** : listes fermées pour les modes de paiement (« OM », « Orange Money », « orange money »), les villes (« Dakar », « DAKAR », « dakarr »), les catégories	159 946 anomalies traitées en L5 (55 853 corrigées, 25 932 rejetées, 78 161 signalées)	Taux de conformité qualité (05_qualite.md)	DSI, chaque service	**Haute**

Ce qui n'est PAS recommandé, et pourquoi :

- *« Développer une application tablette pour allonger les sessions »* : la durée des sessions est identique sur mobile, PC et tablette (§ 8.1). Rien ne justifie cet investissement.
- *« Pousser les étudiants à se connecter plus longtemps pour progresser »* : aucune relation entre heures connectées et progression ($r = -0{,}01$, § 8.1).
- *« Remplacer la satisfaction par le taux de réussite »* : un indicateur de substitution tromperait le décideur (11_kpi.md, § 5).

8. Ce que les données ne permettent PAS d'affirmer

8.1 Des données simulées : certains « constats » sont des paramètres du générateur

Les 5 sources ont été **générées** (Python, Faker, graine 2026). Plusieurs résultats du tableau de bord ne décrivent donc pas un comportement réel : ils **restituent un paramètre du générateur**. Je l'ai vérifié dans le code.

Constat du tableau de bord	Paramètre du générateur	Fichier
Pic d'activité entre 20 h et 22 h, rien avant 6 h	Poids horaires de 6 h à 23 h, maximum à 20 h et 21 h	`sources/s2_mysql/generate_data.py`

Constat du tableau de bord	Paramètre du générateur	Fichier
Dakar porte 29 % du CA, Thiès 13 %	Poids régionaux : Dakar 30, Thiès 13 (C10)	`common/senegalese_data.py`
Abandon de 6,24 %	`P_ABANDON = 0.06` (6 % par an)	`sources/s1_postgresql/generate_data.py`
Réussite de 93 %	Seuil de validation à 10/20 ; jusqu'à 5 tentatives par quiz, le score progressant de 7 points de pourcentage à chaque essai	`sources/s2_mysql/generate_data.py`
Durée de connexion identique sur les 3 appareils	Durée tirée d'une loi log-normale, **indépendamment** de l'appareil	idem
Aucune relation heures connectées / progression (r = −0,01)	Variables tirées indépendamment (12_visualisations.md, § 2.3)	idem
Recouvrement quasi uniforme entre filières (89 à 91 %)	Mêmes probabilités de paiement pour toutes les filières (aucun paramètre de filière)	`sources/s1_postgresql/generate_data.py`
Pic du CA en octobre	Rentrée au 1er octobre (C7) et 1re tranche payée dans les 10 jours suivant l'inscription	idem

Comment les présenter : comme des **capacités** de la plateforme, pas comme des découvertes. Exemple : « Sur des données réelles, cette carte de chaleur dirait au DG quand programmer les classes virtuelles et la maintenance. »

Ce que cela prouve quand même, et c'est important. Retrouver en sortie les paramètres injectés en entrée est une **validation de bout en bout** du pipeline : 6 % d'abandon par an injectés → 6,24 % mesurés ; 10 500 personnes dans le référentiel (L1) → 10 500 comptées ; Dakar pondérée à 30 % → 29 % du CA. Un pipeline qui perdrait, dupliquerait ou rattacherait mal des lignes ne retrouverait pas ces valeurs. C'est le lien entre cette phase et la Phase 15.

Correction par rapport aux notes de synthèse de L8. La relation entre **tentatives et score** n'est pas nulle : elle est **négative et faible** (r = −0,20, 12_visualisations.md § 2.3) ; ceux qui ont besoin de plus de tentatives ont un score moyen plus bas. C'est le croisement **heures connectées × progression** qui ne montre aucune relation (r = −0,01).

8.2 Aucune affirmation causale

Le tableau de bord montre des **associations**, jamais des **causes**. Même la relation tentatives / score (r = −0,20) ne dit pas que retenter fait baisser le score : les étudiants en difficulté retentent plus **et** ont de moins bons scores. Une cause se démontre par une expérimentation (deux groupes, une seule différence), pas par un graphique.

8.3 « Taux de réussite » : de quoi parle-t-on ?

93,13 % est la part des couples (étudiant, quiz) **validés au moins une fois**, toutes tentatives confondues. Cela explique l'écart apparent avec une distribution des scores centrée vers 10-12/20 : un étudiant qui échoue deux fois puis valide compte comme une réussite. Ce n'est **pas** le taux de réussite au diplôme, qu'aucune source ne contient (gap L3).

8.4 Médiane plutôt que moyenne

Le DG demande un temps « moyen » de connexion. La **médiane** (29 min) est retenue, car environ 1 % des connexions dépasse 150 min, jusqu'à 480 min : une moyenne serait tirée vers le haut par ces sessions anormales. 1

658 connexions sans déconnexion (B08) sont exclues, faute de durée.

8.5 Le piège du taux de recouvrement filtré sur une petite région

Sans filtre, le recouvrement par filière va de 89 % à 91 %. Avec un filtre sur **Kaffrine**, Power BI affiche **2 821 %** (constat L8).

L'explication « Kaffrine a peu d'étudiants » est **incomplète**. Un petit effectif rend un taux **instable**, il ne le multiplie pas par 30 : si le numérateur et le dénominateur portaient sur les **mêmes** inscriptions, le taux resterait proche de 90 %. Un taux de 2 821 % signifie que, dans ce contexte de filtre, **le CA retenu porte sur beaucoup plus d'inscriptions que le montant dû**.

Ce que l'on sait du modèle : le CA vient de `fact_paiements`, le montant dû de `fact_inscriptions`, et chacun porte **sa propre** `region_key` (la région de l'étudiant à la date de l'événement). J'ai écarté une cause : les déménagements de la démonstration SCD 2 prennent effet à la date d'extraction (octobre 2026), **après** tous les paiements, donc ils ne séparent pas les deux régions. **La cause exacte reste à confirmer**, avec cette requête sur le DW :

```
 -- Recouvrement par région, côté SQL : chaque fait rattaché à SA région
WITH ca AS (SELECT r.region, SUM(p.montant_ca) AS ca
            FROM dw.fact_paiements p JOIN dw.dim_region r USING (region_key) GROUP BY 1),
     du AS (SELECT r.region, SUM(i.montant_du) AS du, COUNT(*) AS inscriptions
            FROM dw.fact_inscriptions i JOIN dw.dim_region r USING (region_key) GROUP BY
1)
SELECT COALESCE(ca.region, du.region) AS region, du.inscriptions, ca.ca, du.du,
       round(100 * ca.ca / NULLIF(du.du, 0), 2) AS recouvrement_pct
FROM ca FULL JOIN du USING (region)
ORDER BY recouvrement_pct DESC NULLS FIRST;
```

- Si Kaffrine est proche de 90 % en SQL, le problème vient du **contexte de filtre de Power BI** (segment posé sur une colonne qui ne filtre qu'un des deux faits, interaction entre visuels…).
- Si Kaffrine est aberrante en SQL aussi, le problème vient du **rattachement des régions** dans le DW, et il faut comparer, pour les étudiants concernés, la région de l'inscription et celle des paiements.

Résultat (lot L10, requêtes K1 à K4 de `diagnostics_L10.sql`, 12/10/2026) :

Requête	Résultat	Conclusion
K1 : recouvrement par région	Kaffrine **89,68 %** ; les 14 régions entre 88,57 % (Matam) et 93,29 % (Kédougou)	Kaffrine est normale
K2 : par filière à Kaffrine, chaque fait agrégé séparément	De 79,84 % à 100 %	Aucun taux au-dessus de 100 %
K3 : paiements rattachés à une autre région que leur inscription	**0** sur 38 372	Hypothèse « déménagements SCD 2 » réfutée
K4 : versions SCD 2 dans `dim_etudiant`	**0**	Réfutée une seconde fois : aucun étudiant n'a déménagé dans le DW actuel

Le Data Warehouse est juste ; le 2 821 % venait du modèle Power BI.

Cause identifiée et corrigée (21/10/2026). La relation `fact_paiements[region_key] → dim_region[region_key]` était **inactive**. Un filtre sur Kaffrine filtrait donc le montant dû (les inscriptions de

Kaffrine) mais **pas** le CA (les paiements de toutes les régions) : 13,55 Mds XOF rapportés au seul dû de Kaffrine. Le même défaut rendait égales les 14 barres du graphique « CA par région » de la page Vue Direction. La relation a été rendue active : dans l'export du 21/10/2026, le CA par région suit désormais l'entrepôt (Dakar ≈ 3,9 Mds XOF, soit 29 % ; Thiès ≈ 1,8 Md, soit 13 %). Le numérateur du taux est donc filtré comme le dénominateur.

Écart restant, non expliqué : une fois la matrice de la page Finance rétablie et les segments année et niveau vidés, Power BI affiche **89,29 %** pour Kaffrine, contre **89,68 %** dans l'entrepôt. Le correctif a fait disparaître l'aberration (2 821 %), mais pas tout l'écart. Les deux calculs étant des ratios des sommes, ils devraient coïncider ; l'écart de 0,39 point reste à expliquer (13_powerbi.md). La valeur qui fait foi est celle de l'entrepôt, **89,68 %**.

Pourquoi la porte G5b ne l'avait pas vu : elle compare les mesures **sans filtre**, et une relation inactive ne change aucun total (13_powerbi.md, § 7).

Un second piège, rencontré pendant le diagnostic. Une première requête de vérification donnait 32 à 47 % pour toutes les filières de Kaffrine. Elle joignait `fact_paiements` et `fact_inscriptions` **ligne à ligne** (sur l'étudiant et la formation) : le montant dû de chaque inscription était compté **une fois par paiement**. Avec 2,29 paiements par inscription en moyenne, 90,10 % ÷ 2,29 ≈ 39,4 %. C'est le « chasm trap » de la modélisation dimensionnelle : dans une constellation, on **agrège chaque fait séparément** sur les dimensions partagées, puis on joint les résultats.

Règles de lecture retenues :

- un taux se lit sur une population suffisante et cohérente, avec son effectif ;
- numérateur et dénominateur issus de deux faits s'agrègent **séparément** ;
- au-delà de 100 %, ou loin de la moyenne, on vérifie le calcul avant de conclure.

9. Objections probables du décideur, et réponses

Objection	Réponse
« Ces chiffres sont-ils fiables ? »	Chaque KPI est calculé trois fois (SQL sur le DW, Python sur la couche clean, DAX dans Power BI) avec le même résultat ; le pipeline est testé de bout en bout (101 contrôles, porte G6), y compris par des tests qui introduisent volontairement des erreurs pour vérifier qu'elles sont détectées
« Pourquoi 10 500 étudiants et pas 26 476 ? »	Les mêmes personnes apparaissent dans plusieurs systèmes, sous des identifiants différents (UUID dans PostgreSQL, `LMS-XXXXXX` dans MySQL). Le rapprochement compte chaque personne une seule fois
« 93 % de réussite, c'est excellent, non ? »	C'est la réussite aux quiz en ligne, en acceptant plusieurs tentatives. Ce n'est ni la réussite au diplôme ni une mesure de la qualité de l'apprentissage (§ 8.3)
« Pourquoi ne pas mesurer la satisfaction avec les données existantes ? »	Tout indicateur de substitution (temps passé, réussite) mesurerait autre chose. Il faut la demander aux étudiants (R1)
« Le recouvrement est à 90 %, où est le problème ? »	Le taux est stable, mais le montant non encaissé a doublé en deux ans (311 M → 655 M XOF) parce que l'activité a doublé
« Faut-il investir dans une application tablette ? »	Rien ne le justifie : la durée des sessions est la même sur tous les appareils (§ 7). Sur ces données simulées, c'est un paramètre du générateur ; sur données réelles, le même graphique trancherait
« Pourquoi l'abandon dépasse-t-il la cible ? »	Les données ne le disent pas : la source ne date pas l'abandon et n'en donne pas le motif. C'est précisément ce que R1 et R4 doivent éclairer

10. L'histoire en une minute

> Pour la première fois, EduSmart connaît son nombre réel d'étudiants : **10 500**, et non 26 476. Ses fondamentaux sont sains : **13,55 milliards de XOF** encaissés, **90 %** de recouvrement, **93 %** de réussite aux quiz.
>
> Mais trois signaux doivent alerter : l'argent non encaissé a **doublé en deux ans** (655 M XOF sur la dernière année) ; **7 étudiants sur 10** n'ont aucune activité mesurée sur 30 jours ; l'abandon reste au-dessus de la cible, **à 6,24 %**, depuis trois ans.
>
> Et l'entreprise ne sait pas pourquoi : elle ne mesure **ni la satisfaction de ses étudiants, ni la qualité de ses enseignants**.
>
> La priorité n'est plus de recruter, c'est **d'engager et d'écouter** : mesurer la satisfaction et l'enseignement, relancer les impayés, réactiver les inactifs, et fiabiliser la saisie à la source.

Références

- PDF « BI Recherche P8 », Phase 14 (Étape 6) ; Phase 1 (questions du DG).
- C. Nussbaumer Knaflic, *Storytelling with Data* (2015) : contexte, idée maîtresse, choix du visuel, élimination du superflu.
- B. Dykes, *Effective Data Storytelling* (2019) : données, récit et visuels.
- B. Minto, *The Pyramid Principle* (1987) : commencer par la conclusion ; situation, complication, résolution.
- Documents du projet : 02_besoin_metier.md, 11_kpi.md, 12_visualisations.md, 13_powerbi.md, 15_tests_pipeline.md.

Phase 15 — Validation et tests du pipeline

EduSmart Decision Platform · Lot L9 · Étape 7 du module BI

> **PDF, recherche :** pourquoi tester un pipeline ETL ?
>
> **PDF, TP :** créer des tests permettant de vérifier : toutes les lignes ont-elles été extraites ? toutes les lignes ont-elles été chargées ? des données ont-elles été perdues ? des erreurs sont-elles apparues ? les clés sont-elles toujours valides ?
>
> Code : `pipeline/verify_g6.py` · tests : `tests/test_verify_g6.py`, `tests/test_pipeline_integration.py` · rapport généré : `data/reports/G6_<lot>.md`.

---

1. Pourquoi tester un pipeline ETL ?

Un pipeline qui « tourne sans erreur » peut quand même produire de faux chiffres. Ses défauts sont **silencieux** : une jointure qui écarte des lignes, un filtre trop large ou un doublon ne lèvent aucune exception, et le tableau de bord affiche alors un chiffre faux avec une parfaite assurance.

Raison	Ce qui arrive sans test	Exemple réel dans EduSmart
Les pertes sont silencieuses	Une ligne disparaît entre deux couches, sans message	Un `INNER JOIN` à la place d'un `LEFT JOIN` aurait écarté les paiements orphelins **sans trace**. En L5, ils sont rejetés **et tracés** dans `quality.rejets`
Les doublons gonflent les totaux	Une même ligne est comptée deux fois	7 438 notes en double (B12) : sans dédoublonnage (règle `MY_NOTE_DOUBLON`), le nombre de tentatives et le taux de réussite seraient faussés
Les sources changent	Une colonne renommée casse l'extraction, ou pire, la vide	`version_schema` (empreinte des colonnes) dans `meta.metadata_sources`
Le pipeline évolue	Une optimisation change un résultat sans que personne ne le voie	L6 : `TRANSFORM s2_mysql` est passé de 486 s à 23 s (51 `ANALYZE`). Il fallait prouver que les **chiffres** n'avaient pas bougé, seulement la durée
La confiance du décideur	Un seul chiffre faux décrédibilise tout le tableau de bord	Le DG ne vérifiera pas 300 000 notes : il doit pouvoir faire confiance à la chaîne
Les sources volatiles	Une donnée Redis expire avant l'extraction	`statistics:today` expire au bout d'1 h (C24) : correctif L5, tolérance de G3 limitée à Redis

Tester un pipeline, c'est donc vérifier des **invariants** : des égalités qui doivent rester vraies quelles que soient les données. Exemple : « lignes en staging = lignes en clean + lignes rejetées ». Un test d'invariant ne dépend pas d'une valeur attendue écrite à la main ; il reste valable quand les données changent.

2. La stratégie de test d'EduSmart

Trois niveaux, du plus rapide au plus complet :

Niveau	Quoi	Où	Quand	Volume
Tests unitaires	Fonctions pures : règles de nettoyage, équation de conservation, comparaison des KPI, format des rapports	`tests/test_*.py` (sans base)	À chaque modification, en 2 min	303 tests (249 avant L9, + 41 en L9, + 13 en L10)
Portes de contrôle	Invariants sur les vraies données, couche par couche	`pipeline/verify_g2.py` … `verify_g6.py`	À chaque exécution du pipeline	G2 85, G3 69, G4 57, G5a 8, G5b 8, **G6 101**
Tests d'intégration	Le pipeline complet sur les 5 vraies sources, les portes, **les mutations**	`tests/test_*_integration.py` (`EDUSMART_INTEGRATION=1`)	Avant chaque livraison de lot	69 tests (57 avant L9, + 11 en L9, + 1 en L10)

Pourquoi G6 alors que G2, G3 et G4 existent ? Chaque porte précédente regarde **une** frontière. G6 regarde la chaîne **entière**, et ajoute deux choses qui manquaient :

Porte	Frontière contrôlée	Ce qu'elle ne voit pas
G2	source → staging	ce que devient la ligne ensuite
G3	anomalies du volet A → traitement	les lignes **sans** anomalie qui se perdraient
G4	clean → DW	ce qui s'est perdu **avant** la couche clean
G6	**source → staging → clean + rejets → DW**, journal, clés, KPI	—

Les deux ajouts : l'**équation de conservation staging → clean + rejets**, que personne ne vérifiait, et la **non-régression des KPI**, qui fige les 8 valeurs validées en L7.

3. Les 5 questions du PDF : la porte G6

Code	Question du PDF	Contrôle	Nb
G6.1	Toutes les lignes ont-elles été **extraites** ?	Source recomptée maintenant = manifeste du lot = journal `EXTRACT` (statut SUCCES)	17
G6.2	Toutes les lignes ont-elles été **chargées** ?	Staging (lignes du lot) = manifeste = journal `LOAD`, et **aucune ligne d'un autre lot**	17
G6.3	Des données ont-elles été **perdues** ?	Équation de conservation (§ 4) : 16 tables + 9 contrôles Redis + 8 faits + 2 contrôles du rapport qualité	35
G6.4	Des **erreurs** sont-elles apparues ?	Journal du lot : 41 étapes attendues présentes, dernière exécution SUCCES, aucune `EN_COURS`, 0 erreur ; `metadata_sources` à jour	9
G6.5	Les **clés** sont-elles toujours valides ?	26 clés étrangères des 8 faits (regroupées par fait), membres « Inconnu », version courante unique (SCD 2), clés primaires des 24 tables clean, 4 intégrités garanties par les rejets	15
G6.6	*(ajout)* Les KPI ont-ils changé ?	Les 8 KPI de `dw.v_kpi` = valeurs validées en L7, tolérance explicite	8
		Total	**101**

Détails de conception :

- **Redis n'est jamais recompté après coup.** Le PDF Source 5 le dit : « Redis ne conserve pas les données de manière permanente ». Une heure après l'extraction, `statistics:today` a expiré : recompter donnerait un

écart **normal**. La référence de Redis est donc l'instant d'extraction (manifeste = journal).

- **Une étape relancée n'est jugée que sur sa dernière exécution.** Le test d'idempotence recharge le staging : le journal contient alors deux lignes `LOAD` par objet. Un échec suivi d'un succès est compté à part, pour information (« échecs rattrapés »).
- **Lecture seule.** G6 n'écrit rien et ne valide aucune transaction : c'est ce qui permet les tests de mutation (§ 5).
- **G6 ne s'inscrit pas dans `meta.etl_execution_log`** (décision D-L9-03) : son propre résultat fausserait G6.4 à l'exécution suivante.
- **Réutilisation, pas recopie.** Les listes des clés étrangères et des faits viennent de `verify_g4.py`, celle des 16 tables du rapport qualité de `rapport_qualite.py`. Un test unitaire vérifie que G6 n'en possède pas de copie.

4. L'équation de conservation (« des données ont-elles été perdues ? »)

4.1 Le principe

Chaque ligne du staging a **exactement un destin** : elle arrive en clean (corrigée ou non, éventuellement signalée), ou elle est rejetée **avec trace** dans `quality.rejets`. D'où, pour chaque table :

```
lignes du lot en staging  =  lignes en clean  +  lignes rejetées DISTINCTES
lignes en clean           =  lignes du fait correspondant dans le DW
```

Piège évité : compter les rejets avec `COUNT(*)`. Une ligne rejetée par deux règles serait comptée deux fois, et l'équation pourrait tomber juste par hasard (une perte compensée par un double rejet). G6 compte les rejets par `COUNT(DISTINCT rang)`, où `rang` est le `_row_number` du staging, et vérifie à part qu'**aucune ligne n'est rejetée deux fois**. J'ai relu les 14 appels de `quality.rejeter` : les règles d'une même table sont disjointes (`rn > 1` pour les doublons, `rn = 1` pour les autres), donc ce contrôle doit être vert.

Piège évité : les 159 946 anomalies ne sont pas des lignes. Une ligne peut porter plusieurs anomalies. Elles n'entrent jamais dans une équation de lignes.

4.2 Redis : l'unité change selon la famille

Une ligne du staging Redis est une **clé**. La couche clean, elle, compte des clés, des messages ou des membres selon la famille. G6 écrit donc une équation par famille :

Famille (PDF Source 5)	Unité en clean	Équation contrôlée
`session:*`	une session	clés = `clean.redis_sessions`
`last_course:*`, `last_quiz:*`, `progress:*`	un étudiant	clés = clean + clés rejetées (étudiant inconnu, E06)
`notifications:*` (clé)	un étudiant	clés = étudiants distincts en clean + clés rejetées
`notifications:*` (message)	un message	messages = clean + doublons (E04) + messages des clés rejetées
`online_users`, `statistics:today`	un compteur	1 + 4 lignes de `clean.redis_compteurs`
`leaderboard:*`	un membre	membres = clean, **bloquant** depuis L10 (constat L9-A1, décision A1-bis)
toute autre clé	—	aucune clé non routée (sinon elle disparaîtrait sans trace)

5. Les tests de mutation : prouver que les tests savent échouer

Un test qui ne peut pas échouer ne prouve rien. Pour chaque question du PDF, un test d'intégration **casse volontairement** une donnée, dans une transaction, vérifie que G6 passe au rouge sur le bon contrôle, puis **annule** la transaction (`ROLLBACK`). Les données réelles ne sont jamais modifiées durablement.

Mutation	Question	Défaut introduit	Contrôle G6 qui doit échouer
`Q1`	Extraites ?	La source contient une ligne de plus que le lot (`s2_mysql.notes`)	`Extraction de s2_mysql.notes`
`Q2_ligne_staging_perdue`	Chargées ?	Une ligne supprimée de `staging.stg_pg_filieres`	`Chargement de s1_postgresql.filieres`
`Q3_ligne_dw_perdue`	Perdues ?	Une note supprimée de `dw.fact_notes`	`clean -> DW : fact_notes`
`Q3_ligne_clean_perdue`	Perdues ?	Un paiement supprimé de `clean.paiements`, sans rejet	`staging -> clean + rejets : s1_postgresql.paiements`
`Q3_rejet_en_double`	Perdues ?	Une ligne rejetée deux fois	`Aucune ligne rejetée deux fois`
`Q4_etape_en_echec`	Erreurs ?	Dernière exécution de `TRANSFORM s2_mysql` en `ECHEC`	`Journal : étape TRANSFORM`
`Q5_cle_orpheline`	Clés ?	Une inscription supprimée : ses paiements deviennent orphelins	`Intégrité clean : paiements -> inscriptions`
`NR_kpi_ca_fausse`	Non-régression	**1 000 XOF** ajoutés à un seul paiement (sur 13,55 Mds)	`KPI CA`
`Q3_membre_classement_perdu` *(L10)*	Perdues ?	Un membre du classement Redis supprimé de la couche clean	`Redis : membres du classement -> clean.redis_leaderboard`

Une **contre-épreuve** termine la série : après les 9 mutations, G6 est de nouveau verte, ce qui prouve qu'aucune n'a été validée par erreur.

Preuve que les tests de mutation mordent (faite pendant le développement). En sabotant volontairement l'équation de conservation de G6 (« toujours vrai »), les deux tests `Q3_ligne_*_perdue` échouent ; G6 restaurée, ils repassent. Un test de mutation qui resterait vert avec une porte sabotée serait inutile.

6. Rapport de tests final

6.1 Chaîne des portes

Porte	Lot	Question	Résultat
G0	L0	L'infrastructure répond-elle ?	5/5 ✅
G1	L2	Les 5 sources sont-elles conformes aux PDF ?	195/195 ✅ (39 + 45 + 50 + 30 + 31)
G2	L4	Extraction et chargement fidèles ?	85/85 ✅
G3	L5	Toutes les anomalies traitées ?	69/69 ✅ (159 946 anomalies)
G4	L6	Le Data Warehouse est-il juste ?	57/57 ✅

Porte	Lot	Question	Résultat
G5a	L7	KPI : SQL (DW) = Python (clean) ?	8/8 ✅
G5b	L8	KPI : DAX (Power BI) = SQL ?	8/8 ✅
G6	**L9**	**Le pipeline est-il fiable de bout en bout ?**	**101/101** ✅ (17 + 17 + 35 + 9 + 15 + 8)

6.2 Suite pytest

Mode	Commande	Avant L9	Attendu après L9	Obtenu
Unitaire	`python -m pytest`	249 passed, 57 skipped	290 passed, 68 skipped	**290 passed, 68 skipped** ✅ (166 s)
Intégration	`$env:EDUSMART_INTEGRATION = "1"; python -m pytest`	—	358 passed, 0 skipped	**358 passed, 0 skipped** ✅ (1 464 s, soit 24 min)

Critère de la porte G6 (validé le 12/10/2026) : la suite **complète** en mode intégration, **0 test ignoré**. Un test ignoré ne prouve rien. Durée constatée : 24 min pour la suite d'intégration complète (dont environ 16 min pour `test_qualite_integration`).

Après L10 (contrôle du classement rendu bloquant, test de cohérence des rapports) : **299 passed, 69 skipped** en mode unitaire ✅, **368 passed, 0 skipped** en mode intégration ✅ (1 190 s, soit 20 min), porte G6 **101/101** ✅ avec `Redis : membres du classement -> clean.redis_leaderboard : 1 325 membres = 1 325 en clean`.

L10, partie 2 : 4 tests de plus sur le support de présentation (KPI, variantes, 11 points de la Phase 18). Attendu : **303 passed, 69 skipped** en mode unitaire, **372 passed, 0 skipped** en mode intégration.

Résultats obtenus sur le poste de développement (Windows, Python 3.14, Docker), le 12/10/2026 ; porte G6 validée sur le lot `B20261012T134851`.

6.3 Ce qui a été testé, et où

Élément	Où	Résultat
41 tests unitaires de G6	Atelier de développement, Python 3.13	41/41 ✅ ; suite unitaire complète : 288 passed, 70 skipped (2 tests ignorés de plus que chez toi : `data/` absent)
G6 sur un **entrepôt miniature**	PostgreSQL 16 local, **vrais DDL du dépôt** (meta, staging, quality, dw), couche clean minimale, 99 lignes de staging aux équations connues, dont un échec rattrapé, un doublon de notification, un étudiant Redis inconnu et un membre de classement écarté	101/101 ✅
8 mutations + contre-épreuve + ligne de commande	Même entrepôt miniature	10/10 ✅ ; G6 sabotée : 2 échecs attendus ✅
G6 sur les 5 vraies sources	Poste de développement (Docker)	**101/101** ✅ ; suite d'intégration complète 358/358

7. Journal des décisions et constats du lot L9

Décisions

#	Décision	Raison
D-L9-01	G6 dans `pipeline/verify_g6.py`	Même famille que G2, G3, G4 (contrôles du pipeline et du DW)
D-L9-02	Rapport de porte dans `data/reports/G6_<lot>.md` (non versionné) **et** synthèse versionnée dans ce document	`data/` est exclu par `.gitignore` : sans synthèse, le correcteur ne verrait aucun résultat sur GitHub
D-L9-03	G6 ne s'inscrit pas dans `meta.etl_execution_log`	Un G6 en échec, journalisé, ferait échouer G6.4 à l'exécution suivante (contrôle circulaire)
D-L9-04	Redis jugé à l'instant d'extraction, jamais recompté	Source volatile (PDF Source 5)
D-L9-05	Rejets comptés par `COUNT(DISTINCT rang)` + contrôle séparé des doubles rejets	Une perte ne doit pas pouvoir être compensée par un double comptage
D-L9-06	Référence KPI figée dans le code (`REFERENCE_KPI`) ; égalité exacte pour montants et effectifs, 10^{-9} pour les ratios, 10^{-6} pour la progression	Valeurs L7 transmises avec 10 et 8 décimales : la tolérance est d'un ordre de grandeur au-dessus de la troncature
D-L9-07	Tests de mutation en transaction annulée	Prouver que G6 détecte chaque type de défaut, sans jamais modifier les données
D-L9-08	Critère G6 : 0 test ignoré en mode intégration	Un test ignoré ne prouve rien
D-L10-01	Contrôle du classement Redis **bloquant** (A1-bis), plutôt qu'une nouvelle règle de rejet (A1)	0 cas attendu : une règle ne rejetterait rien, alors qu'un contrôle bloquant détecte toute perte future, sans modifier la couche clean validée en L5
D-L10-02	Test de cohérence des rapports (`tests/test_rapports.py`)	Les chiffres des rapports sont écrits à la main : ils sont comparés à `REFERENCE_KPI`, et toute variante arrondie contradictoire (« 93,1 % ») est refusée

Constats (à arbitrer, aucun ne bloque G6)

#	Constat	Source	Impact	Proposition
L9-A1 ✅	Les membres du classement Redis (`leaderboard:python`) inconnus de MySQL seraient écartés par un **filtre** dans `50_s5_redis.sql`, **sans trace** dans `quality.rejets`	`clean/50_s5_redis.sql`, bloc « classement »	Risque de perte silencieuse. **0 cas attendu** : sur les données régénérées à la graine 2026, les 1 325 membres sont tous présents dans MySQL. Les « 137 » d'abord évoqués sont les 137 faux comptes E06 (`last_course`, `progress`), **rejetés avec trace**	**Résolu en L10 (A1-bis)** : le contrôle G6 devient **bloquant** (membres = clean) au lieu d'ajouter une règle qui ne rejetterait rien ; mutation `Q3_membre_classement_perdu`

#	Constat	Source	Impact	Proposition
L9-A2	G2.1 recompte Redis en direct (`dbsize()`) : G2 relancée **seule** plus d'une heure après l'extraction échoue	`pipeline/verify_g2.py`	Faux rouge possible ; sans effet dans `run_pipeline` (G2 juste après l'extraction)	Aligner G2.1 sur D-L9-04. Non fait en L9 pour ne pas toucher une porte validée
L9-A3	Le dernier commit sur GitHub est `e544056` (mise à jour du `.pbix`), pas `2c2dd26`	`git log`	Références de version dans les rapports	Utiliser `e544056` comme base de L9
L9-A4	Le README racine indiquait encore « L8 : en attente de G5b »	`README.md`	Documentation	Corrigé en L9

8. Exécution

```
# 1. Tests unitaires (2 min)
python -m pytest -q

# 2. Porte G6 seule, sur le dernier lot (sources démarrées)
python -m pipeline.verify_g6
python -m pipeline.verify_g6 --sans-recomptage     # si une source est arrêtée : G6.1
compare manifeste et journal

# 3. Suite complète en mode intégration (≈ 24 min) : critère de la porte G6
$env:EDUSMART_INTEGRATION = "1"; python -m pytest -q
Remove-Item Env:EDUSMART_INTEGRATION
```

En cas d'échec, le rapport `data/reports/G6_<lot>.md` indique la question concernée, le contrôle et les comptages exacts (ex. `40 150 ≠ 40 149 clean + 0 rejetées (écart +1)`).

Références

- PDF « BI Recherche P8 », Phase 15 (Étape 7).
- R. Kimball et J. Caserta, *The Data Warehouse ETL Toolkit* (2004) : sous-système de contrôle qualité, rapprochement des comptages entre couches.
- Documents du projet : 05_qualite.md (rejets, porte G3), 06_metadonnees.md (journal), 07_conception_dw.md (porte G4), 11_kpi.md (valeurs de référence).

Phase 16 — Rapport individuel

EduSmart Decision Platform · Lot L10 · Ndeye Penda SARR · Master 2 Business Intelligence, UCAD

> **PDF, Phase 16 (projet individuel) :** développer son pipeline ETL ou ELT ; intégrer sa source de données ; participer à la construction du Data Warehouse ; proposer un schéma multidimensionnel ; définir les KPI ; construire un tableau de bord ; rédiger un rapport d'analyse.
>
> **Lecteur visé :** l'enseignant et tout lecteur technique. Ce rapport explique **ce qui a été construit, comment, pourquoi ainsi, et ce que j'en ai appris**. Le rapport destiné au Directeur Général est le rapport décisionnel (Phase 17).

---

1. Contexte et périmètre

EduSmart est une plateforme de formation en ligne dont les données sont dispersées dans **cinq systèmes** qui ne se parlent pas (PDF « Données EduSmart ») : la gestion académique (PostgreSQL), la plateforme pédagogique (MySQL), les ressources humaines (fichiers CSV), les journaux de l'application mobile (MongoDB) et la plateforme temps réel (Redis). Le Directeur Général veut une plateforme décisionnelle unique.

Une particularité de ce projet : il a été réalisé seule. Le PDF prévoit un groupe de cinq, chaque membre étant responsable d'une source. J'ai donc construit **les cinq sources**, puis la totalité de la chaîne décisionnelle. Ce rapport couvre l'ensemble ; le découpage entre « projet individuel » (Phase 16) et « projet collaboratif » (Phase 17) devient un découpage **par public** : ce rapport pour le lecteur technique, le rapport 17 pour le décideur.

2. Les 7 livrables de la Phase 16, et leur preuve

#	Livrable demandé (PDF)	Ce qui a été produit	Preuve vérifiable
1	Développer son pipeline ETL ou ELT	Pipeline **ELT** : 5 extracteurs, chargement, transformation SQL dans l'entrepôt, orchestrateur	`pipeline/`, porte **G2 85/85**
2	Intégrer sa source de données	Les **5 sources** construites, générées (Python, Faker) et volontairement dégradées : 69 types d'anomalies	`sources/s1_postgresql/` à `s5_redis/`, portes **G1 195/195**
3	Participer à la construction du DW	Entrepôt PostgreSQL en 3 couches (bronze, argent, or), 89 règles qualité, métadonnées	`pipeline/sql/`, portes **G3 69/69** et **G4 57/57**
4	Proposer un schéma multidimensionnel	Constellation de **8 faits** et **7 dimensions**, SCD 2 sur l'étudiant, 2 cubes OLAP	07_conception_dw.md, 10_olap.md
5	Définir les KPI	**8 KPI** calculés par deux chemins indépendants ; la satisfaction déclarée non mesurable	11_kpi.md, porte **G5a 8/8**
6	Construire un tableau de bord	Power BI, 4 pages, 31 mesures DAX, 26 relations, 5 hiérarchies	`powerbi/EduSmart.pbix`, porte **G5b 8/8**
7	Rédiger un rapport d'analyse	Data Storytelling, rapport décisionnel	14_data_storytelling.md, 17_rapport_decisionnel.md

Et, au-delà du PDF : une porte de **tests de bout en bout** (**G6 101/101**) et **372 tests automatisés** (§ 7).

3. La démarche : des lots et des portes de contrôle

Le projet a été découpé en **11 lots** (L0 à L10). Chaque lot suit le même cycle : plan détaillé, validation, production, exécution des tests, correction, validation. Un lot n'est validé que si sa **porte de contrôle** est entièrement verte.

Lot	Contenu	Phases du PDF	Porte	Résultat
L0	Infrastructure Docker (6 services), configuration, journalisation	—	G0	5/5
L1	Référentiel maître : 10 500 personnes	—	—	Livré
L2 (a à e)	Les 5 sources	Projet précédent	G1	195/195
L3	Recherches : opérationnel vers décisionnel, besoin métier, architectures, ETL ou ELT	1 à 4	—	Validé
L4	Pipeline : extraction, staging, métadonnées	4, 6	G2	85/85
L5	Couche clean, contrôle qualité	5	G3	69/69
L6	Data Warehouse, SCD 2	7, 8, 9	G4	57/57
L7	OLAP, KPI	10, 11	G5a	8/8
L8	Visualisations, Power BI	12, 13	G5b	8/8
L9	Data Storytelling, tests du pipeline	14, 15	G6	101/101
L10	Rapports, présentation	16, 17, 18	—	Ce document

Outils et assistance. Ce projet a été réalisé avec l'assistance d'un outil d'IA générative (Claude, Anthropic) pour la génération de code, la documentation et la revue de qualité. Les choix de conception ont été arbitrés et validés par l'auteure à chaque lot ; l'exécution des tests, la vérification des résultats et la validation finale ont été effectuées par l'auteure, sur son poste (Windows, Python 3.14, Docker, Power BI Desktop).

Pourquoi cette méthode ? Une erreur découverte en L8 dans un chiffre du tableau de bord peut venir de n'importe quelle couche. Avec une porte par couche, chaque couche est prouvée juste **avant** de construire la suivante : quand un écart apparaît, on sait où chercher.

4. Les cinq sources

Source	Technologie	Contenu	Volume	Anomalies injectées
S1 Gestion académique	PostgreSQL 15	Étudiants, filières, classes, inscriptions, paiements	67 882 lignes (5 tables)	16 types (A01 à A16)
S2 Plateforme pédagogique	MySQL 8.0	Modules, cours, quiz, notes, progression, connexions	422 218 lignes (6 tables)	16 types (B01 à B16)
S3 Ressources humaines	Fichiers CSV	Enseignants, départements, salaires, absences	6 728 lignes (4 fichiers)	19 types (C01 à C19)
S4 Application mobile	MongoDB 6	Événements (14 types)	297 601 documents	11 types (D01 à D11)
S5 Temps réel	Redis 7	Sessions, progression, classement, notifications, compteurs	4 608 clés	7 types (E01 à E07)

Source	Technologie	Contenu	Volume	Anomalies injectées
Total			**≈ 800 000 enregistrements**	**69 types**

Les anomalies suivent les recommandations des PDF sources : doublons, formats de dates multiples, encodages mélangés (UTF-8 et ISO-8859-1), séparateurs différents, catégories mal orthographiées, identifiants incompatibles, enregistrements orphelins. Chaque anomalie est **journalisée** au moment de son injection (`data/anomalies/`). Ce journal sert de vérité terrain pour prouver qu'elle a bien été traitée (porte G3), et il n'est **jamais lu par le pipeline**.

5. Les choix structurants, et leurs alternatives

Décision	Alternative écartée	Pourquoi ce choix	Document
ELT (plus précisément EtLT)	ETL	Garder le brut dans l'entrepôt pour **prouver** chaque correction ; changer une règle sans réextraire ; MongoDB et Redis chargés tels quels en JSONB. **Pas** pour une raison de volume : ≈ 800 000 enregistrements, ce n'est pas du Big Data	04_etl_vs_elt.md
Data Warehouse PostgreSQL en couches (bronze, argent, or)	Data Lake, Lakehouse	Données structurées, volume modeste, besoin de requêtes SQL fiables et traçables	03_architectures.md
3 actions qualité : corriger, rejeter, signaler	Tout corriger	**Corriger n'est pas inventer** : 45 règles signalent la valeur au lieu de la deviner	05_qualite.md
Constellation de 8 faits	Une étoile unique, un flocon	8 processus métier avec des grains différents (un paiement, une note, une connexion…), et des dimensions **conformes** partagées	07_conception_dw.md
7 dimensions au lieu des 5 du PDF	Formation unique	Le PDF mélange l'offre diplômante (filière, classe) et l'offre en ligne (module, quiz) : deux hiérarchies différentes, donc trois dimensions	07_conception_dw.md
SCD 2 sur la ville et la région de l'étudiant	SCD 1 (écraser)	Un paiement de 2024 doit rester attribué à la région de 2024 (cas pratique de la Phase 9)	07_conception_dw.md
Nombre réel d'étudiants = personnes distinctes	Somme des sources	La somme naïve donne **26 476**, le rapprochement **10 500**	11_kpi.md
Médiane du temps de connexion	Moyenne	Résiste aux sessions anormales (jusqu'à 480 min)	11_kpi.md
Satisfaction déclarée non mesurable	Indicateur de substitution	Aucune source ne la contient ; un substitut tromperait le décideur	11_kpi.md
Étoiles pures dans Power BI	Reproduire le flocon du DW	Deux chemins vers une même dimension rendent le filtrage ambigu	13_powerbi.md

6. Difficultés rencontrées et solutions

Chaque difficulté ci-dessous a réellement eu lieu ; elle est tracée dans le lot indiqué.

#	Lot	Difficulté	Cause	Solution	Ce que j'en retiens
1	L1	Un même étudiant porte deux identifiants (UUID dans PostgreSQL, `LMS-XXXXXX` dans MySQL)	Systèmes conçus séparément (PDF MySQL : « ne pas utiliser `id_etudiant` »)	Table de correspondance `mapping_etudiants` (9 000 paires), 1 000 inscrits sans compte LMS et 500 comptes LMS sans inscription rendus visibles	L'intégration commence par la question « qui est qui ? »
2	L2-c, L4	Données différentes sur deux postes, à graine identique	Faker produit des dates qui dépendent du fuseau de la machine, et Windows refuse les dates antérieures à 1970	`common.seed.random_date` : on tire un nombre de jours, jamais une date Faker (convention C25)	La reproductibilité se teste, elle ne se suppose pas
3	L5	Une anomalie Redis introuvable par la porte G3	`statistics:today` expire au bout d'une heure : la donnée a disparu avant l'extraction	Garde-fou à l'extraction (alerte), tolérance de G3 **limitée à Redis**, régénération du snapshot juste avant le pipeline	Une source volatile se juge à l'instant de son extraction
4	L6	L'étape DW refusée par le journal	`CREATE TABLE IF NOT EXISTS` ne modifie pas une table existante : la contrainte `ck_log_etape` de L4 ignorait l'étape `DW`	La contrainte est redéfinie (`DROP` puis `ADD`) à chaque initialisation	Un script « idempotent » doit aussi savoir faire **évoluer** un schéma
5	L6	`TRANSFORMs2_mysql` : **486 s**	Les tables temporaires n'ont pas de statistiques : PostgreSQL estimait 1 ligne là où il y en avait des dizaines de milliers, et choisissait des boucles imbriquées	51 `ANALYZE` explicites : **23 s** (21 fois plus rapide), chiffres inchangés	Mesurer avant d'optimiser (`EXPLAIN`, `scripts/diagnostic_perf.py`)
6	L8	Filtrage ambigu dans Power BI	Relations créées automatiquement, branche en flocon `dim_quiz` → `dim_module`	2 relations supprimées, modèle en étoiles pures, aucun filtrage bidirectionnel	Ne jamais accepter les relations automatiques sans les relire
7	L8	Pas de boxplot natif dans Power BI	Limite de l'outil	Visuel certifié AppSource, avec le graphique Python en alternative	Connaître les limites de l'outil avant de promettre un visuel
8	L9	Une perte de lignes peut passer inaperçue	Une ligne écartée par un filtre ne lève aucune erreur	Équation de conservation (staging = clean + rejets) et **tests de mutation** : on casse volontairement une donnée pour vérifier que le test la détecte	Un test qui ne peut pas échouer ne prouve rien

#	Lot	Difficulté	Cause	Solution	Ce que j'en retiens
9	L10	Un taux de recouvrement de **2 821 %** dans Power BI, puis de **32 à 47 %** dans ma requête de vérification	Ma requête joignait les paiements et les inscriptions **ligne à ligne** : le montant dû de chaque inscription était compté une fois **par paiement** (2,29 paiements par inscription ; 90,10 % ÷ 2,29 ≈ 39,4 %). C'est le « chasm trap » de la modélisation dimensionnelle	Agréger chaque fait **séparément**, puis joindre les résultats : Kaffrine est à **89,68 %**. Hypothèse « déménagements SCD 2 » réfutée par deux requêtes (0 paiement rattaché à une autre région que son inscription ; 0 version SCD 2). **Cause du 2 821 %** : dans Power BI, la relation `fact_paiements → dim_region` était **inactive** ; le filtre de région ne touchait pas le CA. Relation rendue active	Dans une constellation, on n'additionne jamais les mesures de deux faits joints ligne à ligne. Une hypothèse se **teste** avant d'être écrite. Et un total juste ne prouve pas qu'un modèle filtre juste : la porte G5b, qui ne contrôle que des totaux, était verte

7. Tests et qualité

Niveau	Volume	Rôle
Tests unitaires (sans base)	303	Règles de nettoyage, calculs des KPI, équation de conservation, cohérence des chiffres des rapports
Tests d'intégration (5 vraies sources)	69	Pipeline complet, portes, idempotence, cas limites du SCD 2, **9 tests de mutation**
Portes de contrôle	G0 à G6	7 portes, toutes vertes

Les KPI sont calculés par **trois chemins** qui doivent donner le même résultat : SQL sur le DW, Python sur la couche clean (porte G5a), DAX dans Power BI (porte G5b). La porte G6 fige ces valeurs : toute modification du pipeline qui changerait un KPI la fait échouer.

Le détail est dans 15_tests_pipeline.md.

8. Limites du projet

Limite	Conséquence	Où c'est documenté
Données simulées	Plusieurs « constats » restituent des paramètres du générateur (pic d'activité à 20 h, poids de Dakar, abandon de 6 %) : ils valident le pipeline, pas un comportement réel	14_data_storytelling.md, § 8.1
Satisfaction et évaluation des enseignants absentes	2 des 7 questions du DG restent sans réponse	02_besoin_metier.md
KPI d'activité incomplet	Les vidéos et téléchargements MongoDB ne sont pas dans le DW	11_kpi.md
Snapshot Redis unique	Pas d'historique temps réel (une seule photographie, le 15/09/2026 à 23 h)	Convention C24
Pas de déploiement	Le pipeline tourne à la demande, sans planificateur (Airflow, cron) ni rafraîchissement automatique du tableau de bord	—

9. Bilan personnel

Texte de l'auteure.

Durée et méthode. J'ai consacré environ trois semaines à ce projet, en travaillant par lots successifs (L0 à L10), avec une méthode rigoureuse de tests et de portes de contrôle.

Ce qui a été le plus difficile. La gestion des 159 946 anomalies dans la couche clean : il fallait à la fois les corriger, les tracer et ne pas casser les KPI validés. Puis la compréhension du fan-out dans ma requête Kaffrine, qui m'a fait réaliser qu'une jointure ligne à ligne entre deux faits fausse tout.

Ce que j'ai préféré. La construction du tableau de bord Power BI, parce qu'elle transforme dix lots de travail technique en quelque chose de visuel et de compréhensible pour un décideur.

Ce que j'ai appris. Les fondamentaux de la BI de bout en bout (ETL/ELT, Data Warehouse en constellation, OLAP, KPI, Power BI), mais aussi la rigueur nécessaire pour intégrer cinq sources hétérogènes sans perdre une seule ligne, et l'importance des tests automatisés (372 tests : 303 unitaires et 69 d'intégration) pour garantir la fiabilité.

Ce que je referais autrement. Je prendrais plus de temps sur la modélisation initiale pour anticiper les pièges comme le fan-out, et je documenterais mes décisions au fur et à mesure plutôt qu'à la fin.

10. Compétences mobilisées

Chaque compétence renvoie à un élément vérifiable du dépôt.

Domaine	Compétence	Preuve
Ingénierie des données	Pipeline ELT multi-sources (SQL et NoSQL), idempotent, journalisé	`pipeline/run_pipeline.py`, `meta.etl_execution_log`
SQL (PostgreSQL)	CTE, fonctions de fenêtrage, `JSONB`, fonctions PL/pgSQL, `GROUP BY CUBE`, optimisation (`ANALYZE`, `EXPLAIN`)	`pipeline/sql/`
Python	psycopg2, PyMySQL, pymongo, redis-py, pandas, Faker	`sources/`, `pipeline/`
Qualité des données	89 règles sur 5 dimensions (complétude, unicité, cohérence, exactitude, fraîcheur), rejets tracés	05_qualite.md
Modélisation	Constellation, dimensions conformes, grain, SCD 2, membres « Inconnu »	07_conception_dw.md
BI et visualisation	Power BI (DAX, modèle en étoile, hiérarchies, segments), matplotlib	`powerbi/`, `scripts/visualisations.py`
Tests	pytest, tests d'intégration, tests de mutation, portes de contrôle	`tests/`, `pipeline/verify_g*.py`
Infrastructure	Docker Compose (6 services), configuration par variables d'environnement	`docker/`
Communication	Data Storytelling, recommandations à un décideur, honnêteté sur les limites	14_data_storytelling.md, 17_rapport_decisionnel.md

Références

- PDF « BI Recherche P8 », Phases 1 à 18 ; PDF « Données EduSmart » ; PDF des 5 sources.
- R. Kimball et M. Ross, *The Data Warehouse Toolkit*, 3e éd. (2013).

- R. Kimball et J. Caserta, *The Data Warehouse ETL Toolkit* (2004).
- Documentation du projet : docs/README.md.

Phase 17 — Rapport décisionnel

EduSmart Decision Platform · Lot L10 · Données au 15/09/2026 · À l'attention du Directeur Général

> **PDF, Phase 17 :** fusionner les cinq sources pour produire un pipeline ETL unique, un Data Warehouse commun, une base multidimensionnelle, un cube OLAP, un tableau de bord Power BI et **un rapport décisionnel complet**.
>
> Ce rapport s'adresse au **décideur**. Les choix techniques sont expliqués dans le rapport individuel ; le récit détaillé des résultats est dans le Data Storytelling.

---

1. Résumé exécutif

> **EduSmart encaisse 90 % de ce qu'elle attend et ses apprenants réussissent leurs quiz (93 %), mais seulement 3 sur 10 sont actifs sur 30 jours. La priorité n'est plus de recruter, c'est d'engager et d'écouter.**

Ce qui va bien

- **10 500** étudiants réels, enfin comptés une seule fois (la somme des systèmes en annonçait 26 476).
- **13,554 Mds XOF** encaissés ; activité multipliée par deux en deux ans (3 617 → 7 383 inscriptions).
- **93,13 %** de réussite aux quiz ; sessions médianes de **29 min**.

Trois alertes

1. **L'argent non encaissé a doublé en deux ans** : 311 M → 655 M XOF par année académique, à taux de recouvrement constant (≈ 90 %).
2. **71 % des étudiants sans activité mesurée sur 30 jours** : 3 003 actifs sur 10 500 (28,6 %, cible proposée 30 %).
3. **L'abandon dépasse la cible depuis trois ans** : 6,24 % (cible proposée 5 %).

Deux angles morts : ni la satisfaction des étudiants, ni la qualité des enseignants ne sont mesurées.

Un constat RH : **62 %** des heures d'absence des enseignants ne sont pas remplacées, soit **6 409 heures** de cours perdues en trois ans.

Sept recommandations (§ 6), dont deux à lancer en priorité : **mesurer la satisfaction** (R1) et **relancer les impayés** (R3).

2. Contexte et périmètre

Élément	Valeur
Sources intégrées	5 : gestion académique (PostgreSQL), plateforme pédagogique (MySQL), ressources humaines (CSV), application mobile (MongoDB), temps réel (Redis)
Volume traité	≈ 800 000 enregistrements
Période	Années académiques 2023-2024 à 2025-2026 (rentrée au 1er octobre)
Date de référence	15/09/2026 : aucune activité au-delà

Élément	Valeur
Restitution	Tableau de bord Power BI, 4 pages : Vue Direction, Finance, Pédagogie, Engagement
Devise	XOF (franc CFA)

⚠️ **Les données sont simulées** (générées pour le projet). Les mécanismes de mesure sont réels et vérifiés ; certains constats reflètent les paramètres de la simulation (§ 7.1). Chaque recommandation indique son niveau de confiance.

3. Peut-on faire confiance à ces chiffres ?

Oui, et voici pourquoi :

Garantie	Preuve
Aucune donnée perdue sans trace	Chaque ligne extraite arrive dans l'entrepôt ou est écartée **avec son motif** : l'équation est vérifiée à chaque exécution, table par table (101 contrôles automatiques)
Les erreurs de saisie sont traitées, pas ignorées	159 946 anomalies traitées : 55 853 corrigées, 25 932 traitées par rejet, 78 161 signalées sans être devinées
Chaque KPI est calculé trois fois	Trois langages, trois couches (SQL sur l'entrepôt, Python sur les données nettoyées, DAX dans Power BI) : même résultat
Les contrôles savent détecter une erreur	9 tests introduisent volontairement une erreur (ligne perdue, clé orpheline, montant faussé de 1 000 XOF) : tous détectés
Le tableau de bord est réconcilié avec l'entrepôt	Un taux aberrant observé dans Power BI (Kaffrine) a été recalculé dans l'entrepôt : 89,68 %, valeur normale (§ 7.2)

4. Les indicateurs clés

KPI	Valeur au 15/09/2026	Cible proposée	Statut	Responsable
Chiffre d'affaires encaissé	**13,554 Mds XOF**	≥ CA de l'année précédente à date	✅	DG, Finance
Taux de recouvrement	**90,10 %**	≥ 90 %	✅ (de justesse)	Finance
Taux de réussite aux quiz	**93,13 %**	≥ 85 %	✅	Pédagogie
Taux d'abandon	**6,24 %**	≤ 5 %	⚠️	DG, Pédagogie
Progression moyenne	**65,59 %**	≥ 70 %	⚠️	Pédagogie
Étudiants actifs (30 jours)	**3 003** (28,6 %)	≥ 30 %	⚠️	DG
Temps médian de connexion	**1 740 s (29 min)**	≥ 20 min	✅	Pédagogie
Nombre réel d'étudiants	**10 500**	Suivi	—	DG
Satisfaction des étudiants	**Non mesurée**	—	❌	DG

Les cibles sont des propositions (lot L7) : aucune source ne contient d'objectif. Elles sont à valider par la direction. Définitions complètes : 11_kpi.md.

5. Analyse par axe

5.1 Finance : l'argent rentre, mais les impayés grossissent

Année académique	Inscriptions	Montant dû	Encaissé	Non encaissé	Recouvrement
2023-2024	3 617	3 179 M	2 868 M	311 M	90,19 %
2024-2025	6 191	5 624 M	5 101 M	523 M	90,70 %
2025-2026	7 383	6 240 M	5 585 M	655 M	89,51 %
Total		**15 043 M**	**13 554 M**	**≈ 1 489 M**	**90,10 %**

Millions de XOF, arrondis. Chaque montant est rattaché à l'année de la formation payée.

- **Le taux est stable, le montant ne l'est pas.** À 90 % de recouvrement, chaque doublement de l'activité double les impayés.
- **L'année 2025-2026 n'est pas close** : une partie des 655 M peut encore être encaissée.
- **Aucune région n'est en décrochage** : de 88,57 % (Matam) à 93,29 % (Kédougou) ; Dakar à 90,16 %.
- **Saisonnalité** : le pic d'encaissement est en octobre, à la rentrée (1re tranche).

5.2 Pédagogie : on réussit les quiz, on ne finit pas les parcours

Indicateur	Valeur	Lecture
Réussite aux quiz	93,13 %	Couples (étudiant, quiz) validés **au moins une fois**, toutes tentatives confondues. Ce n'est **pas** la réussite au diplôme, qu'aucune source ne contient
Progression moyenne	65,59 %	Un tiers des contenus en ligne n'est pas parcouru
Abandon	6,24 %	Stable sur trois ans (6,25 % ; 6,33 % ; 6,16 %) : un phénomène structurel, pas un accident
Distribution des scores	Centrée vers 10-12/20, accumulation à 20/20	Effet plafond : ces quiz ne distinguent plus les meilleurs étudiants
Tentatives et score	Relation négative faible (r = −0,20)	Ceux qui retentent ont un score moyen plus bas : un signal pour cibler le tutorat, **pas** une cause

La source ne date pas l'abandon et n'en donne pas le motif : on sait **combien** abandonnent, pas **quand** ni **pourquoi**.

5.3 Engagement : présents le soir, absents sur la durée

Indicateur	Valeur	Lecture
Étudiants actifs sur 30 jours	3 003 (28,6 %)	**Valeur minimale** : les vidéos et téléchargements de l'application mobile ne sont pas encore comptés
Temps médian de connexion	29 min	Identique sur mobile, PC et tablette
Créneau d'activité	Pic entre 20 h et 22 h, tous les jours	Aucune connexion entre minuit et 6 h, pas d'effet week-end
Heures connectées et progression	Aucune relation (r = −0,01)	Passer plus de temps connecté ne s'accompagne pas d'une meilleure progression

5.4 Ressources humaines

Masse salariale

Année académique	Enseignants	dont permanents	Masse salariale nette	Part des permanents	Salaire net moyen (par bulletin)
2023-2024	114	72	980,7 M	89,1 %	728 038
2024-2025	116	74	1 033,3 M	89,8 %	751 492 (+3,2 %)
2025-2026	120	78	1 020,4 M	90,3 %	784 355 (+4,4 %)
Total			**3 034,4 M**		**+7,7 % en deux ans**

Millions de XOF. Année du bulletin de salaire. 2025-2026 ne couvre que 11 mois : les salaires sont versés jusqu'en août 2026.

- Les **permanents** (65 % des enseignants) représentent **90 %** de la masse salariale ; les vacataires (42 chaque année) en représentent 10 %.
- Sur trois ans, la masse salariale représente **22,4 %** du CA encaissé. C'est un ordre de grandeur : le CA est rattaché à l'année de la formation, les salaires à la date du bulletin.
- **Encadrement** : les inscriptions ont doublé (3 617 → 7 383), les enseignants n'ont augmenté que de 5 % (114 → 120). Soit **31,7 → 61,5 inscriptions par enseignant**. *Prudence : l'effectif enseignant de la simulation est plafonné à 120 par construction (convention C18). Sur données réelles, ce ratio serait un indicateur de charge à suivre.*

Absences des enseignants

Année académique	Absences	Heures	Heures non remplacées	Part non remplacée
2023-2024	798	3 581	2 144	59,9 %
2024-2025	774	3 400	2 211	65,0 %
2025-2026	771	3 384	2 054	60,7 %
Total	**2 343**	**10 365**	**6 409**	**61,8 %**

- **6 409 heures de cours non remplacées en trois ans** : c'est le chiffre RH qui touche directement les étudiants.
- Les motifs sont répartis presque uniformément (de 209 à 239 absences pour 10 motifs). Cette régularité est probablement un effet de la simulation.
- Entre 68 % et 79 % des absences sont justifiées selon le motif.
- **Incohérence de saisie à vérifier** : 89 absences **sans motif**, dont 77,5 % sont pourtant marquées « justifiées ».
- 79 durées aberrantes ont été neutralisées (non comptées dans les heures).

6. Recommandations

#	Recommandation	Constat	KPI de suivi	Responsable	Confiance	Priorité
R1	Collecter un **score de satisfaction** (1 à 5) à la fin de chaque module	Satisfaction non mesurée	Satisfaction	DG	Haute	**1**
R2	Créer une **évaluation des enseignements** et une table d'**affectation** enseignant ↔ cours	Qualité des enseignants non mesurée	Note moyenne par enseignant	Pédagogie, RH	Haute	2
R3	**Plan de relance des impayés** dès la 2e tranche, piloté par le Top 10 des impayés	≈ 1 489 M XOF non encaissés, en hausse	Recouvrement, impayés	Finance	Moyenne	**1**

#	Recommandation	Constat	KPI de suivi	Responsable	Confiance	Priorité
R4	**Programme de réactivation** des inactifs (relance après 15 jours sans activité, tutorat ciblé sur les étudiants qui retentent le plus)	71 % sans activité mesurée ; abandon 6,24 % ; progression 65,59 %	Actifs (30 j), abandon, progression	Pédagogie	Moyenne	2
R5	Intégrer les **vidéos et téléchargements** au Data Warehouse	KPI d'activité incomplet	Actifs (30 j)	Équipe data	Haute	3
R6	**Normaliser la saisie à la source** (listes fermées : modes de paiement, villes, catégories, motif d'absence obligatoire)	159 946 anomalies traitées ; absences « justifiées sans motif »	Taux de conformité qualité	DSI, chaque service	Haute	3
R7	Un **dispositif de remplacement** des enseignants absents (vivier de vacataires, cours enregistrés)	61,8 % des heures d'absence non remplacées	Part des heures remplacées	RH, Pédagogie	Moyenne (à confirmer sur données réelles)	2

Ce qui n'est pas recommandé : investir dans une application tablette pour allonger les sessions (durées identiques sur tous les appareils), ni inciter à « se connecter plus longtemps » pour progresser (aucune relation observée).

Pourquoi R1 en premier ? Les trois alertes (impayés, inactivité, abandon) ont une cause commune possible que les données actuelles ne permettent pas d'établir. Sans la voix des étudiants, R3 et R4 traitent les symptômes.

7. Ce que les données ne permettent pas de dire

7.1 Les effets de la simulation

Plusieurs résultats restituent les paramètres du générateur de données : le pic d'activité à 20 h, le poids de Dakar dans le CA (29 %), l'abandon de 6 %, l'uniformité du recouvrement entre filières, l'effectif enseignant plafonné à 120. Ces constats démontrent que la plateforme **sait mesurer** ces phénomènes ; ils ne décrivent pas un comportement réel. Le détail, vérifié dans le code, est au § 8.1 du Data Storytelling.

7.2 Le taux de recouvrement par segment : le cas Kaffrine

Un filtre sur la région de Kaffrine affichait **2 821 %** dans Power BI. L'entrepôt a été interrogé directement :

Vérification	Résultat
Recouvrement de Kaffrine, calculé dans l'entrepôt	**89,68 %** : normal (14 régions entre 88,57 % et 93,29 %)
Recouvrement par filière à Kaffrine	de 79,84 % à 100 %, **aucun au-dessus de 100 %**
Paiements rattachés à une autre région que leur inscription	**0** sur 38 372
Étudiants ayant déménagé (versions SCD 2)	**0**

Conclusion : l'entrepôt est juste. Les hypothèses « petit effectif » et « déménagements » ont été testées et **réfutées**. La cause était dans le tableau de bord : la relation entre les paiements et les régions était **inactive**. Un filtre de région s'appliquait au montant dû, mais pas au chiffre d'affaires : le CA de toutes les régions était divisé par le dû de Kaffrine seule. **Corrigé le 21/10/2026** : le CA se répartit désormais correctement entre les régions (Dakar 29 %, Thiès 13 %, comme dans l'entrepôt). Power BI affiche désormais **89,29 %** pour Kaffrine, contre **89,68 %** dans l'entrepôt : l'aberration a disparu, mais il reste un écart de 0,39 point, non expliqué à ce jour et documenté dans 13_powerbi.md. **La valeur qui fait foi est celle de l'entrepôt, 89,68 %.**

Règles de lecture pour le décideur :

- un taux se calcule en agrégeant **séparément** le numérateur (paiements) et le dénominateur (inscriptions) ; additionner après avoir croisé les deux tables gonfle le dénominateur (une vérification intermédiaire, faite ainsi, avait donné 32 à 47 % : un autre faux résultat) ;
- au-delà de 100 %, ou très loin de la moyenne, on vérifie le calcul avant de conclure ;
- sur une petite population (une région × une filière), deux filières à 100 % peuvent ne compter que quelques inscriptions : un taux se lit avec son effectif.

7.3 Les autres limites

Limite	Conséquence
Satisfaction et évaluation des enseignants absentes	2 des 7 questions de la direction sans réponse
Abandon non daté, sans motif	On ne peut ni prévenir l'abandon au bon moment, ni en traiter la cause
Réussite au diplôme absente	Le taux de réussite ne porte que sur les quiz en ligne
Snapshot temps réel unique (15/09/2026, 23 h)	Pas de tendance sur les données temps réel
Aucun historique de déménagement dans l'entrepôt actuel	Le mécanisme d'historisation (SCD 2) est en place et testé, mais aucun étudiant n'a changé de ville dans les données chargées
Pas de rafraîchissement automatique	Le tableau de bord se met à jour à la demande, après exécution du pipeline

8. Annexes

8.1 Glossaire

Terme	Définition
KPI	Indicateur clé de performance : une mesure rattachée à un objectif, avec une cible
Recouvrement	Encaissé ÷ montant dû (frais annuels de la classe, après réduction)
Étudiant actif	Au moins une connexion, une note ou une activité de quiz dans les 30 jours précédant le 15/09/2026
Médiane	Valeur qui partage les observations en deux moitiés égales ; insensible aux valeurs extrêmes
Data Warehouse	Base de données unique, construite pour l'analyse, qui réunit les 5 sources après nettoyage
SCD 2	Historisation d'un attribut (ici la ville de l'étudiant) : l'ancienne valeur est conservée avec ses dates de validité

8.2 Pour aller plus loin

Besoin	Document
Le récit détaillé et les objections probables	14_data_storytelling.md
Les fiches des 8 KPI	11_kpi.md
Le tableau de bord, page par page	13_powerbi.md, `powerbi/EduSmart.pdf`
La fiabilité du pipeline	15_tests_pipeline.md
La démarche technique	16_rapport_individuel.md

Sources des chiffres : vues `dw.v_kpi` et `dw.v_kpi_annee` (KPI, finance) ; requêtes K1 à K4 et RH1 à RH4 du lot L10, exécutées sur l'entrepôt le 12/10/2026, après validation de la porte G6 (101/101).

Phase 18 — Présentation

EduSmart Decision Platform · Lot L10 · Support : `presentation/EduSmart_presentation.pptx` *(21 diapositives, 16:9)*

> **PDF, Phase 18 :** présenter 1. le contexte métier, 2. les sources de données, 3. les difficultés d'intégration, 4. le pipeline ETL/ELT, 5. les contrôles qualité réalisés, 6. les métadonnées produites, 7. le Data Warehouse, 8. le modèle multidimensionnel, 9. les KPI retenus, 10. le tableau de bord Power BI, 11. les recommandations stratégiques.
>
> Il n'y a pas de soutenance orale : le support doit se comprendre **seul**. Chaque diapositive porte un titre qui énonce sa conclusion, et des notes de l'orateur qui la complètent.

---

1. Principes de construction

Principe	Application
Commencer par la conclusion	La diapositive 2 donne l'idée maîtresse et quatre chiffres avant tout détail technique
Un message par diapositive	Le titre est une phrase (« Le taux de recouvrement est stable, les impayés doublent »), pas un sujet (« Finance »)
Suivre les 11 points du PDF	Un cercle safran numéroté (1 à 11) signale chaque point ; les diapositives sans numéro sont des résultats ou des limites
Des chiffres vérifiables	Tous viennent des documents validés (11, 14, 15, 17) ; un test automatique compare ceux du support à la référence des KPI
Le rouge brique pour ce qui s'écarte de la cible	Abandon, progression, étudiants actifs, impayés, heures non remplacées
Des graphiques natifs	Les 3 graphiques (qualité, impayés, RH) sont des graphiques PowerPoint modifiables, pas des images
Honnêteté	Une diapositive dédiée à ce que les données ne permettent pas de dire

Palette : bleu nuit (fonds de titre, textes), sarcelle (résultats conformes), safran (motif, accent), rouge brique (alertes). **Polices** : Cambria pour les titres, Calibri pour le texte (installées avec Office).

2. Les 21 diapositives

#	Section	Point PDF	Titre (le message)	Contenu
1	Introduction	—	EduSmart Decision Platform	De cinq sources dispersées à une plateforme décisionnelle
2	Introduction	—	L'essentiel en une page	Idée maîtresse ; 10 500 étudiants réels, 13,554 Mds XOF encaissés, 90,10 % de recouvrement, 3 003 actifs (28,6 %)
3	Le projet	1	Le Directeur Général pose 7 questions	5 répondues, 2 sans données (satisfaction, évaluation des enseignants)
4	Le projet	2	Cinq sources hétérogènes, volontairement imparfaites	Volumes et types d'anomalies par source (≈ 800 000 enregistrements, 69 types)

#	Section	Point PDF	Titre (le message)	Contenu
5	Le projet	3	Intégrer, c'est d'abord savoir qui est qui	26 476 → 10 500 personnes ; identifiants, formats, source volatile
6	Le projet	4	ELT : transformer dans l'entrepôt	Schéma sources → bronze → argent → or → Power BI ; pourquoi ELT
7	Le projet	5	159 946 anomalies traitées, aucune devinée	Graphique corrigées / rejetées / signalées ; 69/69, 89 règles
8	Le projet	5	Sept portes de contrôle, toutes vertes	G0 à G6 ; équation de conservation ; 368 tests ; 9 mutations détectées
9	Le projet	6	Chaque chiffre est traçable jusqu'à sa source	`metadata_sources`, `etl_execution_log`, lignage de bout en bout
10	Le projet	7	Un entrepôt PostgreSQL en trois couches	Bronze, argent, or ; SCD 2 « un étudiant change de ville »
11	Le projet	8	Une constellation de 8 faits et 7 dimensions	Matrice de bus : grain de chaque fait, dimensions partagées
12	Les résultats	9	8 KPI, et un indicateur que l'on ne sait pas mesurer	8 cartes valeur / cible / statut ; satisfaction « non mesurée »
13	Les résultats	10	Power BI · Vue Direction : où en sommes-nous ?	CA et dû par année, satisfaction « non mesurée », CA par région ; avant / après le correctif
14	Les résultats	10	Power BI · page Finance : où en est le recouvrement ?	Matrice filière × année, impayés par filière ; principes du tableau de bord
15	Les résultats	10	Power BI · Pédagogie et Engagement	Histogramme des scores, carte de chaleur jour × heure
16	Les résultats	—	Le taux de recouvrement est stable, les impayés doublent	311 → 523 → 655 M XOF non encaissés ; régions de 88,57 % à 93,29 %
17	Les résultats	—	On réussit les quiz, on ne finit pas les parcours	93,13 % ; 65,59 % ; 6,24 % ; 28,6 % ; associations, pas causes
18	Les résultats	—	6 409 heures de cours non remplacées en trois ans	Graphique heures remplacées / non remplacées ; masse salariale ; salaire moyen
19	Décider	11	Sept recommandations, deux priorités	R1 à R7, KPI de suivi, priorité ; pourquoi R1 d'abord
20	Décider	—	Ce que ces données ne permettent pas de dire	Simulation, angles morts, Kaffrine, absence d'historique SCD 2
21	Décider	—	Engager et écouter	Conclusion : première décision, mesurer la satisfaction

3. Les chiffres du support et leur source

Chiffre	Valeur	Source
Chiffre d'affaires encaissé	13,554 Mds XOF	`dw.v_kpi`, 11_kpi.md
Taux de recouvrement	90,10 %	idem
Taux de réussite aux quiz	93,13 %	idem
Taux d'abandon	6,24 %	idem

Chiffre	Valeur	Source
Progression moyenne	65,59 %	idem
Étudiants actifs (30 jours)	3 003	idem
Temps médian de connexion	1 740 s (29 min)	idem
Nombre réel d'étudiants	10 500	idem
Anomalies traitées	159 946 (55 853 corrigées, 25 932 rejetées, 78 161 signalées)	Porte G3, 05_qualite.md
Non encaissé par année	311 M, 523 M, 655 M XOF	`dw.v_kpi_annee`, 17_rapport_decisionnel.md
Recouvrement par région	88,57 % à 93,29 % ; Kaffrine 89,68 %	Requête K1 (lot L10)
Heures d'absence non remplacées	6 409 sur 10 365 (61,8 %)	Requêtes RH3 et RH4 (lot L10)
Masse salariale nette	3 034 M XOF sur trois ans	Requêtes RH1 et RH2 (lot L10)
Tests automatisés	368 (299 unitaires, 69 d'intégration)	15_tests_pipeline.md

4. La page Vue Direction et le correctif du 21/10/2026

Dans le premier export du tableau de bord, le graphique « CA encaissé par région » de la page **Vue Direction** affichait 14 barres égales, au niveau du CA total. Cause : la relation `fact_paiements → dim_region` était **inactive** dans le modèle Power BI ; c'était aussi l'origine du taux de 2 821 % observé à Kaffrine. La relation a été rendue active le 21/10/2026 et le tableau de bord réexporté : la diapositive 13 montre la page Vue Direction corrigée, avec le constat avant / après (13_powerbi.md).

5. Régénérer le support

Le fichier `.pptx` a été construit par programme (pptxgenjs), à partir des chiffres ci-dessus, puis vérifié : validation du format PowerPoint, rendu de chaque diapositive, test automatique des chiffres (`tests/test_rapports.py`). Les captures Power BI sont des recadrages de `powerbi/EduSmart.pdf`. Toute modification d'un KPI doit être répercutée dans le support **et** dans la référence `REFERENCE_KPI` : le test signale tout écart.